



UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
DEPARTAMENTO DE INGENIERÍA ELÉCTRICA

**DETECCIÓN DE PATRONES ALTERNANTES CÍCLICOS EN REGISTROS
POLISOMNOGRÁFICOS DE NIÑOS**

MEMORIA PARA OPTAR AL TÍTULO DE INGENIERO CIVIL ELÉCTRICO

MARCELO ALEJANDRO MARÍN ABARCA

PROFESOR GUÍA:
CLAUDIO HELD BARRANDEGUY

MIEMBROS DE LA COMISIÓN:
PABLO ESTEVEZ VALENCIA
PATRICIO PEIRANO CAMPOS

SANTIAGO DE CHILE
2021

RESUMEN DE LA MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL ELÉCTRICO
POR: MARCELO ALEJANDRO MARÍN ABARCA
FECHA: 2021
PROF. GUÍA: CLAUDIO HELD BARRANDEGUY

DETECCIÓN DE PATRONES ALTERNANTES CÍCLICOS EN REGISTROS POLISOMNOGRÁFICOS DE NIÑOS

En este trabajo de título se desarrolló un sistema de detección automática de Patrones Alternantes Cílicos (CAP) en registros polisomnográficos de niños sanos, sin la necesidad del conocimiento previo de la evolución temporal de los estados y etapas de sueño durante la noche. Los CAP se definen como patrones electro-encefalográficos (EEG) que aparecen durante el estado de sueño quieto (NREM) y se asocian a la inestabilidad del sueño. Se componen de dos fases, A y B. Ambas fases pueden tener una duración de 2 a 60 s. Las fases A corresponden a un aumento de amplitud y cambio de frecuencia respecto de la actividad de fondo del EEG, y se distinguen tres tipos. Las fases B son la actividad de fondo del EEG, asociadas a fases A. Para definir un CAP deben ocurrir al menos dos fases A, a una distancia temporal de 2 a 60 s.

El sistema de detección que se desarrolló incluye las siguientes técnicas de procesamiento de señales: transformada de Fourier (FFT) y el método de Welch. Se probaron clasificadores basados en Redes Neuronales Artificiales (ANN) y Random Forest (RF). El detector automático de CAP puede ser considerado un sistema modular en cascada: El primer módulo detecta tramos de EEG compatibles con el estado de sueño NREM, en los módulos siguientes se buscan eventos de fases A en esos tramos, y luego se asocian temporalmente para definir la presencia de CAP. Además se analizan las características de las fases A para identificar su tipo.

La base de datos utilizada consta de 48 registros polisomnográficos nocturnos de niños, adquiridos en el Laboratorio de Sueño y Neurobiología Funcional del Instituto de Nutrición y Tecnología de los Alimentos (INTA), U. de Chile. La base de datos fue dividida en los conjuntos de entrenamiento (22 registros), validación (6 registros) y prueba (20 registros). Los registros tienen marcadas las fases A, lo que fue realizado por un experto en sueño mediante inspección visual. Estas marcas fueron consideradas como *ground truth* para evaluar el desempeño del sistema.

Los resultados obtenidos en la detección de fases A con el conjunto de prueba en los registros completos de sueño nocturno muestran 79,4 % de sensibilidad para clasificadores basados en ANN. Para clasificadores basados en RF los resultados fueron 78,3 % de sensibilidad. Considerando sólo los segmentos NREM en el conjunto de prueba los resultados mejoran, mostrando 80,1 % de sensibilidad, para clasificadores ANN, y 79,2 % de sensibilidad, para clasificadores RF.

Los resultados en la detección de CAP para el conjunto de prueba en los registros completos de sueño nocturno muestran 81,3 % de sensibilidad para clasificadores ANN, y 69,5 % de sensibilidad para clasificadores RF. Considerando sólo los segmentos NREM en el conjunto de prueba se obtiene 81,5 % de sensibilidad, para clasificadores ANN, y 71,6 % de sensibilidad, para clasificadores RF.

Este trabajo de memoria permitió llegar, principalmente, a dos conclusiones. Primero, los resultados de la detección de fases A son similares o superiores a los reportados en otros trabajos, pero como no se utilizan las mismas bases de datos, la comparación es limitada. Los resultados obtenidos en la identificación del tipo de fase A también son similares a los de la literatura. Segundo, los resultados de la detección de CAP son bajos. La mayor proporción de errores en las detecciones se deben a que el sistema etiqueta fases A no marcadas por el experto (tasa significativa de falsos positivos), y por consiguiente aumenta la marca de zonas de CAP. No se encontraron estudios con los cuales comparar este resultado.

Con mucho cariño a mi familia.

Agradecimientos

Quiero agradecer a mis padres y familia, quienes siempre me han dado un apoyo incondicional.

Agradecer a mis amigas y amigos por entregarme felicidad y risas durante este período, además de ser un tremendo apoyo durante el tiempo que llevo en la universidad.

También agradecer a los profesores y profesoras que conocí en la universidad, quienes no solo me transmitieron la materia del curso que imparten, sino que también me han permitido crecer como un ser humano integral. En particular, agradecer al profesor Claudio Held, por su gran disposición y paciencia, también a sus críticas, que sin duda han sido fundamentales para realizar este trabajo.

Tabla de contenido

1. Introducción	1
1.1. Características del Sueño	1
1.2. Patrones Alternantes Cílicos	2
1.3. Objetivos	3
1.3.1. Objetivos Generales	3
1.3.2. Objetivos Específicos	4
1.4. Estado del Arte	5
1.4.1. Sistemas de detección automática de fases A	5
1.4.2. Identificación del tipo de fase A	9
2. Metodología	11
2.1. Sujetos y registros	11
2.2. Procedimiento de adquisición	11
2.3. Base de datos	12
2.4. Métodos de clasificación	13
2.4.1. Aprendizaje supervisado	13
2.4.2. Redes neuronales artificiales	14
2.4.3. Random Forest	15
2.5. Sistema de detección automática de CAP	16
2.5.1. Módulo 1: Detección de zonas compatibles con CAP en el EEG	18
2.5.2. Módulo 2: Detección automática de fases A	20
2.5.2.1. Aplicación de FFT y método de Welch	22
2.5.2.2. Características para clasificar A1, A3 y B	22
2.5.2.3. Clasificador de fases A1, A3 y B	23
2.5.2.4. Determinación de una fase A en base a votación entre clasificadores	25
2.5.3. Módulo 3: Clasificador de tipo de fase A	26
2.5.4. Módulo 4: Identificación de CAP	27
2.6. Métricas de desempeño	27
2.6.1. Indicadores para evaluar la detección de fases A	27
2.6.2. Indicadores para la identificación del tipo de fase A	28
2.6.3. Métricas para detección de CAP	29
3. Resultados	30
3.1. Resultados del sistema de detección automática de fases A (módulo 2)	30
3.2. Resultados del sistema de identificación del tipo de fase A (módulo 3)	35
3.3. Resultados globales de CAP (módulo 4)	37

4. Discusión	43
4.1. Análisis de resultados	43
4.1.1. Detección automática de fases A (módulo 2)	43
4.1.2. Identificación del tipo fase A (módulo 3)	49
4.1.3. Sistema de detección automático de CAP (módulo 4)	51
5. Conclusiones	54
5.1. Detección de fases A	54
5.2. Identificación del tipo de fase A	54
5.3. Sistema de detección automático de CAP	55
5.4. Trabajo futuro	55
Bibliografía	57
Anexo A. Base de datos	60
Anexo B. Resultados	63

Índice de Tablas

1.1.	Resultados de detección automática de fases A publicados por Mariani et. al. en 2012, utilizando distintos métodos de clasificación sobre segmentos de registros de sueño en estado NREM [14].	6
1.2.	Resultados obtenidos por Machado et. al. [11] en la detección automática de fases A utilizando distintos métodos de clasificación. Nota: Los porcentajes de los resultados han sido presentados tal como los presentó Machado et al. . . .	8
1.3.	Resultados recientes obtenidos por Hartmann y Baumert [6] en la detección automática de fases A utilizando distintos métodos, en segmentos de registros EEG en estado de sueño NREM.	8
1.4.	Resultados obtenidos por Machado et. al. [11], para los distintos clasificadores de tipo de fases A evaluados sobre registros de sueño completos. Se presenta la sensibilidad para cada fase, además de la exactitud total.	9
1.5.	Resultados obtenidos por Hartmann y Baumert [6] en la clasificación de tipo de fases A en segmentos de registros en estado de sueño NREM. Para ambas bases de datos evaluadas se presenta la sensibilidad para cada fase, además de la exactitud total.	9
3.1.	Fases A contenidas en la base de datos	30
3.2.	Cantidad y tipo de fases A en los registros del conjunto de prueba marcadas por experto. Se aprecia que la cantidad de fases A puede variar considerablemente entre registros, sin embargo, la cantidad de fases A1 suele ser mayor a la cantidad de fases A2 y A3.	31
3.3.	Tabla resumen de la detección automática de fases A, para registros de sueño completos, en los conjuntos de entrenamiento, validación y prueba, aplicando clasificadores basados en ANN y RF.	31
3.4.	Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando registros completos y utilizando clasificadores basados en ANN.	32
3.5.	Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando registros completos y utilizando clasificadores basados en RF.	33
3.6.	Tabla resumen de la detección automática de fases A, sobre los segmentos del EEG en estado de sueño NREM, para los conjuntos de entrenamiento, validación y prueba, aplicando clasificadores basados ANN y RF.	33
3.7.	Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN.	34
3.8.	Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF.	35

3.9.	Resultados de cada registro del conjunto de prueba para la identificación del tipo de fase A, considerando registros de sueño completos.	36
3.10.	Resultados de cada registro del conjunto de prueba para la identificación del tipo de fase A, considerando sólo los segmentos de registro de sueño en estado NREM.	37
3.11.	Cantidad de fases A en cada registro del conjunto de prueba marcadas por un experto y cantidad de estas fases que no están contenidas en CAP.	38
3.12.	Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en ANN.	39
3.13.	Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en RF.	40
3.14.	Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN.	41
3.15.	Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF.	42
4.1.	Resultados obtenidos por diferentes sistemas de detección automáticos de fases A aplicados a la totalidad de registros de sueño.	46
4.2.	Resultados obtenidos por diferentes sistemas de detección automáticos de fases A aplicados a porciones de registros en estado de sueño NREM del EEG. . . .	48
4.3.	Resultados de la identificación del tipo de fase A del sistema propuesto. Se muestran también los resultados de Machado et. al. [11]. Ambos resultados corresponden a registros de sueño completos.	50
4.4.	Resultados de la identificación del tipo de fase A del sistema propuesto. Se muestran también los resultados de Hartmann et. al. [6]. Ambos resultados corresponden a segmentos de registros de sueño en estado NREM.	51
A.1.	Definición de los conjuntos de entrenamiento, validación y prueba. Cada registro tiene un número asociado.	60
A.2.	Cantidad y tipo de fases A en los registros del conjunto de entrenamiento marcadas por experto.	61
A.3.	Cantidad y tipo de fases A en los registros del conjunto de validación marcadas por experto.	61
A.4.	Cantidad de fases A en los registros del conjunto de entrenamiento marcadas por un experto y cantidad de estas fases que no están contenidas en CAP. . . .	62
A.5.	Cantidad de fases A en los registros del conjunto de validación marcadas por un experto y cantidad de estas fases que no están contenidas en CAP.	62
B.1.	Resultados del conjunto de prueba para la detección de fases A, considerando la totalidad del registro de sueño y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	63
B.2.	Resultados del conjunto de prueba para la detección de fases A, considerando la totalidad del registro de sueño y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	64

B.3.	Resultados del conjunto de prueba para la detección de fases A, considerando segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	65
B.4.	Resultados del conjunto de prueba para la detección de fases A, considerando segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	66
B.5.	Resultados totales del conjunto de prueba para la identificación del tipo de fase A, considerando registros de sueño completos.	66
B.6.	Resultados totales del conjunto de prueba para la identificación del tipo de fase A, considerando segmentos de registros de sueño en estado NREM.	67
B.7.	Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	67
B.8.	Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	68
B.9.	Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño en segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	69
B.10.	Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño en segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 0,8 1,2 1,6 2)	70

Índice de Ilustraciones

1.1.	Ejemplos de fase A1 y A3 marcadas por un experto en un registro de EEG. Las marcas se muestran en el canal F3-C3; una línea roja corresponde a una fase A1, y una línea verde a una fase A3. El tamaño de la línea corresponde a la duración de cada fase A. La figura muestra 5 canales del EEG que se registran en el polisomnograma en esta investigación; F3-C3, F4-C4, C3-O1, C4-O2 y C4-C3. La duración de la ventana que se muestra es de 30 s.	4
1.2.	Ejemplos de fase A2 y A3 marcadas por un experto en un registro de EEG. Las marcas horizontales en el canal F3-C3 corresponden a una fase A2 si es una línea azul, y una fase A3 si es una línea verde. El tamaño de la línea corresponde a la duración de cada fase A. La figura muestra 5 canales del EEG que se registran en los polisomnogramas de esta investigación; F3-C3, F4-C4, C3-O1, C4-O2 y C4-C3. La duración de la ventana que se muestra es de 30 s.	5
2.1.	Mapa de Sammon de la partición de los registros polisomnográficos en los conjuntos de entrenamiento, validación y prueba. Cada punto simboliza un registro y el color del punto indica el conjunto al que pertenece cada registro.	13
2.2.	Ejemplo de la estructura de un perceptrón planteado por Rosenblatt en 1958 [22]	14
2.3.	Ejemplo de una red neuronal multi capa, con una entrada X de dimensión N, una capa oculta con M neuronas y una capa de salida \hat{Y} que tiene K elementos	15
2.4.	Ilustración del proceso de bagging. La repartición de datos en los subconjuntos se realiza de forma aleatoria. Fuente: Orellana A., 2018 [19]	16
2.5.	Diagrama de bloques del sistema de detección automática de CAP propuesto. La entrada al sistema es el registro polisomnográfico. El módulo 1 identifica las zonas NREM que son las zonas compatibles con presencia de CAP. El módulo 2 detecta las fases A. Estas fases A se entregan al módulo 3, que las clasifica en tipos de fase A. Finalmente, el módulo 4 identifica las zonas CAP, es decir, pesquisa conjuntos de fases A, aplica reglas para establecer la presencia de CAP, y produce un reporte de fases A y CAP, que constituye la salida del sistema. . .	17

2.6.	Diagrama de bloques del módulo 2. La entrada al módulo 2 son las zonas del EEG que el módulo 1 identificó como NREM. El módulo 2 busca determinar si cada ventana de 1,28 s del EEG debe ser catalogada como posible fase A o B de CAP. Primero se aplica la FFT sobre ventanas de Hamming de 1,28 s, con traslape de 0,64 s, a los canales del EEG. Posteriormente se aplica el método de Welch con el fin de obtener un espectro de frecuencia de contexto para la ventana de 1,28 s. A partir del espectro de frecuencia de la FFT y del espectro de frecuencia del método de Welch se obtienen cocientes de potencias en bandas de frecuencia. Estos cocientes constituyen las características que se utilizan como entradas a un clasificador (ANN o RF) que permite preclasificar cada ventana de 1,28 s en A1, A3 o B, para cada canal del EEG. Además, otro clasificador utiliza como entradas las características de todos los canales. De esta forma se construyen 6 clasificadores; 5 de cada canal EEG y uno que abarca todos los canales. Finalmente, se realiza una votación entre clasificadores, votación que define si la ventana de 1,28 s debe ser catalogada como A o B.	21
4.1.	Ejemplo de fase A bien consolidado, donde existe un cambio en frecuencia y amplitud que es notorio respecto de la actividad EEG de fondo. La figura muestra las 5 derivaciones del EEG del registro. La línea roja marcada en el canal fronto central F3-C3 es la marca del experto de la fase A, en base a la observación de todos los canales. La línea negra punteada es la marca de la detección del sistema automático.	44
4.2.	Ejemplo de fases A en que existe un bajo cambio en amplitud y frecuencia de la señal respecto a la actividad de fondo del EEG. La figura muestra las 5 derivaciones del EEG del registro. Las fases A marcadas por un experto aparecen como una línea roja continua en el canal fronto central F3-C3. Las líneas negras punteadas son las marcas de las detecciones del sistema automático.	45
4.3.	Curvas ROC del sistema de detección de fases A propuesto, aplicado sobre registros completos de sueño nocturno. Las curvas se obtuvieron utilizando distintos valores del parámetro α_5 (es el valor asociado a cada punto) y aplicando clasificadores basados en ANN y RF (dos curvas). Además se compara con los resultados de otros métodos publicados en la literatura.	47
4.4.	Curvas ROC del sistema de detección de fases A propuesto aplicado sólo sobre segmentos del EEG en estado de sueño NREM. Las curvas fueron obtenidas utilizando distintos valores del parámetro α_5 (el valor asociado a cada punto), para clasificadores basados en ANN y RF. Además se comparan con los resultados de otros métodos publicados en la literatura.	49
4.5.	Curvas ROC del sistema de detección de CAP propuesto aplicado sobre registros completos de sueño nocturno. Las curvas se obtuvieron utilizando distintos valores del parámetro α_5 (valor asociado a cada punto) y aplicando clasificadores basados en ANN y RF (dos curvas).	52
4.6.	Curvas ROC del sistema de detección de CAP propuesto aplicado sobre segmentos del EEG en estado de sueño NREM. Las curvas se obtuvieron utilizando distintos valores del parámetro α_5 (valor asociado a cada punto) y aplicando clasificadores basados en ANN y RF (dos curvas).	53

Capítulo 1

Introducción

1.1. Características del Sueño

Dormir es una condición biológica que se observa en todos los animales. En los humanos, en condiciones normales, el dormir representa aproximadamente un tercio de cada jornada. El sueño es un estado en que aparentemente la persona está inactiva. Sin embargo, existe tanto actividad cerebral como corporal.

Los ciclos de sueño se regulan principalmente por dos procesos: el circadiano y el homeostático [27]. El ritmo circadiano comprende eventos que ocurren en un sistema biológico con una periodicidad aproximada de 24 horas. Muy diversas variables de nuestro organismo presentan modulación circadiana, siendo el del ciclo sueño-vigilia (CSV) uno de los ritmos circadianos más evidentes. Particularmente relevante es el rol que el conjunto de la fisiología circadiana juega en la integración temporal del CSV con el ciclo luz-oscuridad (día-noche), en que la necesidad de dormir se ve incrementada o reducida a través de las 24 horas [20].

El proceso homeostático comprende un conjunto de mecanismos de autorregulación, los cuales buscan preservar la composición y propiedades del medio interno de un organismo. Los mecanismos homeostáticos que controlan el equilibrio interno de un organismo, también participan en la regulación de los tiempos del CSV y la necesidad de dormir. En efecto, el proceso homeostático favorece que a mayor cantidad de horas despierto, mayor será la necesidad de dormir, y a más horas durmiendo, la necesidad de dormir disminuirá [20].

Los procesos homeostático y circadiano actúan de forma independiente entre sí, pero su interacción regula la coordinación, duración y calidad del CSV [3].

El CSV representa una sucesión ordenada de estados comportamentales. El concepto de estado comportamental enfatiza que el conjunto de la fisiología -y particularmente del funcionamiento del sistema nervioso central observado desde la perspectiva de múltiples variables- tiende a permanecer en un número discreto de configuraciones posibles. Estas configuraciones o estados comportamentales no son dos, sueño y vigilia, sino más bien tres; en efecto, al interior del dormir alternan dos estados, el sueño NREM y el sueño REM, tan diferentes entre sí como lo es cualquiera de ellos con el estado de vigilia. Estas diferencias se pueden evidenciar en el electroencefalograma (EEG), electrooculograma (EOG) y electromiograma (EMG). También existen otras señales que pueden ser de interés para analizar el sueño, como los movimientos corporales (MC), electrocardiograma (ECG), esfuerzo respiratorio, entre otras. Estas señales fisiológicas se adquieren a través de un polisomnograma, es decir, el registro simultáneo de todas ellas durante un período de sueño nocturno.

El sueño NREM, se caracteriza por la aparición de ondas de gran amplitud en el EEG, cuya frecuencia va disminuyendo a medida que dicho estado de sueño va profundizándose. El tono muscular se encuentra disminuido respecto a vigilia y no ocurren movimientos oculares; además, la frecuencia respiratoria y cardiaca son más lentas y regulares [3].

A fines de la década del 60 del siglo pasado, Rechtschaffen y Kales, publicaron un manual para la clasificación del sueño, el cual divide el sueño NREM (sueño quieto, SQ) en 4 etapas (SQ 1,2,3 y 4), de más superficial a más profundo; estas etapas se caracterizan por patrones característicos [20].

El año 2007 la Academia Estadounidense de Medicina del Sueño (AASM, por sus siglas en inglés) propuso un nuevo manual para la clasificación del sueño. Uno de los cambios fue la fusión de las etapas SQ3 y SQ4 en una sola etapa, denominada Sueño Profundo o Sueño de Ondas Lentas (SWS, por sus siglas en inglés, *slow wave sleep*). En consecuencia, el estado de sueño NREM consta de 3 Etapas: N1, N2 y N3 (por sus siglas en inglés, *no rapid eye movements*) [8]

Durante sueño REM la actividad del EEG se caracteriza por tener menor amplitud y mayor frecuencia, asociada a ausencia de tono muscular (atonía), presencia de movimientos oculares rápidos en el EOG, y las frecuencias cardiaca y respiratoria son más rápidas e irregulares [20].

Existen diversas hipótesis sobre las funciones del sueño, pero no existe una teoría clara y unificadora. El sueño tiene una función restauradora, tanto corporal como cerebral, pero no sería su única función. Una de las hipótesis más apoyadas sostiene que el sueño estimula el mantenimiento y mejora las estructuras sinápticas, las cuales contribuyen con los procesos de memoria y plasticidad cerebral [28].

1.2. Patrones Alternantes Cílicos

Los patrones alternantes cílicos (CAP, por sus siglas en inglés) son el marcador EEG de sueño inestable. Además de la duración, profundidad y continuidad del sueño, las propiedades restauradoras del mismo dependen de la capacidad del cerebro para mantener períodos de sueño estables. Esta propiedad fisiológica básica no se limita solo a los patrones del EEG, sino que repercute en la actividad autónoma en curso y las funciones conductuales, que se arrastran mutuamente en una oscilación sincronizada. Los CAP se pueden identificar tanto en el sueño de adultos como de niños y, por lo tanto, representa una herramienta sensible para la investigación tanto de la fisiología como de los trastornos del sueño a través de la vida. Propiedades fisiológicas básicas, como la dimensión de la inestabilidad del sueño, han proporcionando nuevos conocimientos sobre la fisiopatología y el tratamiento de los trastornos del sueño.

En 2002, Terzano et. al. [26] publicaron el primer manual para la detección e identificación de Patrones Alternantes Cílicos (CAP, por sus siglas en inglés). En él se definen los CAP como una actividad periódica en el EEG durante el sueño NREM. También se menciona que las personas con patologías del sueño pueden tener CAP en sueño REM.

Los CAP se componen de dos elementos que se denominan fases A y B. Cada fase puede tener una duración de 2 a 60 segundos. Las fases A corresponden a un aumento de amplitud y cambio de frecuencia respecto de la actividad de fondo del EEG. La fase B es la actividad de fondo del EEG, en el entorno de las fases A.

Como regla general, para que una fase A sea considerada parte de un CAP, debe preceder

y/o seguir a otra fase A, a una distancia temporal de 2 a 60 segundos. La última fase A de una serie como la descrita señala el fin de un CAP. Como convención, la fase A que termina un CAP no debe ser considerada como parte del CAP en evaluación, pero sí debe ser considerada la fase B que antecede a la última fase A. En caso de haber una fase A separada por más de 60 segundos respecto a una fase A previa o posterior, no se considera parte de un CAP.

Tipos de fases A

De acuerdo a Terzano et al. [26] las fases A se definen en 3 tipos: A1, A2 y A3. Se pueden describir de la siguiente forma:

Fase A1: Se caracteriza por ráfagas y complejos-K¹ de ondas deltas (0,5 Hz - 4 Hz)

Fase A2: Actividad del EEG compuesta por ondas lentas y rápidas; mezcla entre una fase A1 y A3.

Fase A3: Se caracteriza por estar compuesta principalmente por ondas en la banda alfa (8 Hz - 12 Hz) y en la banda beta (12 Hz - 30 Hz).

Las figuras 1.1 y 1.2 muestran ejemplos de los tipos de fases A

Otra característica de las fases A es que deben aparecer simultáneamente en gran parte de los canales del EEG que se están evaluando. En los canales frontales suelen verse de forma más clara.

Los especialistas asocian los CAP a micro despertares, por lo que servirían para evaluar la inestabilidad del sueño y/o perturbación del dormir [26]. Halász et al. [5] mencionan que los CAP son útiles para evaluar la calidad del sueño, para ello evalúan la proporción tiempo con CAP en el tiempo total de NREM, llamado tasa CAP (CAP-rate), y la distribución de CAP a través de las etapas del sueño. Estos indicadores pueden utilizarse para mejorar la caracterización de patologías del sueño, tales como epilepsia nocturna del lóbulo frontal, apnea del sueño o insomnio.

Para identificar los CAP los especialistas identifican los episodios de sueño NREM en el registro polisomnográfico. En dichos episodios identifican las fases A, y observando la relación entre fases A, los CAP. Puesto que este análisis se realiza de manera visual, requiere bastante tiempo incluso para un experto. El proceso tiene componentes relevantes de criterios subjetivos de evaluación del especialista, lo que se ve reflejado en que el porcentaje de acuerdo entre expertos de distintos centros es de un 69 % a 77 % [21]. Es importante destacar que este estudio es de clasificación de CAP utilizando un solo canal del EEG.

1.3. Objetivos

1.3.1. Objetivos Generales

Desarrollar un sistema de detección y clasificación automática de Patrones Alternantes Cílicos (CAP) en registros polisomnográficos nocturnos de niños sanos, sin la necesidad del

¹ Los complejos K son patrones que aparecen en el EEG y se dan principalmente en SQ2. Se caracterizan por ser ondas de gran amplitud y baja frecuencia.

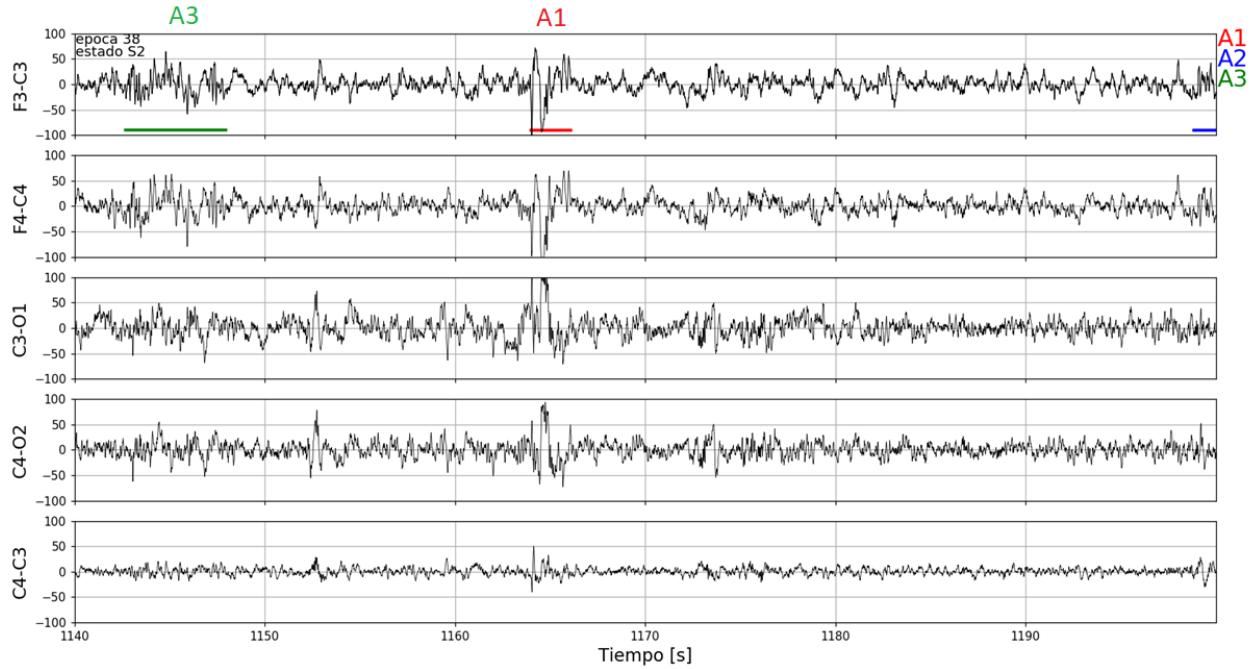


Figura 1.1: Ejemplos de fase A1 y A3 marcadas por un experto en un registro de EEG. Las marcas se muestran en el canal F3-C3; una línea roja corresponde a una fase A1, y una línea verde a una fase A3. El tamaño de la línea corresponde a la duración de cada fase A. La figura muestra 5 canales del EEG que se registran en el polisomnograma en esta investigación; F3-C3, F4-C4, C3-O1, C4-O2 y C4-C3. La duración de la ventana que se muestra es de 30 s.

conocimiento *a priori* de los estados y etapas del sueño (hipnograma).

1.3.2. Objetivos Específicos

1. Desarrollar un sistema de detección de CAP, observando el procedimiento que realiza el especialista durante la inspección visual del polisomnograma con ese fin, utilizando características frecuenciales, temporales, técnicas de procesamiento de señales e inteligencia computacional.
2. Determinar qué características del EEG permiten tener una correcta detección de fases A.
3. Evaluar el sistema de detección de CAP y el detector de fases A utilizando solamente segmentos del EEG en estado de sueño NREM.
4. Comparar el desempeño del sistema desarrollado con la marca de los expertos, y también con sistemas de detección de fases A y de identificación del tipo de fase A descritos en la literatura.

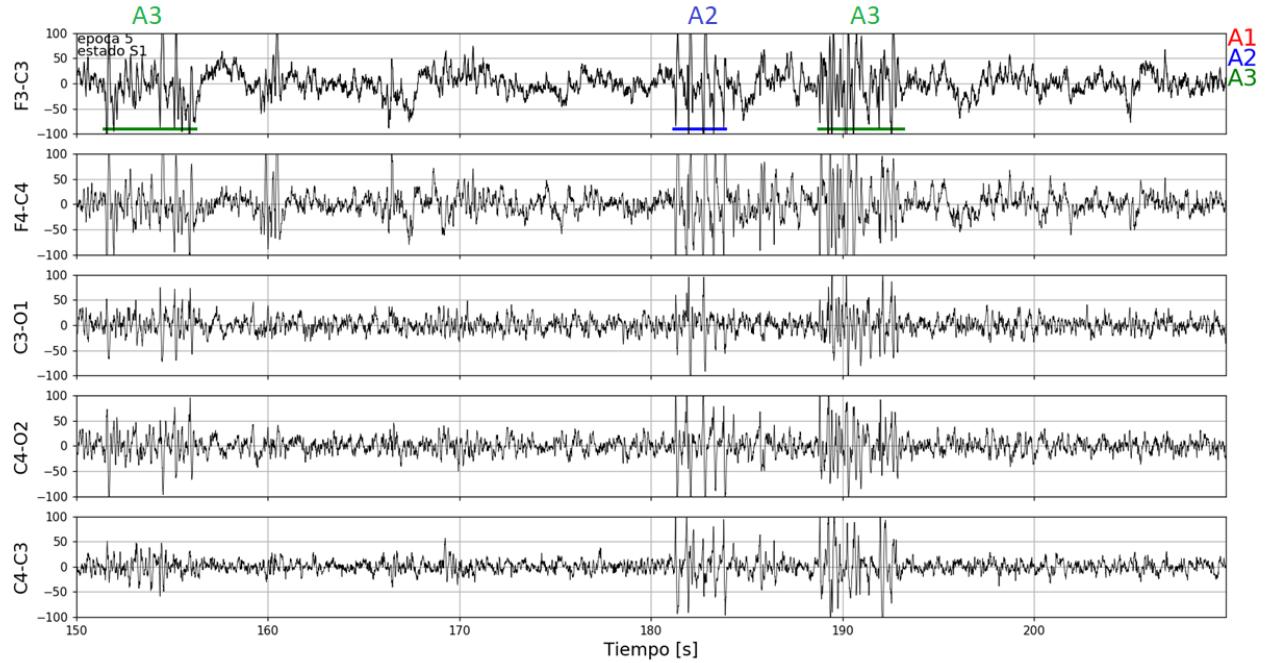


Figura 1.2: Ejemplos de fase A2 y A3 marcadas por un experto en un registro de EEG. Las marcas horizontales en el canal F3-C3 corresponden a una fase A2 si es una línea azul, y una fase A3 si es una línea verde. El tamaño de la línea corresponde a la duración de cada fase A. La figura muestra 5 canales del EEG que se registran en los polisomnogramas de esta investigación; F3-C3, F4-C4, C3-O1, C4-O2 y C4-C3. La duración de la ventana que se muestra es de 30 s.

1.4. Estado del Arte

En la investigación bibliográfica no se encontraron trabajos de detectores automáticos de CAP, sin embargo, fue posible encontrar trabajos relacionados a la detección e identificación de fases A, de acuerdo al siguiente resumen:

1. Detección de fases A: [6], [11], [12], [13], [14], [15], [18] y [24].
2. Identificación del tipo de fases A: [6], [11] y [16].

Para detectar los CAP es esencial tener una buena detección de fases A; es por esto que los trabajos de detección de CAP suelen estar orientados en la detección automática de fases A.

1.4.1. Sistemas de detección automática de fases A

Estos trabajos pueden ser divididos conforme consideran al hipnograma como conocido o como desconocido. Esta división se hace para permitir una comparación más precisa entre distintos trabajos. Si el hipnograma es conocido, las zonas de búsqueda de fases A quedan acotadas a las zonas NREM definidas por hipnograma, y no se buscan fases A en zonas que el sistema incluyó erróneamente y que son de Vigilia o REM.

Los sistemas de detección automática de fases A encontrados en la literatura utilizan las mismas métricas de evaluación: exactitud, sensibilidad y especificidad (ver sección 2.6.1). Estas métricas consisten en comparar segundo a segundo la marca del experto y la marca del sistema que se está proponiendo; el criterio de comparar segundo a segundo es compartido por todos los trabajos revisados. Esto difiere de la clasificación de los expertos, en que una fase A completa (de varios segundos de duración) es de un tipo solamente, no tiene tramos diferentes.

Uno de los grupos de investigación en la detección automática de fases A es el de Mariani et. al., del Politécnico di Milano; Italia, que ha realizado diversas publicaciones [12], [13], [14], [15].

En 2010, Mariani et al. [12] publicaron un detector automático de fases A basado principalmente en características frecuenciales: potencias por bandas de frecuencia y varianza temporal en la señal del EEG, y un clasificador basado en redes neuronales artificiales (ANN, *Artificial Neural Network*), obteniendo una sensibilidad de 75,65 %, especificidad de 83,05 % y una exactitud de 81,55 %. Estos resultados se obtuvieron con una base de datos de segmentos de registros en estado de sueño NREM de 4 individuos sanos que no fue dividida en conjuntos de entrenamiento, validación y prueba. Utilizando las mismas características frecuenciales y la misma base de datos, el año 2011, Mariani et al. [13] introdujeron un clasificador basado en Máquinas de Soporte Vectoriales (SVM, *Support Vector Machines*), obteniendo una sensibilidad de 73,82 %, una especificidad de 85,93 % y una exactitud del 84,05 %. Es decir, mejoraron en especificidad y exactitud, pero disminuyeron en sensibilidad, respecto al trabajo anterior. Dentro de los aportes entregados por estos trabajos destaca la importancia de las características frecuenciales, las cuales son utilizadas en investigaciones posteriores.

En una publicación del año 2012 Mariani et. al. aplicaron distintos clasificadores: Discriminante Lineal, SVM, ANN y AdaBoost [4], con las mismas características de los trabajos anteriores, sobre una base de datos de segmentos de registros en estado de sueño NREM de 8 individuos. Los autores aplicaron validación cruzada para la prueba. Los resultados obtenidos se muestran en la tabla 1.1 [14]. Los resultados que obtuvieron son bastante diferentes entre sí y en algunas métricas inferiores a los trabajos anteriormente presentados, sin embargo, utilizan distintas bases de datos, por lo que no se puede afirmar que tienen peores resultados.

Tabla 1.1: Resultados de detección automática de fases A publicados por Mariani et. al. en 2012, utilizando distintos métodos de clasificación sobre segmentos de registros de sueño en estado NREM [14].

Método	Sensibilidad (%)	Especificidad (%)	Exactitud (%)
Discriminante Lineal	72,50	86,60	84,90
SVM	70,10	84,00	81,90
AdaBoost	68,50	79,30	79,40
ANN	72,90	82,30	81,50

El grupo de Mariani publicó otro trabajo el año 2013 [15], en el que crearon una etapa de identificación de REM, NREM y Vigilia, previa a la detección de fases A. El objetivo de esta etapa es prescindir del conocimiento a priori de las etapas de sueño, para ello utilizaron características frecuenciales de uno de los canales del EEG, no especifican qué canal y un clasificador basado en ANN. Para la detección de fases A utilizaron características frecuenciales

probadas en trabajos anteriores ([13] y [14]) y un sistema de clasificación basado en Discriminante Lineal, obteniendo una sensibilidad de 67,03 %, una especificidad de 89,63 % y una exactitud de 86,09 %. Para este trabajo utilizaron una base de datos de 16 individuos y no se menciona si existe una división de la base de datos en conjuntos de entrenamiento, validación y prueba. Este trabajo tiene un objetivo muy similar a los que se buscan en esta memoria, que es detectar CAP sin la necesidad de conocer las estados de sueño. Los resultados que obtienen se caracterizan por una muy baja sensibilidad, respecto a los trabajos previamente presentados, y una especificidad y exactitud similar a los trabajos ya presentados.

El año 2015, Niknazar et al. [18] publicaron un trabajo basado principalmente en características temporales obtenidas a partir del método "comportamiento estadístico de extremos locales" (SBLE, *statistical behavior of local extrema*). Este método consiste en utilizar las amplitudes máximas o mínimas locales de la señal y con éstas obtener características de comportamiento como aumento, disminución o amplitud constante de la señal. A partir del mismo método crearon un índice de similitud con el que realizaron la clasificación de fases A y B. Obtuvieron una sensibilidad de 75,83 %, una especificidad de 81,30 % y una exactitud de 80,51 %. Los resultados son similares a los de los trabajos ya presentados. El método SBLE fue creado por Niknazar et al. y dentro de los trabajos revisados fue el único que utilizó éste método. Utilizaron una base de datos de 6 sujetos sanos. No mencionaron si la base de datos se dividió en conjuntos de entrenamiento, validación y prueba, ni tampoco si se recorrieron los registros enteros o sólo partes de ellos.

Mostafa et al. [24] publicaron el año 2018 un trabajo basado en la utilización de un canal EEG, al que se le extraen características cada 2 s, no mencionan el uso de traslape, mediante un *Autoencoder*², el cual también detecta las fases A. Obtuvieron una sensibilidad del 55,04 %, 69,01 % de especificidad y un 67,00 % de exactitud, no mencionan si estos resultados fueron utilizando ventanas de un segundo. Utilizaron 14 registros de sueño completos, de los cuales 4 correspondían a individuos con trastornos de la respiración al dormir, 1 con bruxismo y 9 de individuos sanos. Para evaluar el sistema desarrollado utilizaron validación cruzada de registros completos de la base de datos. Los resultados que obtuvo Mostafa et al. se caracterizan por ser muy bajos, respecto a los otros trabajos, sin embargo, se debe considerar que utilizan una base de datos en que existen sujetos con y sin desórdenes del sueño, lo que incrementa la dificultad de la detección de CAP.

El año 2018, Machado et al. [11] desarrollaron un sistema de detección de fases A que incluía distintos métodos de extracción de características: transformada de Fourier, descomposición empírica modal (EMD, por sus siglas en inglés), entropía de Shannon, entre otros. Obtuvieron características derivadas, por ejemplo, de la transformada de Fourier trabajaron con la potencia por bandas de frecuencia. Estas características se utilizaron simultáneamente en diferentes tipos de clasificadores de fases A o B: SVM, discriminante lineal y K vecinos más cercanos (KNN, *k-nearest neighbors*). Los resultados obtenidos se presentan en la tabla 1.2. En este trabajo se utilizaron 30 registros de personas con epilepsia nocturna del lóbulo frontal (NFLE, por sus siglas en inglés). Para validar los resultados obtenidos se utilizó validación cruzada, y se utilizaron los registros completos. Este trabajo incluye gran parte de las características utilizadas por Mariani et al. en los trabajos ya presentados e incorpora características que no habían sido utilizadas en la detección de CAP. Los resultados obtenidos son bajos respectos a los trabajos previamente presentados, sin embargo, se debe considerar que la base de datos que utilizan es de sujetos con trastornos del sueño y además utilizan la

² Tipo de red neuronal artificial que permite extraer características de forma no-supervisada.

totalidad de los registros.

Tabla 1.2: Resultados obtenidos por Machado et. al. [11] en la detección automática de fases A utilizando distintos métodos de clasificación.
 Nota: Los porcentajes de los resultados han sido presentados tal como los presentó Machado et al.

Método	Sensibilidad (%)	Especificidad (%)	Exactitud (%)
Discriminante Lineal	79	74	73
KNN	82	69	75
SVM	79	76	76

El año 2019, Hartmann y Baumert [6] desarrollaron un trabajo que incluía dos bases de datos: una base con 16 registros de personas sanas (la misma base de datos que utilizó Mariani et al en [15], descrito más arriba) y otra con 30 registros de personas con epilepsia nocturna del lóbulo frontal (la misma base que utilizó Machado et. al [11], mencionada anteriormente). El sistema propuesto utilizó características frecuenciales, entropía de Shannon, operador de energía de Teager, entre otras. Obtuvieron resultados con dos modelos de clasificación: uno basado en redes neuronales prealimentadas (*Feed-Forward*) y otro basado en redes neuronales recurrentes, en particular LSTM (*Long Short-Term Memory*). Los resultados se presentan en la tabla 1.3. En este trabajo se aplicó validación cruzada en los resultados, y sólo se clasificaron segmentos de registros en estado NREM. Los resultados que

Tabla 1.3: Resultados recientes obtenidos por Hartmann y Baumert [6] en la detección automática de fases A utilizando distintos métodos, en segmentos de registros EEG en estado de sueño NREM.

Método	Sensibilidad (%)	Especificidad (%)	Exactitud (%)
En 16 registros de personas sanas			
Red Neuronal Feed Forward	73,04	84,61	82,66
LSTM	76,10	88,49	86,43
En 30 registros de personas con NFL			
Red Neuronal Feed Forward	73,42	82,41	80,40
LSTM	78,48	86,50	85,09

El método propuesto por Hartmann y Baumert es muy parecido al de Machado et al., la gran diferencia está en los sistemas de clasificación, la base de datos y los segmentos de registros utilizados. Al ver los resultados de Hartmann y Baumert se ve que son los que tienen la mayor exactitud de los trabajos vistos hasta aquí, a pesar de que no tienen una alta sensibilidad. Es uno de los trabajos que más se acerca al objetivo de esta memoria, respecto a la detección de CAP, no obstante, solo tienen resultados en segmentos de registros EEG en estado de sueño NREM.

1.4.2. Identificación del tipo de fase A

La identificación automática del tipo de fase A ha sido abordada en los trabajos de Machado et al. [11] y Hartmann y Baumert [6], ya mencionados en la sección anterior. Estos trabajos tienen alguna relación entre sí, por ejemplo, la base de datos utilizada por Machado et. al. corresponde a una de las dos bases de datos que utilizaron también Hartmann y Baumert. Además, utilizaron las mismas métricas de desempeño en la identificación del tipo de fase A. Ambos trabajos comparten que su clasificador inicial binario, que particiona entre fases A y B, fue modificado en un clasificador multiclas para identificar A1, A2, A3 y B. Los resultados de Machado et. al.[11] se presentan en la tabla 1.4 y los resultados de Hartmann y Baumert [6] en la tabla 1.5.

Tabla 1.4: Resultados obtenidos por Machado et. al. [11], para los distintos clasificadores de tipo de fases A evaluados sobre registros de sueño completos. Se presenta la sensibilidad para cada fase, además de la exactitud total.

Método	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud total (%)
Discriminante Lineal	73	66	37	18	68
KNN	71	59	31	16	70
SVM	76	58	44	24	71

Tabla 1.5: Resultados obtenidos por Hartmann y Baumert [6] en la clasificación de tipo de fases A en segmentos de registros en estado de sueño NREM. Para ambas bases de datos evaluadas se presenta la sensibilidad para cada fase, además de la exactitud total.

Método	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud total (%)
En 16 registros de personas sanas					
LSTM	85,51	63,14	42,31	70,62	81,89
En 30 registros de personas con NFLE					
LSTM	82,30	59,54	45,40	74,25	78,27

Los resultados de Hartmann y Baumert con la segunda base de datos [6] y los de Machado et al. [11] podrían ser bastante comparables entre sí, ya que la base de datos de personas con NFLE es la misma. Sin embargo, Hartmann y Baumert solo consideraron las etapas NREM, en cambio Machado et al. consideraron los registros completos. Nótese también que difieren en el número de cifras significativas en los resultados presentados, a pesar de qué la base de datos de Machado et al. es mayor a la de Hartmann y Baumert, por considerar registros enteros. Hartmann y Baumert reportan la duración total de las fases A de las bases de datos: la base de datos de personas con NFLE contiene 50.791 s de A1, 27.754 s de A2 y 51.397 s de A3 y la base de datos de personas sanas contiene 24.027 s de A1, 10.633 s de A2 y 16.062 s de A3.

Cabe destacar que el trabajo de Machado et al. [11] es el más cercano al objetivo de este trabajo de memoria, ya que crearon un sistema de detección automática de fases A e identificación del tipo de fase A, utilizando la totalidad del registro. Sin embargo, tanto

Machado et. al. como Hartmann y Baumert identifican el tipo de fase A segundo a segundo, en cambio la norma las cataloga por episodio. Es decir, en estos trabajos, una fase A de 5 s puede estar marcada como 3 s A1, 1 s A2 y 1 s A3, estableciendo fases A como una mezcla de tipos de fase A. Segmentar los tipos de fases A por segundo no es lo que buscan los expertos, ya que dentro de lo que buscan, en la identificación de fase A, es saber la cantidad de tipos de fases A dentro de un registro y al atomizar las fases A no se podría.

Capítulo 2

Metodología

2.1. Sujetos y registros

Para este trabajo se utilizaron 48 registros polisomnográficos de niños sanos de entre 10 y 15 años de edad, de ambos sexos, obtenidos en el Laboratorio de Sueño y Neurobiología Funcional del Instituto de Nutrición y Tecnología de los Alimentos (INTA) de la Universidad de Chile. Estos 48 registros, de distintos niños, fueron seleccionados de un universo mayor de polisomnogramas; otros registros se descartaron porque estaban incompletos y/o sin marcas de fases A. El protocolo experimental fue aprobado por el Comité de Ética del INTA, Universidad de Chile. Los padres de los niños fueron informados sobre los aspectos metodológicos implicados en la investigación.

2.2. Procedimiento de adquisición

Los registros se adquirieron durante el período de sueño nocturno. Esto se realizó en una habitación especialmente adecuada para ello en el Laboratorio de Sueño y Neurobiología Funcional del INTA. El procedimiento se estandarizó para suprimir potenciales influencias del ambiente, los ritmos circadianos y/o de la ingesta de alimentos en los registros.

Los polisomnogramas se obtuvieron mediante un polígrafo modelo Easy EEG-II de 32 canales (Cadwell, WA, USA, 2000). Se utilizaron 21 canales distribuidos de la siguiente manera: cinco para el EEG, cuyos electrodos se posicionaron según el sistema internacional 10-20 [9], utilizándose las derivaciones F4-C4, C4-O2, F3-C3, C3-O1 y C4-C3; dos para el EOG, cuatro para el EMG, cuyas medidas se realizaron en el mentón, diafragma y en ambas piernas utilizando electrodos de superficie; uno para el ECG (derivación VI); dos para la detección de actividad motora (extremidades superior e inferior) utilizando transductores piezoeléctricos; uno para la medición del flujo de aire nasal; uno para el esfuerzo respiratorio abdominal; uno para la medición del pulso; uno para la temperatura corporal; uno para la oximetría; uno para el registro de la posición del sujeto y uno para el registro de ronquidos. Todas las señales se muestran a una tasa de 200 Hz y grabaron en discos en formato EDF (European Data Format) para el análisis y procesamiento posterior.

2.3. Base de datos

Un grupo de expertos en sueño del Laboratorio de Sueño y Neurobiología Funcional del INTA realizaron la inspección visual de los polisomnogramas adquiridos pesquisando CAP, marcando el inicio y fin de cada fase A, sin marcar los CAP correspondientes, utilizando el software *HypnoLab* [25]. *HypnoLab* es un sistema de visualización y análisis automático de registros polisomnográficos, que incluye diferentes herramientas que permiten marcar y analizar señales polisomnográficas.

Los 48 registros seleccionados para este trabajo fueron divididos en conjuntos de entrenamiento, validación y prueba para la implementación, ajuste y prueba del sistema. Para realizar esta partición se usó un mapa de Sammon¹ [23], con el propósito de que cada conjunto fuese representativo de la diversidad de señales que aparecen.

El mapa de Sammon se construyó considerando las siguientes variables de los registros polisomnográficos:

1. Potencia espectral EEG en la banda delta (0,5-4 Hz), theta (4-7 Hz), alfa (7-10 Hz), sigma(10-15 Hz) y beta (15-30 Hz).
2. Potencia RMS de la señal EMG.
3. Potencia RMS en la señal de movimientos corporales (MC).
4. Potencia RMS en la señal del EOG.

A continuación se detallan estas mediciones:

Las potencias espectrales de cada banda se calcularon aplicando la FFT sobre la derivación F3-C3 del EEG, utilizando una ventana de Hamming móvil de 2,56 s con un traslape de 1,28 s. La potencia espectral de cada banda para cada época² de 30 s de registro, se representó por el promedio de las potencias calculadas para todas las ventanas de la época. Cada época se asoció con un estado del sueño, de acuerdo al hipnograma de cada registro. Se obtuvo el promedio para cada variable para estado de sueño, calculado con los promedios de épocas asociadas. Así por ejemplo, para la potencia de la banda delta del EEG, se obtuvieron 3 valores: las potencias de la banda delta del EEG en los estados REM, NREM y Vigilia.

La potencia RMS de la actividad muscular se obtuvo calculando la potencia RMS (ver ecuación 2.2) de la señal del EMG, utilizando primero una ventana móvil de 5 s con un traslape de 2,5 s. Luego, la potencia RMS de la actividad muscular de cada época de 30 s se obtuvo como el promedio de la potencia RMS de todas las ventanas contenidas en la época de análisis. La potencia de cada época se clasificó según el estado de sueño. Finalmente se obtuvo el promedio de la potencia muscular para cada estado de sueño, es decir, las potencias RMS de la actividad muscular en REM, NREM y Vigilia.

Los valores de potencia RMS para los movimientos corporales y el EOG se obtuvieron con el mismo procedimiento aplicado para la potencia RMS de la señal del EMG.

¹ Un mapa de Sammon es un método no lineal que permite representar datos de alta dimensionalidad en dos dimensiones. Consiste en un proceso iterativo en que se parte con puntos distribuidos al azar en el espacio objetivo, que se van ajustando mediante la minimización de una medida de preservación global de distancias euclidianas entre todos los puntos, lo que se conoce como estrés de Sammon [23].

² De acuerdo con RK [20], las épocas son intervalos fijos en que se dividen los registros de sueño, generalmente de 20 o 30 segundos de duración.

A partir del mapa de Sammon construido con las variables recién descritas se seleccionaron 22 registros para el conjunto de entrenamiento, 6 registros para validación y 20 registros para prueba. El mapa de Sammon obtenido se muestra en la figura 2.1. Para más detalle de la formación de los conjuntos de registros, véase el Anexo A.1.

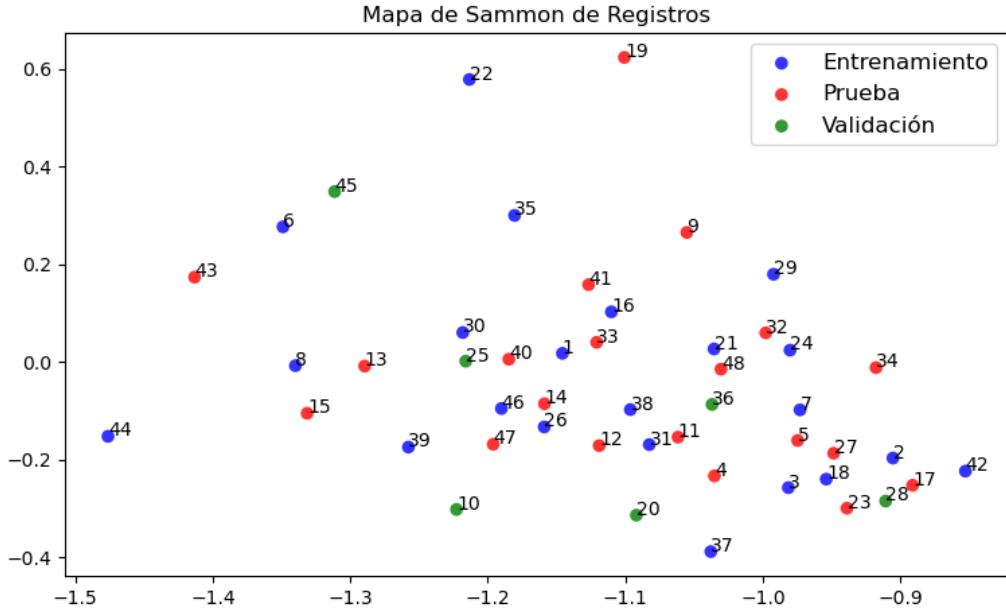


Figura 2.1: Mapa de Sammon de la partición de los registros polisomnográficos en los conjuntos de entrenamiento, validación y prueba. Cada punto simboliza un registro y el color del punto indica el conjunto al que pertenece cada registro.

2.4. Métodos de clasificación

Este trabajo puede describirse como un problema de clasificación, ya que en la detección de fases A se busca clasificar entre fases A y B, y en la identificación del tipo de fase A se busca clasificar entre fases A1, A2 y A3.

2.4.1. Aprendizaje supervisado

La base de datos utilizada incluye las marcas de las fases A de los registros polisomnográficos que se quieren identificar, es decir, es una base de datos etiquetada. Lo más razonable para un problema de clasificación en el cual se tienen las etiquetas es utilizar aprendizaje supervisado. Este aprendizaje hace uso del conocimiento a priori de las clases asociadas a los datos, es decir, aprende a partir de un conjunto de entradas y salidas (clases esperadas). Se busca reducir el error entre la clasificación del experto y la del sistema. Dentro de los modelos más utilizados de clasificación de aprendizaje supervisado están: regresión logística, clasificador Bayesiano ingenuo (*naive Bayes*), máquina de soporte vectorial (SVM), redes neuronales artificiales (ANN) y Random Forest (RF). En particular, para este trabajo se utilizaron ANN

y RF.

Para entrenar los clasificadores se utilizaron dos conjuntos de datos, un conjunto de entrenamiento y otro de validación. El conjunto de entrenamiento se utiliza para fijar sus parámetros, y el conjunto de validación permite evitar que el clasificador se sobreajuste a los datos contenidos en el conjunto de entrenamiento. La razón por la cual se busca evitar un sobreajuste es que el clasificador perdería capacidad de generalización para clasificar nuevos datos, es decir, tendría un desempeño inferior ante nuevos datos.

El tercer conjunto de datos, el conjunto de prueba, permite evaluar el desempeño del clasificador con datos no utilizados en su construcción.

2.4.2. Redes neuronales artificiales

Las redes neuronales artificiales (ANN) son modelos matemáticos inspirados en la biología del cerebro. Las ANN, al igual que las redes neuronales biológicas, son sistemas que se componen por unidades modulares conectadas entre sí. En el caso de las redes neuronales artificiales el perceptrón es la unidad básica. El perceptrón fue propuesto por Rosenblatt en 1958 [22]; representa una abstracción matemática de una neurona biológica. La figura 2.2 presenta un esquema de la estructura del perceptrón.

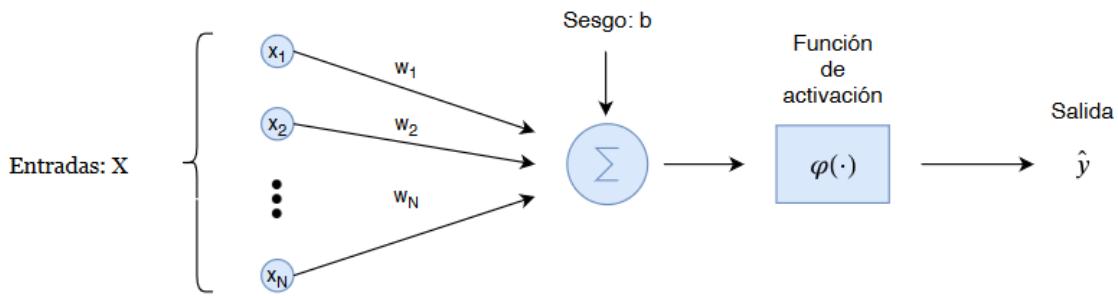


Figura 2.2: Ejemplo de la estructura de un perceptrón planteado por Rosenblatt en 1958 [22]

El perceptrón considera como un estímulo externo, o entrada, un vector $X = [x_1 \ x_2 \ \dots \ x_N]$. Los elementos del vector X se ponderan por pesos sinápticos $W = \{w_i\}_{i \in \{1, \dots, N\}}$, y se suman con una constante b , conocida como sesgo: permite aumentar o disminuir la entrada de la función de activación. Luego a este resultado se le aplica una función no lineal $\varphi(\cdot)$, comúnmente llamada función de activación. Esto puede ser expresado a través de la ecuación 2.1:

$$\hat{y}(X) = \varphi(W \cdot X + b) = \varphi\left(\sum_i^N w_i x_i + b\right) \quad (2.1)$$

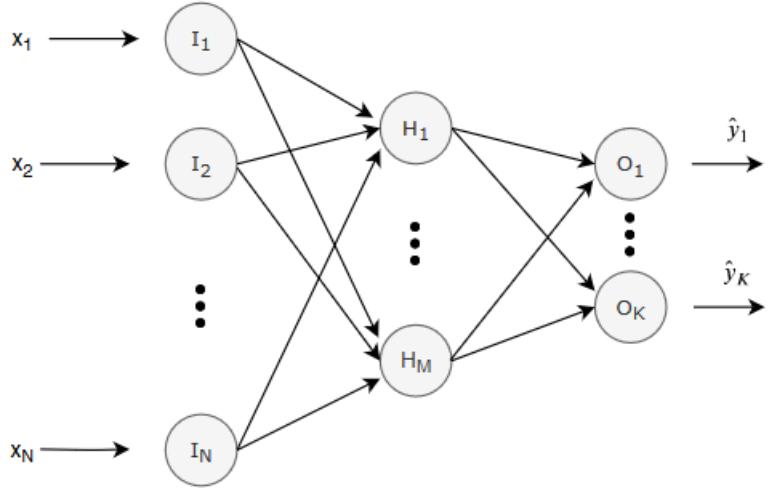


Figura 2.3: Ejemplo de una red neuronal multi capa, con una entrada X de dimensión N , una capa oculta con M neuronas y una capa de salida \hat{Y} que tiene K elementos

Las redes neuronales típicas son estructuras compuestas por un conjunto de perceptrones dispuestos en capas, tal como se muestra en la figura 2.3, donde las neuronas están conectadas a neuronas de capas contiguas. Esta estructura se conoce como perceptrón multi capa (MLP, *Multi Layer Perceptron*), en que se distinguen 3 tipos capas: la capa de entrada, que es la que recibe los datos de entrada $I_{i \in \{1, \dots, N\}}$, la o las capas ocultas $H_{i \in \{1, \dots, M\}}$ (que pueden ser una o más capas) y la capa de salida, la cual entrega la salida de la red $O_{i \in \{1, \dots, K\}}$.

2.4.3. Random Forest

Random Forest (RF), o bosques aleatorios es un método de regresión o clasificación basado en una serie de árboles de decisión. RF utiliza la técnica de *bagging* [2], que consiste en entrenar cada uno de los árboles con distintos subconjuntos de datos, seleccionados aleatoriamente, pertenecientes al conjunto de datos de entrenamiento. Esto se hace con el fin de reducir la varianza en la predicción. La predicción de RF se obtiene combinando con algún método (moda, media u otro método) la salida de todos los árboles (bosque) de decisión.

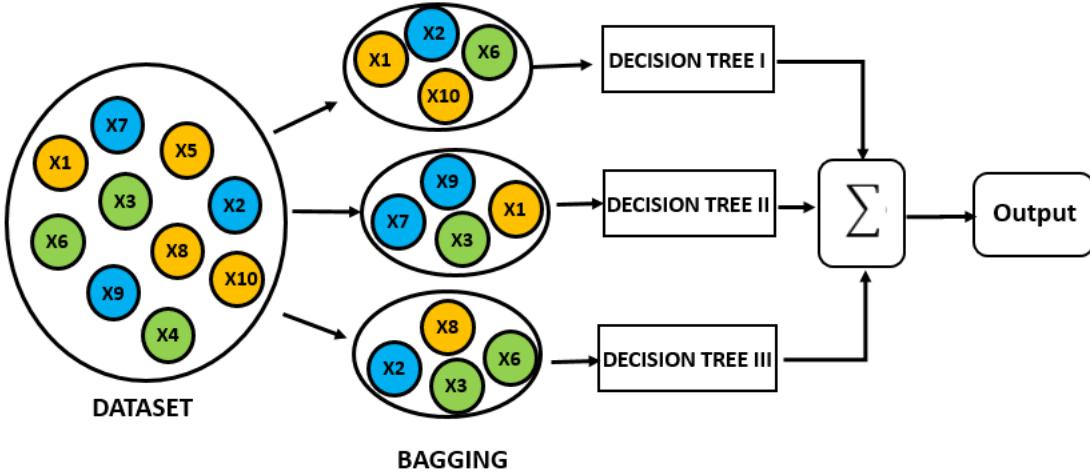


Figura 2.4: Ilustración del proceso de bagging. La repartición de datos en los subconjuntos se realiza de forma aleatoria. Fuente: Orellana A., 2018 [19]

Dentro de los principales parámetros para aplicar RF está la cantidad de árboles que se deben considerar, la profundidad que los árboles pueden alcanzar, el número de ramificaciones, entre otros [2].

2.5. Sistema de detección automática de CAP

El detector automático de CAP que se presenta en este trabajo puede ser descrito como un sistema modular en cascada, como se muestra en la figura 2.5. Inicialmente, en un registro polisomnográfico se identifican zonas compatibles con CAP, que corresponden a aquellas en estado de sueño NREM. Luego, dentro de esas zonas, se buscan fases A. Posteriormente se identifican los tipos de las fases A detectadas. A partir de las fases A detectadas se identifican los CAP, y se entrega un reporte de métricas CAP: tiempo de CAP, cantidad y tipo de fases A, entre otras métricas. En total consta de cuatro módulos.

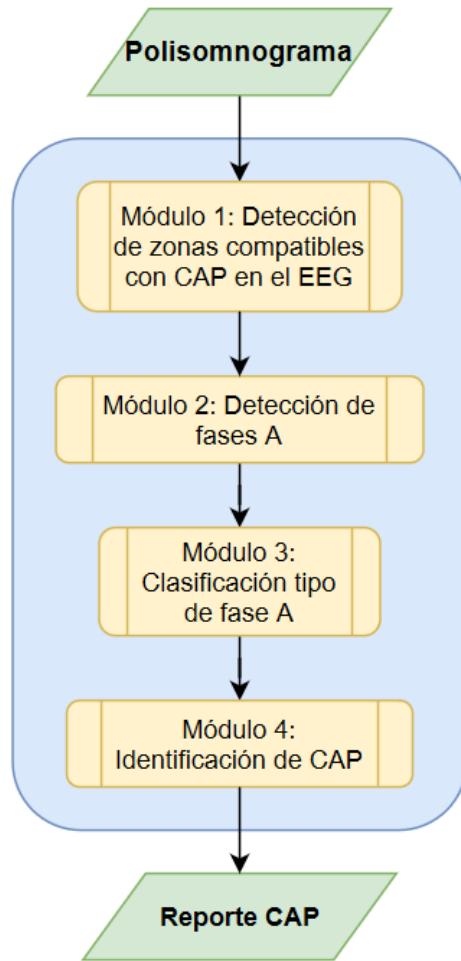


Figura 2.5: Diagrama de bloques del sistema de detección automática de CAP propuesto. La entrada al sistema es el registro polisomnográfico. El módulo 1 identifica las zonas NREM que son las zonas compatibles con presencia de CAP. El módulo 2 detecta las fases A. Estas fases A se entregan al módulo 3, que las clasifica en tipos de fase A. Finalmente, el módulo 4 identifica las zonas CAP, es decir, pesquisa conjuntos de fases A, aplica reglas para establecer la presencia de CAP, y produce un reporte de fases A y CAP, que constituye la salida del sistema.

2.5.1. Módulo 1: Detección de zonas compatibles con CAP en el EEG

Para detectar CAP visualmente, el experto revisa el polisomnograma en busca de zonas compatibles con la presencia de CAP, es decir, las zonas que están en estado de sueño NREM. El módulo 1 sigue esta acción del experto. De esta forma se reduce el espacio de búsqueda de CAP, y consecuentemente disminuyen los tiempos de procesamiento del sistema, ya que los módulos 2 y 3 son computacionalmente costosos. A continuación se describe en detalle el módulo 1.

Para identificar las zonas del EEG en estado NREM también se deben identificar las zonas en estado REM y vigilia. Para esto se toman como referencia las reglas de expertos en clasificación de estados del sueño, presentadas en [3], [7] y [20]. Estas reglas consideran los patrones de las actividades del EEG, EMG, EOG y los canales de movimiento de extremidades para identificar los estados de sueño; REM, NREM y vigilia.

El sistema considera los mismos canales mencionados. Para el EEG, se aplica la FFT sobre el canal F4-C4. Se utiliza una ventana de Hamming móvil de 2,56 s (512 muestras) con un traslape de 1,28 s (256 muestras) entre ventanas. A partir de la FFT se calcula la potencia espectral en las bandas delta (0,5 - 4 Hz), theta (4 - 7 Hz), alfa (7 - 10 Hz), sigma (10 - 15 Hz) y la banda "fisiológica" (0,5 - 60 Hz). La potencia promedio de cada banda y para cada época (ventana temporal de 30 s) se determina como el promedio de las potencias calculadas para todas las ventanas de 2,56 s contenidas en 30 s de registro, obteniéndose cinco potencias promedio.

Con el objetivo de identificar zonas REM, en el canal del EOG se utilizaron ventanas de 2,56 s (512 muestras) con un traslape de 1,28 s (256 muestras) entre ventanas, para calcular la potencia RMS cada 30 s. La potencia RMS para una época (30 s) viene dada por la siguiente expresión:

$$P_{RMS} = \frac{1}{L} \sum_{i=1}^L \sqrt{\frac{1}{N} \sum_{n=1}^N (x_{n,i} - \bar{x}_i)^2} \quad (2.2)$$

El índice n recorre los valores que tiene cada ventana de 2,56 s, es decir, las 512 muestras; $x_{n,i}$ es el valor de una muestra, y \bar{x}_i es el promedio de las muestras de una ventana. N es el tamaño de la ventana, que son 512 muestras. El índice i recorre las ventanas que existen en una época. L es la cantidad de ventanas contenidas en 30 s, que corresponde a 22 ventanas.

Para los canales de movimientos de extremidades también se calcula la potencia RMS, con el fin de detectar las zonas de vigilia. La metodología es muy similar al de la potencia calculada en el EOG. La única diferencia es el tamaño de las ventanas, que en este caso son de 5 s (1000 muestras) con un traslape de 2,5 s (500 muestras).

La decisión de analizar épocas de 30 s, es que son medidas que utilizan los expertos en sus análisis. El tamaño de la ventana de Hamming de 2,56 s se estableció en base a la frecuencia de muestreo de la señal del EEG, ya que el intervalo entre frecuencias al aplicar la FFT viene dado por el cuociente entre la frecuencia de muestreo y el tamaño de la ventana. En este caso, el intervalo es de 0,4 Hz, el que permite una buena resolución en frecuencia para calcular la potencia espectral.

Luego de aplicar las herramientas recién descritas se obtienen ocho vectores del tamaño del número de épocas del registro; cinco de potencias de las distintas bandas del EEG, uno

de la potencia RMS del EOG y dos de la potencia RMS de movimientos de extremidades (superior e inferior). Estos vectores se utilizan para diferenciar el estado NREM de los otros estados, REM y vigilia.

Para descartar sueño REM de los registros polisomnográficos se utilizan tres indicadores: la potencia en la banda sigma normalizada por la banda fisiológica: P_S ; la razón de potencias entre la banda theta y la banda delta: P_{TD} y la potencia RMS del EOG: P_{EOG} . Se realiza un análisis por época (e), donde se clasifica si una zona tiene sueño REM, según si los indicadores están sobre o bajo ciertos umbrales, de acuerdo a las siguientes reglas:

R1) Si $P_{EOG}(e) > \alpha_1 \cdot \overline{P_{EOG}}$ \Rightarrow Salida_{EOG}(e) = 0, si no, Salida_{EOG}(e) = 1

R2) Si $P_{TD}(e) > \alpha_2 \cdot \overline{P_{TD}}$ \Rightarrow Salida_{TD-S}(e) = 0, si no, Salida_{TD-S}(e) = 1

R3) Si $P_S(e) > \alpha_3 \cdot \overline{P_S}$ \Rightarrow Salida_{TD-S}(e) = 0, si no, Salida_{TD-S}(e) = 1

donde $\overline{P_{EOG}}$, $\overline{P_{TD}}$ y $\overline{P_S}$, son escalares que corresponden al promedio de P_{EOG} , P_{TD} y P_S del registro en análisis, respectivamente. Los valores escalares α_1 , α_2 y α_3 se encontraron empíricamente a partir del conjunto de entrenamiento. Los valores 1 en Salida_{EOG} y en Salida_{TD-S} simbolizan que la época en evaluación es catalogada como época libre de REM y 0 como una época que tiene REM.

Estas reglas se basan en que las zonas catalogadas como REM, normalmente, muestran altos niveles de P_{EOG} , P_{TD} y P_S .

Para descartar las zonas de vigilia se crearon dos indicadores: uno basado en la potencia RMS de movimientos de extremidades, a partir del EMG, y el otro en la razón de potencia entre la banda alfa y banda delta [20]. El indicador de movimiento de extremidades corresponde al máximo de potencia, época a época, entre el canal de movimiento de extremidad superior y el canal de movimiento de extremidad inferior. Se definieron estos indicadores como: P_{MOV} (indicador de movimientos de extremidades) y P_{AD} (indicador que corresponde a la razón de potencia entre banda alfa y delta). Luego se realizó un análisis por época, donde se calificó si una zona es contiene Vigilia según si esta sobre o bajo ciertos umbrales, de acuerdo a la siguiente regla:

R4) Si $\left\{ (P_{MOV}(e) > 0) \text{ OR } (P_{AD}(e) > \alpha_4 \cdot \overline{P_{AD}}) \right\} \Rightarrow$ Salida_W(e) = 0,
si no, Salida_W(e) = 1

donde $\overline{P_{AD}}$ es un escalar que corresponde al promedio de P_{AD} del registro en análisis. El valor de α_4 se obtuvo empíricamente a partir del conjunto de entrenamiento.

Finalmente, para identificar una zona NREM se utiliza la siguiente regla:

R5) Si $\left\{ \text{Salida}_{EOG}(e) = 0 \text{ OR } \text{Salida}_{TD-S}(e) = 0 \text{ OR } \text{Salida}_W(e) = 0 \right\}$
 \Rightarrow Salida_{NREM}(e) = 0, si no, Salida_{NREM}(e) = 1

donde 1 simboliza que la época en evaluación es catalogada como época NREM y 0 como una época que no es NREM.

Así se obtiene el inicio y fin de las zonas catalogadas como NREM, las cuales corresponden a la salida del módulo 1 y la entrada para el módulo 2.

2.5.2. Módulo 2: Detección automática de fases A

El módulo 2 tiene como objetivo identificar fases A. La figura 2.6 es un diagrama de bloques del módulo 2, donde la entrada al módulo 2 corresponde a la salida del módulo 1.

A grandes rasgos, en el módulo 2 se utiliza la información de potencia en las distintas bandas de frecuencias de las cinco derivaciones del EEG, con el fin de diferenciar fases A de fases B. Para esto se utilizan las siguientes herramientas: FFT, método de Welch (se explica en 2.5.2.1), clasificadores basados en redes neuronales artificiales y clasificadores basados en random forest.

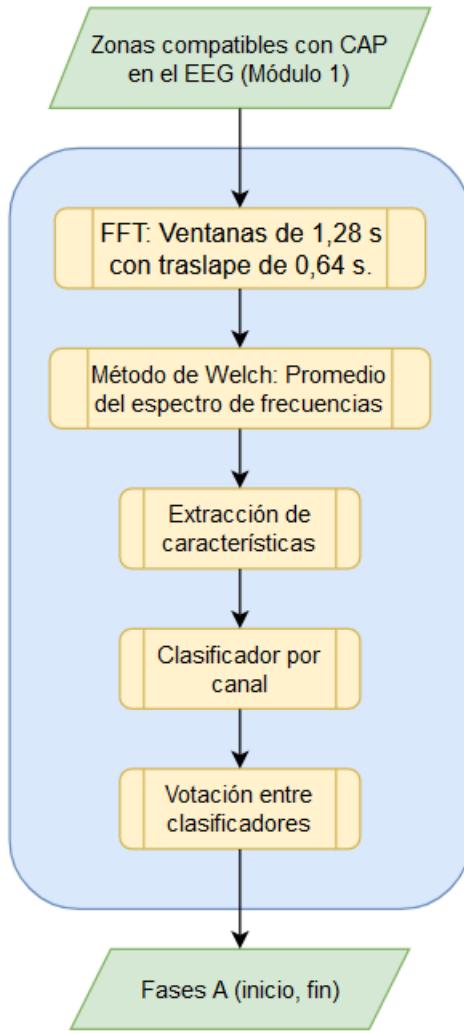


Figura 2.6: Diagrama de bloques del módulo 2. La entrada al módulo 2 son las zonas del EEG que el módulo 1 identificó como NREM. El módulo 2 busca determinar si cada ventana de 1,28 s del EEG debe ser catalogada como posible fase A o B de CAP. Primero se aplica la FFT sobre ventanas de Hamming de 1,28 s, con traslape de 0,64 s, a los canales del EEG. Posteriormente se aplica el método de Welch con el fin de obtener un espectro de frecuencia de contexto para la ventana de 1,28 s. A partir del espectro de frecuencia de la FFT y del espectro de frecuencia del método de Welch se obtienen cocientes de potencias en bandas de frecuencia. Estos cocientes constituyen las características que se utilizan como entradas a un clasificador (ANN o RF) que permite preclasificar cada ventana de 1,28 s en A1, A3 o B, para cada canal del EEG. Además, otro clasificador utiliza como entradas las características de todos los canales. De esta forma se construyen 6 clasificadores; 5 de cada canal EEG y uno que abarca todos los canales. Finalmente, se realiza una votación entre clasificadores, votación que define si la ventana de 1,28 s debe ser catalogada como A o B.

2.5.2.1. Aplicación de FFT y método de Welch

En la sección 1.2 de este informe se presentan las características de una fase A, donde se describe que existen aumentos de energía en ciertas bandas de frecuencias, que caracterizan a las fases A. En base a esto inicialmente se consideró relevante pesquisar las fases A a partir de un análisis frecuencial, a través de la FFT. Sin embargo, luego se pudo evidenciar que analizar tan solo la FFT no era suficiente para tener un buen clasificador automático de fases A, es decir, no bastaba aplicar la FFT en ventanas de 1,28 s para distinguir una fase A de la actividad de fondo del EEG. Por esto se decidió incluir el método de Welch, el cual se utiliza para obtener una referencia de potencias de la actividad de fondo por bandas de frecuencia del EEG.

El método de Welch [29] es una modificación del método de Bartlett, que es una herramienta para calcular la densidad espectral de potencia promedio de una señal. El método de Bartlett consiste en dividir una señal discreta de N muestras en K ventanas móviles de tamaño M, sin traslape, es decir: $N = K \cdot M$. Se calcula la FFT a cada ventana y se multiplica por el complejo conjugado, de esta forma se obtiene la potencia espectral de cada ventana. Luego se promedian las componentes de potencias de las K ventanas y se obtiene la densidad espectral de potencia promedio. Welch perfeccionó el método de Bartlett, introduciendo la posibilidad de traslapar ventanas y la opción de aplicar funciones de ventana como: Hamming, Blackman, Hann, etc.

En otras palabras, el método de Welch consiste en promediar una serie de espectros de potencia, obtenidos mediante FFT, de una determinada cantidad de ventanas consecutivas.

Para este trabajo, a cada canal del EEG se aplica la FFT con una ventana de Hamming móvil de 1,28 s (256 muestras), con un traslape de 0,64 s (128 muestras) entre ventanas, con el objetivo de calcular la potencia espectral en las siguientes bandas de frecuencia: delta lenta (0,5 - 2 Hz), delta rápida (2 - 4 Hz), theta (4 - 7 Hz), alfa (8 - 12 Hz) y beta (12 - 30 Hz). También se calcula la potencia espectral en la banda "fisiológica" (0,5 - 60 Hz) con la que se normalizan las potencias de las bandas descritas anteriormente.

Una vez que se aplica la FFT a todas las zonas catalogadas como NREM, se aplica el método de Welch: para cada una de las ventanas de 1,28 s se toma la potencia espectral, sin normalizar, de: 47 ventanas previas y 47 ventanas posteriores a la ventana en evaluación, además, de la potencia espectral de la ventana en evaluación, es decir, 95 ventanas en total. Cada una de estas potencias espectrales se promedia y se establecen como la potencia espectral del contexto en que está inmersa la ventana de 1,28 s en evaluación. El número de ventanas escogido se debe a que 47 ventanas de 1,28 s con traslape de 0,64 s es la cantidad de ventanas que cabe en 30 s de registro, es decir, es un promedio espectral de un minuto de señal. A partir de estas potencias espectrales de contexto se obtienen las potencias en las bandas de frecuencia delta lenta, delta rápida, theta, alfa y beta.

De esta forma, para cada canal del EEG se obtienen 11 potencias espectrales, para cada ventana de observación: 6 potencias instantáneas de la ventana, y 5 potencias de contexto para la ventana, obtenidas con el método de Welch.

2.5.2.2. Características para clasificar A1, A3 y B

Las 11 potencias espetrales mencionadas anteriormente se utilizan para crear las características con las que se entrena un clasificador asociado a un canal del EEG determinado. Las características utilizadas corresponden a la potencia por banda normalizada de dos formas:

por la potencia de la banda "fisiológica" de la ventana en evaluación, y por la potencia de la misma banda del contexto obtenido por Welch:

$$Potencia\ Normalizada_{Ventana,Banda} = \frac{Potencia_{Ventana,Banda}}{Potencia_{Ventana,Banda\ Fisiológica}} \quad (2.3)$$

$$Indice_{Potencia,Banda} = \frac{Potencia_{Ventana,Banda}}{Potencia_{Contexto,Banda}} \quad (2.4)$$

Es decir, por cada canal del EEG se obtienen 10 características para cada ventana de 1,28 s. Este procedimiento se repite en cada uno de los canales del EEG, luego se normaliza cada una de las características utilizando Z-Score³, y se entregan al siguiente bloque.

2.5.2.3. Clasificador de fases A1, A3 y B

En esta etapa, cada ventana de 1,28 s se clasifica en una de tres clases: A1, A3 y B. A2 no se distingue porque se considera una mezcla entre A1 y A3 [26]. Inicialmente se probaron clasificadores que consideraban A2 como una clase distinta, pero el desempeño fue considerablemente peor.

Se evaluaron dos tipos de clasificadores, unos basados en redes neuronales artificiales (ANN) y otros basados en random forest (RF). Se creó un clasificador por canal, y también uno que consideró las características de todos los canales a la vez. De esta forma se construyeron 6 clasificadores para ANN y 6 para RF.

Las ANN tienen múltiples parámetros que deben ser configurados adecuadamente para un óptimo funcionamiento. Entre estos parámetros se cuentan la cantidad de capas ocultas, la cantidad de neuronas por capa, las funciones de activación de cada neurona, el algoritmo de aprendizaje y la función de costo del sistema.

Para determinar la configuración del clasificador basado en ANN perceptron multicapa se fue cambiando la cantidad de capas ocultas y cantidad de neuronas, se modificaba uno de estos parámetros mientras el otro se mantenía constante. Se determinó que una ANN con tres o más capas ocultas solo incrementa el tiempo de cómputo y los resultados no son sustancialmente mejores que una ANN de dos capas ocultas. Para determinar la cantidad de neuronas a utilizar se hicieron pruebas con 30, 70 y 100, cantidad de neuronas elegidas arbitrariamente. Se determinó que una ANN con 30 neuronas no tiene tan buen desempeño como una con 70 neuronas y una ANN con 100 neuronas tiene un desempeño muy similar a una con 70 neuronas, sin embargo, el tiempo de computo es bastante mayor. En estas pruebas siempre se utilizó el conjunto de entrenamiento. Se concluyó que la mejor configuración, en cuanto a números de capas ocultas y a número de neuronas por capa, es con dos capas ocultas, cada una de 70 neuronas. Además, dentro de las pruebas realizadas se llegó a la conclusión que la mejor implementación cuenta con funciones de activación de tipo *ReLU*. La definición de función de activación se encuentra en 2.4.2 y que sea de tipo *ReLU* significa que está definida

³ Z-Score (también conocida como normalización estándar): Medida estadística que cuantifica en términos de la desviación estándar la distancia a la media. $z_{score} = \frac{x-\mu}{\sigma}$, donde x es la muestra de una población, μ es la media de la población y σ es la desviación estándar de la población.

por la función $\varphi(x) = \max(0, x)$, donde x es la entrada a la neurona, $\varphi(x) = 0$ cuando $x < 0$ y $\varphi(x) = x$ para $x \geq 0$. El algoritmo de optimización *Adam*, basado en el método del gradiente descendente, que busca los pesos W que minimizan la función de costo (ver 2.4.2). La función de costos es de error cuadrático medio (*Mean Square Error: MSE*), que mide el error cuadrático promedio de la diferencia entre el valor estimado y el por estimar, viene dado por la función: $MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$, donde n corresponde al número de predicciones, Y los valores por estimar e \hat{Y} los valores estimados.) [1].

Para determinar los parámetros óptimos en los clasificadores basados en RF se fue cambiando la cantidad de árboles en el bosque (10, 20 y 40) y la profundidad máxima de los árboles (5, 10 y 15) [19], valores elegidos arbitrariamente. Mientras uno de estos parámetros se modificaba el otro se mantenía constante. Se concluyó que la mejor configuración, en cuanto a cantidad de árboles y profundidad máxima de éstos, es de 20 árboles con una profundidad máxima de 10.

Los clasificadores basados en ANN y en RF fueron implementados utilizando la librería scikit-learn versión 0.21.0

Entrenamiento de los clasificadores

Inicialmente se entrenaron los clasificadores utilizando las características señaladas en 2.5.2.2, sin analizar previamente el conjunto de entrenamiento. El desempeño de este primer entrenamiento fue bastante bajo, para ambos clasificadores, estableciéndose que una de las razones para ello fue la existencia de valores atípicos (*outliers*) en el conjunto de entrenamiento. La razón para catalogar como outlier a una ventana es que su etiqueta difiere de las potencias espectrales características encontradas (ver 1.2).

Los outliers encontrados en el conjunto de entrenamiento fueron, por ejemplo, ventanas marcadas como A1 por el experto que tenían una potencia relativa inferior a una ventana marcada como A3 en la banda delta lenta para el mismo registro. Algo similar ocurrió con la banda beta, donde se encontraron ventanas marcadas como A1 por el experto que tenían una potencia relativa mayor que una ventana marcada como A3.

En base a estos antecedentes y a los resultados obtenidos se determinó eliminar las muestras que tenían ventanas catalogadas como A1 que tuvieran una potencia relativa en la banda delta lenta inferior a la mediana de la potencia relativa en la banda delta lenta de las ventanas A3 del conjunto de entrenamiento. Se decidió utilizar la mediana debido a que es más representativa que el promedio, en presencia de valores extremos. También se eliminaron las muestras que tenían ventanas catalogadas como A3 que tuvieran una potencia relativa inferior a la mediana de la potencia relativa en la banda beta de las ventanas A1 en la banda beta, esto se realizó en base a la caracterización de las fases A3 (ver 1.2). Para el caso de las ventanas B, se eliminaron las muestras que tenían una potencia relativa en la banda delta lenta mayor a la mediana de la potencia relativa en la banda delta lenta de las ventanas A1, también se descartaron las muestras de ventanas B que tuvieran una potencia relativa en la banda beta superior a la mediana de las ventanas A3.

En caso de haber dejado los outliers en el conjunto de entrenamiento, el algoritmo de aprendizaje habría aprendido de forma errónea a clasificar entre fases A1, A3 y B. Esto fue verificado dentro de las pruebas preliminares al desarrollo de este trabajo, donde se comprobó como la clasificación entre fases A1, A3 y B era considerablemente errónea.

La eliminación de muestras se realizó por separado para cada uno de los registro del conjunto de entrenamiento e independiente para cada canal del EEG. El conjunto de en-

trenamiento no incluyó los outliers detectados. Es importante decir que la eliminación de outliers solo fue en el conjunto de entrenamiento. El conjunto de prueba no fue revisado (no corresponde).

La eliminación de muestras en el conjunto de entrenamientos no fue consultada con los expertos, por lo que se podría estar dejando fuera características relevantes no consideradas.

Por otra parte las clases A1, A3 y B estaban desbalanceadas en el conjunto de entrenamiento, por lo que se buscó una técnica para balancear datos. Por simplicidad se decidió utilizar *undersampling*⁴, descartando de forma aleatoria la clase más representada. Al utilizar este criterio de balanceo de clases disminuyó considerablemente la cantidad de muestras. Por ejemplo, luego del filtrado de outliers el canal F4-C4 tenía 8.691 muestras de A1, 6.247 muestras de A3 y 184.453 muestras de B, después del balanceo de clases cada clase quedó con 6.247 muestras.

Finalmente cada clasificador se entrenó con clases balanceadas, quedando cada clasificador y muestras por clase en; F3-C3: 6.244 muestras, F4-C4: 6.247 muestras, C4-O2: 5.774 muestras, C3-O1: 5.851 muestras, C4-C3: 5.624 muestras y el clasificador que abarca todos los canales: 5.624 muestras. Nótese que el clasificador que incluye todos los canales tiene tantas muestras como el canal con menos muestras, C4-C3. Como se dijo anteriormente, cada muestra tiene 10 características, descritas en las ecuaciones 2.3 y 2.4, a excepción del clasificador que reúne todos los canales, el cual tiene 50 características.

2.5.2.4. Determinación de una fase A en base a votación entre clasificadores

Para catalogar una ventana de 1,28 s como A o B se utilizó la siguiente regla:

$$\begin{aligned} Si \left\{ \alpha_5 * \sum_i \left[P_{i,n}(A1) + P_{i,n}(A3) \right] \geq \sum_i P_{i,n}(B) \right\} \Rightarrow Salida(n) = 1 \text{ (Ventana A)} \\ si \text{ no } \Rightarrow Salida(n) = 0 \text{ (Ventana B)} \end{aligned} \quad (2.5)$$

donde P es la probabilidad de predicción de las clases, que se calcula con *Softmax*⁵ en el caso de ANN, y en RF, se calcula como el promedio de las predicciones de la clase de los árboles en el bosque [19] de la ventana n-ésima en el clasificador i-ésimo. Para la ventana n-ésima se suman las probabilidades de los seis clasificadores, de A1 y A3, y se compara con la suma de probabilidades de los seis clasificadores, de B.

La razón de utilizar probabilidades en los clasificadores se debe a que cuando las salidas son similares es mejor ser probabilístico en vez de categórico. Por ejemplo, si se tuviesen 2 clasificadores con 2 clases y el primer clasificador dice con una probabilidad de 0,49 que la salida corresponde a la clase 1 y 0,51 de ser de la clase 2, y el segundo clasificador dice con

⁴ Undersampling: Técnica para balancear el número de clases en un conjunto de datos: consiste en dejar el tamaño de las clases según el tamaño de la clase más pequeña. Los datos que sobreviven son escogidos aleatoriamente.

⁵ Softmax o Función exponencial normalizada [1]: Función que generaliza la función logística a múltiples dimensiones. Es utilizada en la última capa de las ANN, con el fin de normalizar la salida y dar una distribución de probabilidad entre las clases de la salida. La función Softmax viene dada por: $\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}$ para $j = 1,..,K$, donde z es un vector K-dimensional de valores reales, y σ , de dimensión K, es la distribución de probabilidad.

una probabilidad de 0,01 que la salida corresponde a la clase 1 y 0,99 de ser de la clase 2, entonces se puede decir que el segundo clasificador aporta más certeza en la decisión de la selección de la clase final. Esta afirmación no sería posible en caso de haber sido categórico en las salidas de los clasificadores. Además, la decisión de utilizar clasificadores con salidas probabilísticas se validó con los resultados de la detección de CAP obtenidos sobre el conjunto de entrenamiento.

El parámetro α_5 es un escalar que permite dar o quitar peso relativo a la detección de ventanas A: a mayores valores de α_5 se incrementa el peso relativo de la detección de ventanas A respecto de la detección de las ventanas B. Si α_5 tiene un valor pequeño, la detección de ventanas A disminuirá y aumentará la detección de ventanas B. El valor del parámetro α_5 se utilizó para crear las curvas ROC de los resultados de la detección de fases A y detección de CAP.

La idea subyacente a la ecuación 2.5 es realizar una votación entre clasificadores respecto a si una ventana debe ser catalogada como A o B. La votación se realiza debido a que a veces una fase A no se visualiza en todos los canales del EEG. Esto se basa en lo que hacen los expertos. Sin embargo, los expertos dan distintas ponderaciones a los canales del EEG, lo que por simplicidad no se hizo en el presente trabajo.

Las fases A deben tener una duración mínima de 2 s y máxima de 60 s, según la definición de fase A [26], por lo que el siguiente paso es corroborar que estas condiciones se cumplan. Lo que primero se decidió, en base a experimentación con el conjunto de entrenamiento, es que en caso de que existan ventanas A distanciadas por hasta 2 ventanas B (es decir, una separación de hasta 1,28 s, recordar que las ventanas han sido creadas con un paso de 0,64 s), estas ventanas B se catalogan como ventanas A y forman una fase A. Durante el entrenamiento se verificó que, si en vez de utilizar 2 ventanas B se utilizan 3 o más ventanas B, los falsos positivos incrementan, y para el caso de 1 ventana B, existían fases A que dejaban de ser detectadas.

Posteriormente, las ventanas A que están en una secuencia de duración mayor a 60 s se catalogan como ventanas B (esta condición no suele ocurrir, sin embargo, se debe hacer con el propósito de cumplir la duración máxima de una fase A). Finalmente se catalogan como ventanas B las ventanas A que están aisladas por 1,92 s o más respecto a una secuencia de ventanas A anterior o posterior a la ventana en evaluación. Así quedan definidas las fases A.

El módulo 2 entrega el inicio y fin de las fases A detectadas, las cuales sirven de entrada para identificar el tipo de fase A en el módulo 3

2.5.3. Módulo 3: Clasificador de tipo de fase A

El módulo 3 busca identificar el tipo de fase A a partir de la detección realizada por el módulo 2. Para identificar el tipo de fase A: A1, A2 o A3, se utilizan las potencias espectrales normalizadas por banda (ver sección 2.3), calculadas en el módulo 2. A cada marca de fase A, se le calcula el promedio y desviación estándar de las potencias espectrales normalizada por banda y por canal de la fase A. Por ejemplo, si una fase A dura 6,4 s entonces para cada canal del EEG existen 10 potencias espectrales normalizadas en la banda delta lenta asociadas a la fase A analizada (duración fase A/ traslape ventana = 6,4/0,64 = 10 potencias espectrales). A partir de las 10 potencias espectrales normalizada de la banda delta se calcula el promedio y desviación estándar, con el fin de tener medidas representativas de la fase A. Esto se realiza en las 5 bandas de frecuencia y en los 5 canales del EEG, por lo que para cada marca de fase A se tienen 50 características (promedio y desviación estándar por 5 frecuencias por 5

canales) que se toman como entradas a un clasificador, cuya salida es el tipo de fase A. El clasificador utilizado en esta etapa está basado en ANN y tiene la misma configuración que las ANN utilizadas en el Módulo 2.

Para el entrenamiento del clasificador de tipo de fase A se consideró el conjunto de entrenamiento completo, no la versión reducida por *undersampling* realizado en el Módulo 2. Dicho *undersampling* se aplicó para dejar las misma cantidad de muestras de ventanas A1, A3 y B para entrenar.

La cantidad de fases A1, A2 y A3 en el conjunto de entrenamiento es desigual (ver tabla 3.1), es decir, se tienen clases desbalanceadas. Para balancear las clases se utilizó *undersampling*, que significa disminuir las clases mayoritarias al mismo tamaño de la clase minoritaria.

2.5.4. Módulo 4: Identificación de CAP

Para determinar la presencia de CAP se deben cumplir las reglas señaladas en [26], las cuales son:

- Para que una secuencia de fases A se considere un CAP debe haber al menos 3 fases A seguidas, alternadas con intervalos menores o iguales de 60 s de fases B. La última fase A no se considera parte del CAP, sino que se define que un CAP comienza en la primera fase A y termina al final de la fase B inmediatamente anterior al inicio de la última fase A. Así se marca el inicio y el fin de un CAP.
- Si una fase A está alejada 60 s o más respecto a otra fase A, no se considera parte de un CAP.

De acuerdo a lo anterior, lo primero que se realiza en el módulo 4 es buscar fases A aisladas por más de 60 s respecto de la fase A más cercana, las que no se consideran en los pasos posteriores (se descartan). Luego se identifican el inicio y fin de cada CAP encontrado en el registro. Finalmente se entregan métricas que son de interés para los expertos: fases A contenidas en la totalidad de CAP, el tipo de fase A, los tiempos de las fases A, razón entre la cantidad de tiempo CAP y la cantidad de tiempo NREM.

2.6. Métricas de desempeño

Tal como se mencionó en Estado del Arte (1.4), los resultados presentados en los trabajos publicados de CAP están enfocados en la detección de fases A y al tipo de fase A. Es por esto que en este trabajo se crearon los mismos indicadores, para presentar resultados. A continuación se presentan los indicadores utilizados para evaluar la detección de fases A y posteriormente los indicadores para evaluar la identificación del tipo de fase A.

2.6.1. Indicadores para evaluar la detección de fases A

La salida del módulo 2 es binaria, clasifica cada ventana como fase A o fase B. Para evaluar estos resultados es necesario utilizar tests estadísticos binarios. Un ejemplo de test estadísticos binario es el aplicado a un sistema que detecta una enfermedad en particular. El objetivo es que se diagnostique una enfermedad cuando el paciente realmente la tiene, o que indique que el paciente no la tiene, en caso contrario. Las salidas se clasifican en 4 tipos:

1. Verdadero Positivo (VP): El paciente tiene la enfermedad y el sistema indica que el paciente tiene la enfermedad.
2. Falso Positivo (FP): El paciente no tiene la enfermedad y el sistema indica que el paciente tiene la enfermedad.
3. Verdadero Negativo (VN): El paciente no tiene la enfermedad y el sistema indica que el paciente no tiene la enfermedad.
4. Falso Negativo (FN): El paciente tiene la enfermedad y el sistema indica que el paciente no tiene la enfermedad.

Los sistemas de detección automática de fases A descritos en la literatura referenciada (ver sección 1.4.1) hacen una comparación segundo a segundo entre lo que dice el experto y lo que predice el sistema automático. En base a lo anterior, para cada segundo de registro se considera un VP cuando la ventana es fase A y se clasifica correctamente, un FP cuando la ventana es fase B pero se clasifica como A, un VN cuando la ventana es fase B y se clasifica como tal, y un FN cuando la ventana es fase A pero se clasifica como B.

A partir de lo anterior se construyen indicadores para describir el desempeño del módulo 2:

$$sensibilidad = \frac{VP}{VP + FN} \quad (2.6)$$

$$especificidad = \frac{VN}{VN + FP} \quad (2.7)$$

$$exactitud = \frac{VP + VN}{VP + VN + FP + FN} \quad (2.8)$$

2.6.2. Indicadores para la identificación del tipo de fase A

Con el módulo 3 se busca identificar el tipo de fase A, por lo que para evaluar este módulo es necesario tener métricas multiclases. Las métricas utilizadas en [6] y [11], son las que se utilizaron en este trabajo.

Sea k una de las clases presentes en el problema y l el número total de clases:

1. Verdadero Positivo (VP_k): Número de veces que una fase por segundo fue clasificada como perteneciente a la clase k , siendo que pertenecía a la clase k .
2. Falso Positivo (FP_k): Número de veces que una fase por segundo fue clasificada como perteneciente a la clase k , siendo que no pertenecía a la clase k .
3. Verdadero Negativo (VN_k): Número de veces que una fase por segundo no fue clasificada como perteneciente a la clase k , siendo que no pertenecía a la clase k .
4. Falso Negativo (FN_k): Número de veces que una fase por segundo no fue clasificada como perteneciente a la clase k , siendo que pertenecía a la clase k .

A partir de estas tasas se obtiene la sensibilidad de cada una de las clases y la exactitud en la identificación del tipo de fase A.

$$sensibilidad_k = \frac{VP_k}{VP_k + FN_k} \quad (2.9)$$

$$exactitud\ global = \frac{\sum_{k=1}^l \frac{VP_k + VN_k}{VP_k + VN_k + FP_k + FN_k}}{k} \quad (2.10)$$

2.6.3. Métricas para detección de CAP

Para evaluar la detección de CAP se aplicaron las mismas métricas que en la detección de fases A: sensibilidad, especificidad y exactitud (ver 2.6.1). Los resultados son analizados cada 1 segundo. La sensibilidad evalúa la detección de las zonas CAP, especificidad la detección de zonas que no son CAP y la exactitud evalúa la detección sobre todo el registro analizado.

Capítulo 3

Resultados

Los resultados obtenidos con el detector desarrollado se presentan en tres secciones; la primera corresponde a la detección de fase A, la segunda a la identificación del tipo de fase A y la tercera a la detección de eventos CAP.

Con el fin de realizar un análisis de sensibilidad del detector de fases A, del identificador de tipo de fase A y del detector de CAP, es que se probaron distintos valores del parámetro α_5 (ver ecuación 2.5).

3.1. Resultados del sistema de detección automática de fases A (módulo 2)

Para evaluar la detección automática de fases A se utilizaron las métricas de sensibilidad, especificidad y exactitud, las que se describen en la sección 2.6.1.

Los resultados para la detección automática de fases A fueron obtenidos buscando maximizar las métricas de sensibilidad y especificidad, y haciendo que ambas tuvieran valores similares. Para ello se utilizó un parámetro α_5 igual a 1,6 (resultados para otros valores del parámetro α_5 se encuentran en Anexos B (tablas B.1 y B.2)), tanto para el modelo basado en ANN como para el modelo basado en RF.

La tabla 3.1 presenta el número de fases A, separadas según tipo, contenidas en los conjuntos de entrenamiento, validación y prueba.

Tabla 3.1: Fases A contenidas en la base de datos

Conjunto	A1	A2	A3
Entrenamiento	5902	1229	1459
Validación	1419	397	534
Prueba	6222	998	1261

La tabla 3.2 presenta la cantidad de fases A, separadas según tipo, para cada uno de los registros contenidos en el conjunto de prueba. En el Anexo A se encuentran las tablas A.2 y A.3, que muestran los tipos de fases A para los registros de los conjuntos de entrenamiento y validación, respectivamente.

Tabla 3.2: Cantidad y tipo de fases A en los registros del conjunto de prueba marcadas por experto. Se aprecia que la cantidad de fases A puede variar considerablemente entre registros, sin embargo, la cantidad de fases A1 suele ser mayor a la cantidad de fases A2 y A3.

Nº Registro	Cantidad de fases		
	A1	A2	A3
4	372	28	49
5	332	39	51
9	300	48	60
11	156	51	76
12	274	51	91
13	268	71	117
14	255	43	47
15	144	23	53
17	431	41	62
19	161	76	181
23	375	78	51
27	312	44	55
32	492	43	46
33	422	51	37
34	422	51	37
40	383	49	44
41	289	37	47
43	313	76	18
47	313	30	68
48	282	23	50
Total	6222	998	1261

La tabla 3.3 presenta las métricas de especificidad, sensibilidad y exactitud obtenidas con los distintos conjuntos para ambos clasificadores, considerando registros de sueño completos.

Tabla 3.3: Tabla resumen de la detección automática de fases A, para registros de sueño completos, en los conjuntos de entrenamiento, validación y prueba, aplicando clasificadores basados en ANN y RF.

Clasificador	Conjunto	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
Red Neuronal Artificial	Entrenamiento	78,8	80,1	78,9
	Validación	78,9	80,5	79,1
	Prueba	78,7	79,4	78,8
Random Forest	Entrenamiento	77,0	80,4	77,2
	Validación	76,5	80,8	76,8
	Prueba	78,8	78,3	78,7

Las tablas 3.4 y 3.5 presentan los resultados obtenidos en cada registro del conjunto de prueba, considerando registros de sueño completos. Se presentan las mismas métricas

anteriores, para ambos clasificadores.

Tabla 3.4: Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando registros completos y utilizando clasificadores basados en ANN.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	76,8	79,0	77,0
5	80,3	79,4	80,2
9	76,9	73,2	76,6
11	81,7	84,5	81,9
12	78,2	81,5	78,5
13	79,3	79,9	79,4
14	81,6	73,5	81,1
15	83,9	75,8	83,5
17	78,8	83,6	79,3
19	79,7	81,6	79,9
23	75,0	86,7	76,1
27	75,4	81,9	75,8
32	78,4	64,9	76,6
33	81,1	80,3	81,0
34	77,7	83,4	78,2
40	78,6	84,2	79,1
41	77,2	82,2	77,6
43	77,4	72,0	77,0
47	76,4	81,9	76,8
48	80,3	79,3	80,2
Total	78,7	79,4	78,8

Tabla 3.5: Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando registros completos y utilizando clasificadores basados en RF.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	77,2	77,7	77,3
5	81,6	77,7	81,3
9	82,4	71,5	81,5
11	79,8	81,4	79,9
12	76,7	79,5	76,9
13	78,1	78,7	78,1
14	79,1	77,0	79,0
15	77,2	76,4	77,2
17	81,9	80,6	81,8
19	76,9	83,2	77,4
23	77,1	81,9	77,6
27	82,8	77,4	82,4
32	79,1	63,7	77,1
33	80,3	80,0	80,3
34	78,7	82,5	79,1
40	77,2	82,8	77,7
41	75,0	82,3	75,5
43	76,3	73,7	76,1
47	78,0	80,3	78,1
48	80,2	78,0	80,1
Total	78,8	78,3	78,7

La tabla 3.6 presenta las métricas de especificidad, sensibilidad y exactitud para los distintos conjuntos y ambos clasificadores, obtenidas sobre segmentos del EEG en estado de sueño NREM.

Tabla 3.6: Tabla resumen de la detección automática de fases A, sobre los segmentos del EEG en estado de sueño NREM, para los conjuntos de entrenamiento, validación y prueba, aplicando clasificadores basados ANN y RF.

Clasificador	Conjunto	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
Red Neuronal Artificial	Entrenamiento	87,1	80,1	86,6
	Validación	86,3	79,4	85,8
	Prueba	85,6	80,1	85,2
Random Forest	Entrenamiento	86,3	80,4	85,9
	Validación	84,6	80,9	84,2
	Prueba	85,6	79,2	85,0

Las tablas 3.7 y 3.8 presentan los resultados obtenidos al analizar cada registro del conjunto de prueba, considerando sólo los segmentos del EEG en estado de sueño NREM. Se

presentan las mismas métricas anteriores para ambos clasificadores.

Tabla 3.7: Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	86,3	79,9	85,8
5	87,3	80,3	86,7
9	85,0	74,7	84,1
11	84,8	84,0	84,8
12	84,3	80,8	84,0
13	86,4	80,3	85,9
14	86,1	77,6	85,6
15	88,4	79,9	88,0
17	88,7	84,4	88,3
19	85,7	80,6	85,2
23	82,3	87,3	82,8
27	80,4	83,1	80,6
32	89,8	64,5	86,5
33	83,1	80,2	82,8
34	85,6	84,1	85,5
40	86,4	84,0	86,2
41	84,7	82,4	84,6
43	85,3	72,5	84,3
47	83,5	83,2	83,5
48	88,6	78,1	87,9
Total	85,6	80,1	85,2

Tabla 3.8: Resultados de cada registro del conjunto de prueba para la detección de fases A, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	85,8	79,8	85,4
5	88,0	78,0	87,1
9	88,1	73,9	87,0
11	83,5	82,0	83,4
12	84,0	79,0	83,6
13	85,5	80,0	85,0
14	84,4	78,9	84,1
15	83,3	82,4	83,2
17	89,9	81,2	89,1
19	83,0	83,3	83,0
23	84,4	82,5	84,2
27	86,6	77,9	86,0
32	89,4	63,1	85,9
33	83,3	81,2	83,1
34	86,2	82,5	85,8
40	85,8	82,8	85,6
41	83,6	82,9	83,6
43	84,3	75,0	83,6
47	84,4	81,6	84,3
48	88,5	76,8	87,8
Total	85,6	79,2	85,0

3.2. Resultados del sistema de identificación del tipo de fase A (módulo 3)

Todos los resultados que se presentan en esta sección se obtuvieron considerando que el módulo 2 utiliza ANN en sus clasificadores y el parámetro α_5 es igual a 1,6. Resultados para otros valores del parámetro α_5 se encuentran en Anexos B (tablas B.5 y B.6).

Los resultados de la identificación de tipo de fase A para registros de sueño completos se presentan en la tabla 3.9.

Tabla 3.9: Resultados de cada registro del conjunto de prueba para la identificación del tipo de fase A, considerando registros de sueño completos.

Nº Registro	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud global (%)
4	74,8	64,9	33,5	47,9	73,4
5	78,8	49,8	60,3	59,2	76,4
9	75,6	48,0	27,7	39,9	72,8
11	80,9	84,7	41,2	30,3	79,2
12	77,3	58,4	61,6	41,1	75,3
13	78,7	70,4	65,8	45,5	77,2
14	81,1	52,1	59,6	26,5	79,1
15	82,8	66,6	64,4	51,7	81,6
17	77,3	84,5	37,6	31,9	76,4
19	78,7	66,3	55,0	41,6	76,3
23	73,2	82,1	38,5	55,3	72,8
27	72,6	25,8	37,0	50,7	69,8
32	76,3	32,1	26,9	46,8	70,2
33	79,1	73,0	35,2	31,5	77,3
34	75,2	60,9	26,4	52,5	73,2
40	77,5	38,8	37,6	65,9	74,6
41	76,0	58,1	67,3	50,5	74,5
43	76,8	30,6	46,4	39,9	73,4
47	74,7	45,3	39,2	49,1	72,6
48	79,3	51,1	47,7	53,7	77,5
Total	77,3	56,5	43,6	45,1	75,1

La tabla 3.10 presenta los resultados de la identificación del tipo de fase A, considerando sólo los segmentos de registros en estado de sueño NREM.

Tabla 3.10: Resultados de cada registro del conjunto de prueba para la identificación del tipo de fase A, considerando sólo los segmentos de registro de sueño en estado NREM.

Nº Registro	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud global (%)
4	84,5	66,9	28,5	45,5	82,3
5	86,1	53,6	52,4	61,8	83,2
9	84,2	48,5	26,7	49,7	80,8
11	84,2	84,7	43,2	32,3	82,4
12	83,8	57,7	60,1	38,7	81,2
13	85,6	69,5	64,3	51,3	83,6
14	85,7	52,9	59,0	34,8	83,5
15	87,2	70,0	68,1	52,4	85,9
17	87,7	86,3	46,9	33,6	86,1
19	84,8	62,7	51,0	42,2	81,8
23	81,0	82,5	40,7	57,8	80,0
27	78,8	26,1	38,0	53,1	75,6
32	88,7	33,3	28,6	37,8	81,0
33	81,1	72,4	41,4	38,6	79,3
34	83,9	59,9	20,8	50,6	80,9
40	85,7	40,0	35,9	62,2	82,1
41	84,1	56,9	61,0	49,0	81,7
43	84,4	27,9	53,2	42,0	80,4
47	82,4	43,3	47,4	49,8	79,7
48	87,7	53,7	56,6	48,9	85,5
Total	84,6	56,8	44,4	46,4	82,0

3.3. Resultados globales de CAP (módulo 4)

De acuerdo a las marcas del experto, no todas las fases A marcadas son parte de un CAP. Las fases A que no pertenecen a un CAP son fases aisladas por más de 60 s respecto a una fase A previa o posterior (definición de CAP: 1.2). La tabla 3.11 muestra el total de fases A marcadas por el experto en el conjunto de prueba y la cantidad de estas fases que no están contenidas en CAP. (Las tablas análogas a la tabla 3.11, para los conjuntos de entrenamiento y validación se encuentran en el anexo A, tablas A.4 y A.5, respectivamente.)

Tabla 3.11: Cantidad de fases A en cada registro del conjunto de prueba marcadas por un experto y cantidad de estas fases que no están contenidas en CAP.

Nº Registro	Total de fases A	Fases A no contenidas en CAP
4	449	30
5	422	26
9	408	48
11	283	60
12	416	65
13	456	43
14	345	58
15	220	53
17	534	23
19	418	73
23	504	37
27	411	58
32	412	27
33	510	46
34	459	25
40	476	27
41	585	54
43	407	66
47	411	35
48	355	40
Total	8481	894

Las fases A que no cumplen con los requisitos para ser CAP fueron descartadas para la detección de CAP. Esto se aplica tanto para las marcas hechas por el experto, como para las marcas del sistema propuesto.

Los resultados para la detección automática de CAP fueron obtenidos buscando maximizar las métricas de sensibilidad y especificidad para CAP, y haciendo que ambas tuvieran valores similares. Para ello se ajustó el parámetro α_5 a 0,4, tanto para el modelo basado en ANN como para el modelo basado en RF.

Tal como en las secciones anteriores, los resultados se dividen según el tipo de clasificador utilizado, ANN o RF, y según se clasifican registros completos o segmentos de registros en estado de sueño NREM. Las tablas 3.12 y 3.13 presentan los resultados de la detección automática de CAP en registros de sueño completo, utilizando clasificadores basados en ANN y RF, respectivamente.

Tabla 3.12: Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en ANN.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	80,6	77,3	79,5
5	75,1	89,8	80,1
9	69,9	76,3	71,7
11	69,7	87,5	73,1
12	76,5	81,1	77,5
13	79,2	71,7	76,9
14	88,0	64,9	82,8
15	94,1	73,4	91,3
17	75,2	94,6	81,7
19	73,3	77,5	74,3
23	79,0	91,3	82,8
27	67,7	81,6	71,1
32	67,0	91,2	74,6
33	77,7	86,2	80,7
34	66,7	85,1	73,9
40	70,8	80,0	74,3
41	78,8	80,3	79,3
43	67,8	74,6	69,4
47	72,3	82,0	75,3
48	81,1	78,9	80,6
Total	75,5	81,3	77,5

Tabla 3.13: Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en RF.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	91,5	57,2	80,2
5	79,2	85,8	81,4
9	79,4	52,2	71,9
11	76,7	78,4	77,0
12	80,3	70,9	78,2
13	91,7	46,0	77,6
14	94,3	44,1	83,0
15	94,9	66,2	90,9
17	76,8	92,9	82,2
19	85,6	49,1	76,6
23	71,7	86,1	76,2
27	66,6	87,6	71,7
32	73,5	80,4	75,6
33	83,4	86,4	84,5
34	75,2	77,3	76,0
40	78,0	65,2	73,2
41	84,8	71,2	80,2
43	77,7	55,7	72,4
47	83,6	66,6	78,4
48	84,8	70,6	81,7
Total	81,5	69,5	78,4

Las tablas 3.14 y 3.15 presentan los resultados de la detección automática de CAP en segmentos del EEG en estado de sueño NREM , utilizando clasificadores basados en ANN y RF, respectivamente.

Tabla 3.14: Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	83,6	78,7	82,0
5	84,7	88,1	85,8
9	81,1	76,8	79,9
11	71,8	90,5	75,4
12	78,6	80,3	79,0
13	84,8	69,4	80,1
14	89,2	65,3	83,8
15	93,1	78,6	91,0
17	82,6	94,8	86,7
19	78,7	79,0	78,8
23	82,0	90,8	84,8
27	78,6	84,1	79,9
32	80,2	88,6	82,8
33	78,1	89,0	81,9
34	75,6	85,7	79,6
40	79,5	78,9	79,3
41	86,4	82,0	84,9
43	72,6	71,1	72,3
47	80,9	78,9	80,3
48	84,7	79,3	83,5
Total	81,3	81,5	81,6

Tabla 3.15: Resultados de cada registro del conjunto de prueba para la detección automática de CAP, considerando sólo los segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF.

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	91,9	58,1	80,7
5	86,2	85,7	86,0
9	87,8	56,7	79,2
11	78,6	80,8	79,1
12	83,8	68,1	80,3
13	92,7	53,4	80,6
14	91,4	44,8	80,9
15	94,4	71,2	91,2
17	84,6	92,8	87,3
19	87,8	52,7	79,1
23	73,9	86,7	77,9
27	74,5	88,5	77,9
32	85,2	79,4	83,4
33	84,3	88,4	85,8
34	81,1	80,7	80,9
40	84,0	71,6	79,3
41	89,2	73,6	84,0
43	80,6	60,3	75,7
47	88,4	68,4	82,2
48	86,9	70,1	83,4
Total	85,4	71,6	81,7

Capítulo 4

Discusión

4.1. Análisis de resultados

4.1.1. Detección automática de fases A (módulo 2)

Los resultados para la detección automática de fases A en registros completos de sueño nocturno en los conjuntos de entrenamiento, validación y prueba, presentan una baja dispersión en los índices presentados en la tabla 3.3, tanto para clasificadores basados en ANN como para clasificadores basados en RF. Esto parece indicar que la distribución de los registros en cada conjunto de la base de datos se realizó adecuadamente, logrando incluir en cada conjunto la variedad de fases A existentes en la muestra. Es decir, permitió obtener un sistema con una buena capacidad de generalización, evitando el sobre-ajuste.

En términos metodológicos, la evaluación final del desempeño del detector automático de fases A se debe realizar sobre el conjunto de prueba. Los resultados obtenidos sobre este conjunto son los que miden el real desempeño del sistema propuesto. Las tablas 3.4 y 3.5 presentan los resultados para la detección de fases A en registros de sueño completo en el conjunto de prueba, donde la primera tabla presenta los resultados obtenidos utilizando clasificadores basados en ANN y la segunda tabla considera un sistema que utiliza clasificadores basados en RF. Ambas tablas presentan resultados para un parámetro α_5 igual a 1,6 (ver ecuación 2.5).

En relación a la sensibilidad de los clasificadores basados en ANN, tabla 3.4, los 5 mejores resultados se obtuvieron en los registros 11, 17, 23, 34 y 40. Para el caso de los clasificadores basados en RF, tabla 3.5, los 5 mejores resultados en sensibilidad se obtuvieron en los registros 19, 23, 34, 40 y 41. Las características comunes de estos registros es la presencia de fases A que presentan un cambio en frecuencia y amplitud notorio respecto de la actividad EEG de fondo, sumado a que el cambio se presenta en los distintos canales del EEG. La figura 4.1 presenta una fase A bien consolidada, la línea horizontal roja representa la marca hecha por el experto y la línea horizontal negra punteada es la marca de la detección del sistema. Por otro lado, los rendimientos decrecen cuando las diferencias de amplitud y frecuencia entre la fase A y la actividad EEG de fondo son reducidas, tal como se presenta en la figura 4.2, donde la línea roja presenta la marca hecha por el experto y la línea negra punteada es la marca hecha por el sistema.

La figura 4.2 corresponde a un segmento de registro donde el individuo está en etapa de sueño profundo. En esta etapa es donde ocurre la mayor parte de los FP en la detección de fase A, debido a que los cambios de actividad del EEG son de pequeña magnitud y las fases A no se

presentan en la mayoría de los canales del EEG, lo que termina haciendo que el clasificador realice detecciones erróneas.

Los mejores resultados en especificidad y exactitud del sistema, con clasificadores basados en ANN, tabla 3.4, se obtuvieron en los registros 5, 11, 14, 15, 33 y 48. En el caso de clasificadores basados en RF, tabla 3.5, los mejores resultados se obtuvieron en los registros 5, 9, 17, 27 y 33. A pesar de que estos registros son los que tienen mejor especificidad y exactitud, no presentan un desempeño significativamente superior al total de los registros. La gran correlación entre los resultados de especificidad y exactitud se debe a que gran parte de los registros corresponde a la actividad de fondo.

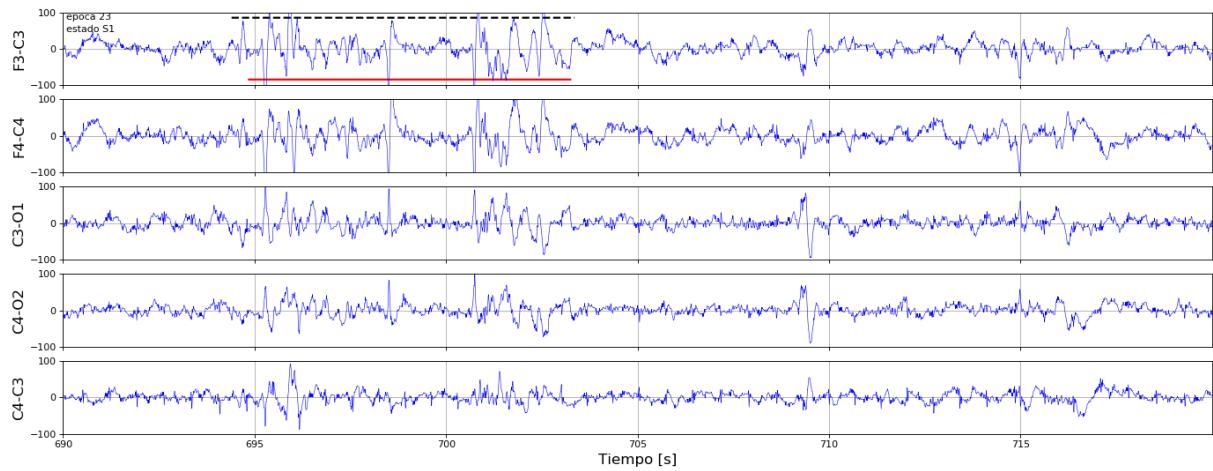


Figura 4.1: Ejemplo de fase A bien consolidado, donde existe un cambio en frecuencia y amplitud que es notorio respecto de la actividad EEG de fondo. La figura muestra las 5 derivaciones del EEG del registro. La línea roja marcada en el canal fronto central F3-C3 es la marca del experto de la fase A, en base a la observación de todos los canales. La línea negra punteada es la marca de la detección del sistema automático.

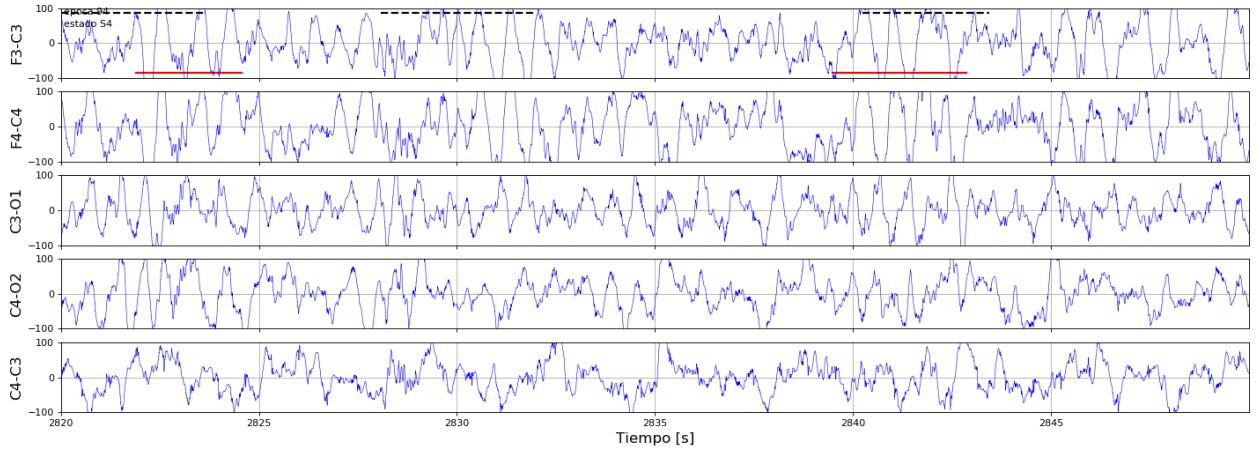


Figura 4.2: Ejemplo de fases A en que existe un bajo cambio en amplitud y frecuencia de la señal respecto a la actividad de fondo del EEG. La figura muestra las 5 derivaciones del EEG del registro. Las fases A marcadas por un experto aparecen como una línea roja continua en el canal fronto central F3-C3. Las líneas negras punteadas son las marcas de las detecciones del sistema automático.

La tabla 3.6 presenta los resultados del sistema detector de fases A aplicado sólo sobre los segmentos de sueño en estado NREM. El objetivo de presentar estos resultados es mostrar las mejoras en la detección al tener el conocimiento previo de los estados de sueño en los registros. Este incremento significa que el módulo 1 no logra identificar de forma precisa los segmentos en estado NREM, por lo que pueden ocurrir dos situaciones: al módulo 2 pasan zonas del EEG en estado de vigilia y/o REM, lo que tiene como consecuencia que se puedan detectar fases A en zonas en que no hay presencia de fases A, y que el módulo 1 descarta zonas NREM que no debiera, que pueden contener fases A que se pierden. Por la forma en que se construyó el módulo 1 es más probable que ocurra el primer escenario: que al módulo 2 pasen zonas de vigilia y/o REM. La mayoría de los trabajos en la literatura presentan resultados de detección de fases A sólo en las zonas NREM, por lo que se utilizaron estos resultados para comparar con esos trabajos.

Para comparar resultados entre diferentes detectores automáticos de fases A, es conveniente utilizar curvas ROC, porque diferentes autores podrían privilegiar diferentes puntos de operación. Una curva ROC se construye modificando el valor de un parámetro que incida en cambios en la sensibilidad y especificidad del sistema propuesto.

Las figuras 4.3 y 4.4 muestran las curvas ROC para registros completos y para segmentos de registros en sueño NREM, respectivamente. Una curva ROC presenta la sensibilidad como función de *1-especificidad* para distintos valores del parámetro α_5 . Las figuras 4.3 y 4.4 incluyen otros puntos fuera de las curvas, que corresponden a los resultados publicados de otros sistemas de detección automática de fases A revisados en la bibliografía. Los valores incluidos corresponden a trabajos que presentan resultados de sensibilidad y especificidad, y aplicados a registros completos o zonas con estado de sueño NREM.

Combinar las curvas ROC que describen los resultados de este trabajo con resultados de otros trabajos publicados permite una comparación en la eficacia lograda; si los puntos que representan los resultados de otros trabajos publicados caen por debajo de la curva ROC del sistema propuesto, entonces los resultados del sistema propuesto son superiores a los de otro

trabajo. Sin embargo, se debe considerar que se trabaja con distintas bases de datos, por lo que la comparación con otros trabajos no es estrictamente correcta, y diferencias pequeñas no son significativas.

Las curvas ROC presentadas en la figura 4.3 fueron creadas a partir de los resultados obtenidos con la totalidad del conjunto de prueba en registros de sueños completos, utilizando 5 valores distintos del parámetro α_5 (anexo B, tablas B.1 y B.2). Los puntos que representan los resultados de otros trabajos (presentados en Estado del Arte 1.4) se encuentran en la tabla 4.1. Al observar dichas curvas ROC se ve que los resultados de Shanawaz et. al. [24] están bajo la curva ROC del sistema propuesto, tanto para el sistema basado en ANN como para el sistema basado en RF, en tanto que los resultados de Machado et. al. [11] están demasiado cerca como para establecer una conclusión. De esta forma se podría considerar que el trabajo propuesto es mejor que el de Shanawaz et. al. [24], sin embargo, esto no es una afirmación totalmente correcta, ya que las bases de datos no son iguales. Por otra parte, los otros trabajos utilizan validación cruzada para evaluar el sistema que proponen, por lo que no hay igualdad de condiciones para comparar.

Es relevante destacar que el trabajo que aquí se presenta es el que cuenta con la mayor base de datos, 48 registros en total, respecto a otros trabajos presentados en la literatura. Esto es válido tanto para la detección automática de fases A en registros completos de sueño, como para la detección en segmentos de registros en estado de sueño NREM.

Tabla 4.1: Resultados obtenidos por diferentes sistemas de detección automáticos de fases A aplicados a la totalidad de registros de sueño.

Autores	Especificidad (%)	Sensibilidad (%)	Exactitud (%)	Cantidad de registros totales
Shanawaz et. al. 2018 [24]	69	55	67	14
Machado et. al. 2018 [11]	79	76	76	30

Nota: Los dígitos significativos corresponden a los publicados en los trabajos referenciados.

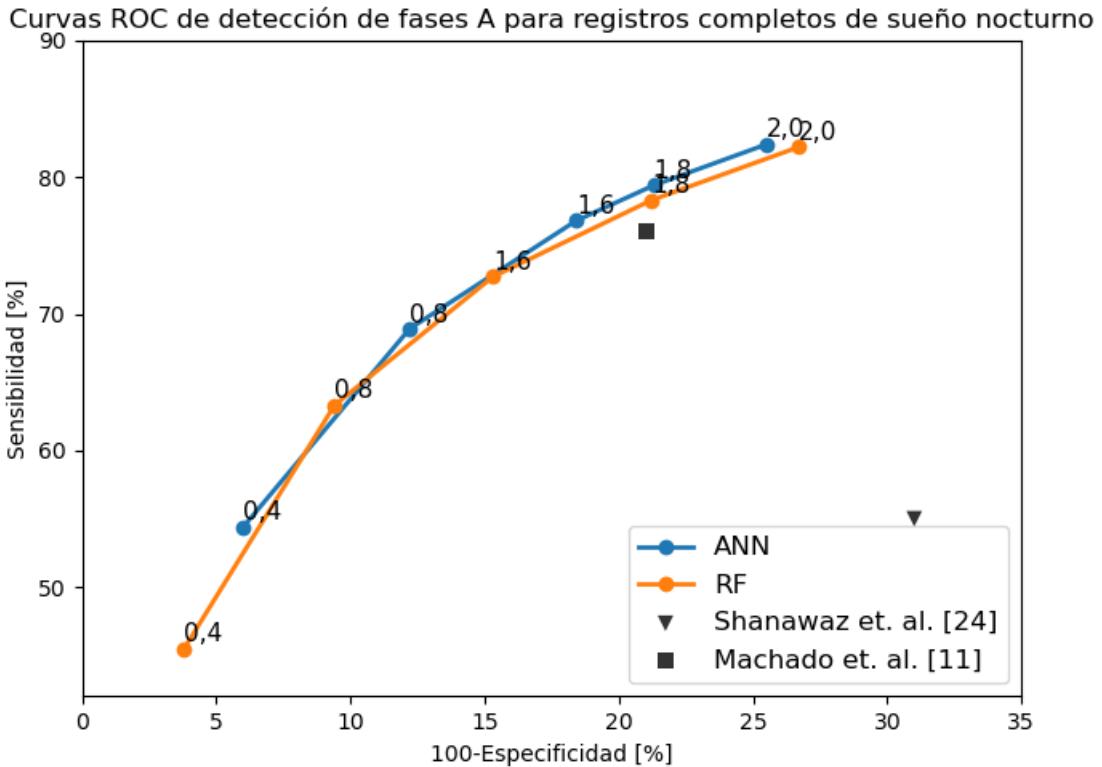


Figura 4.3: Curvas ROC del sistema de detección de fases A propuesto, aplicado sobre registros completos de sueño nocturno. Las curvas se obtuvieron utilizando distintos valores del parámetro α_5 (es el valor asociado a cada punto) y aplicando clasificadores basados en ANN y RF (dos curvas). Además se compara con los resultados de otros métodos publicados en la literatura.

Las curvas ROC presentadas en la figura 4.4 corresponden a los resultados obtenidos con la totalidad de los segmentos de registros en fase NREM del conjunto de prueba, con distintos valores del parámetro α_5 , para los sistemas basados en clasificación ANN y RF (Anexo B tablas B.3 y B.4, respectivamente).

Los resultados de otros trabajos que utilizan sólo las zonas de registros en estado NREM se presentan en la tabla 4.2, y también se muestran en la figura 4.4. Se observa que los resultados obtenidos por Hartmann et. al. [6] son cercanos a los obtenidos por los sistemas que se proponen, esto podría indicar que los resultados son similares. Sin embargo, ellos utilizaron validación cruzada en sus datos y las bases de datos son distintas, por lo que los resultados no son comparables. Los resultados obtenidos por Mariani et. al. en distintas oportunidades [12], [13], [14], [15], Niknazar et. al. [18] y Mendoza et. al. [17] muestran resultados inferiores a la curva ROC del sistema propuesto, tanto para el sistema basado en ANN como para el basado en RF. Sin embargo, nuevamente hay que tener en cuenta que las bases de datos no son las mismas, por lo que la comparación es limitada.

Tabla 4.2: Resultados obtenidos por diferentes sistemas de detección automáticos de fases A aplicados a porciones de registros en estado de sueño NREM del EEG.

Autores	Especificidad (%)	Sensibilidad (%)	Exactitud (%)	Cantidad de registros totales
Mariani et. al. 2010 [12]	83,1	75,7	81,6	4
Mariani et. al. 2011 [13]	85,9	73,8	84,1	4
Mariani et. al. 2012 [14]	86,6	72,5	84,9	8
Mariani et. al. 2013 [15]	89,0	67,0	86,1	16
Niknazar et. al. 2015 [18]	81,3	75,8	80,5	6
Machado et. al. 2016 [10]	-	-	71,0	30
Mendonça et. al. 2018 [17]	74,0	78,0	75,0	14
Hartmann et al. 2019 [6]	88,5	76,1	86,4	16
Hartmann et al. 2019 [6]	86,5	78,5	85,1	30

Nota: Los dígitos significativos corresponden a los publicados en los trabajos referenciados.

Hartmann et. al. [6] obtuvieron resultados con distintas bases de datos, por eso aparece dos veces en la tabla.

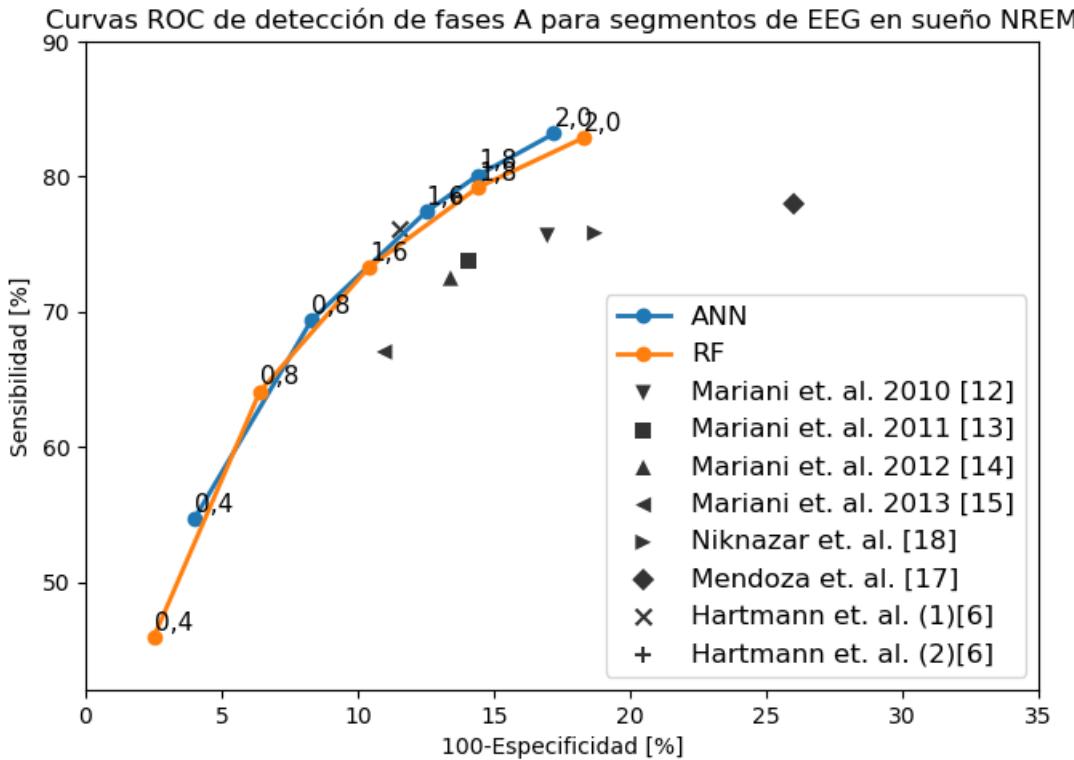


Figura 4.4: Curvas ROC del sistema de detección de fases A propuesto aplicado sólo sobre segmentos del EEG en estado de sueño NREM. Las curvas fueron obtenidas utilizando distintos valores del parámetro α_5 (el valor asociado a cada punto), para clasificadores basados en ANN y RF. Además se comparan con los resultados de otros métodos publicados en la literatura.

Finalmente, realizando un análisis y comparación global del sistema propuesto se puede señalar que:

1. Durante el entrenamiento del sistema de detección de fases A se evidenció que evaluar características frecuenciales en pequeños intervalos de tiempo, menores a 2 s, y comparar estas características frecuenciales con las frecuencias del contexto en que está inmerso el intervalo de tiempo en evaluación, es esencial en una buena detección de fases A, lo que se logró gracias al método de Welch.
2. Las fallas en la detección de fases A se dan principalmente en zonas del EEG donde las fases A no tienen un cambio relevante respecto a la actividad de fondo y cuando las fases A no se ven en la mayoría de los canales. Este es un problema que se da principalmente en sueño quieto profundo.

4.1.2. Identificación del tipo fase A (módulo 3)

Los criterios de los expertos para identificar el tipo de fase A se basan principalmente en un análisis frecuencial, para ello buscan cumplir con la caracterización de cada tipo de fase

A, descritas en la sección Tipos de fases A 1.2. En base a esto es que el sistema propuesto utiliza las potencias por bandas de frecuencia de las fases A.

Para la identificación del tipo de fase A se consideró la marca completa generada por el módulo 2 y no segundo a segundo. Por ejemplo, si una fase A dura 6 s, en este trabajo se clasifica de un solo tipo. Esto es lo que hacen expertos, las fases A no son 3 s A1, 2 s A2 y 1 s A3. El desempeño del sistema de identificación del tipo de fase A, se evaluó comparando segundo a segundo lo que dijo el sistema automático y lo que marcó el experto.

La tabla 4.3 presenta el promedio y la desviación estándar de los resultados presentados en la tabla 3.9 de la identificación del tipo de fase A para registros de sueño completos. A partir de la tabla 4.3 se ve que existe una baja sensibilidad en las fases B, consecuencia de que el módulo 2 etiquetó fases B siendo A. También se ve que la sensibilidad es baja entre los tipos de fases A, esto se debe a una identificación errónea entre fases A1 y A2 y entre fases A2 y A3. El error de identificación entre fases A1 y A2 y entre fases A2 y A3 es esperable, ya que las fases A2 son una mezcla entre fases A1 y A3, tal como se describe en la sección Tipos de fases A 1.2. Otra razón de que la sensibilidad sea baja en los tipos de fases A es que el módulo 2 clasifica fases A, principalmente A2 y A3, como B, por lo que esas fases A llegan como B al módulo 3.

Tabla 4.3: Resultados de la identificación del tipo de fase A del sistema propuesto. Se muestran también los resultados de Machado et. al. [11]. Ambos resultados corresponden a registros de sueño completos.

Autores	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud global (%)	Cantidad de registros totales
Sist. propuesto	77,3 ± 2,7	57,2 ± 17,5	45,4 ± 13,7	45,6 ± 10,3	75,2 ± 3,0	48
Machado et. al. [11]	76 ± –	58 ± –	44 ± –	24 ± –	71 ± –	30

La tabla 4.4 presenta el promedio y la desviación estándar de los resultados presentados en la tabla 3.10 de la identificación del tipo de fase A, considerando sólo los segmentos de registros en estado NREM. A partir de la tabla 4.4 se ve que la sensibilidad en B mejora considerablemente respecto a la sensibilidad presentada en la tabla 3.9, es decir, que si el módulo 1 identificase correctamente el estado de sueño NREM, entonces la sensibilidad de B aumentaría. Por otra parte, la sensibilidad en la identificación del tipo de fase A no tuvo grandes cambios, por lo que mejorar el módulo 1 no ayudaría a aumentar la sensibilidad en la identificación del tipo de fase A.

Tabla 4.4: Resultados de la identificación del tipo de fase A del sistema propuesto. Se muestran también los resultados de Hartmann et. al. [6]. Ambos resultados corresponden a segmentos de registros de sueño en estado NREM.

Autores	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud global (%)	Cantidad de registros totales
Sist. propuesto	84,6 ± 2,44	57,4 ± 17,6	46,2 ± 13,5	46,6 ± 8,9	81,8 ± 2,5	48
Hartmann et. al. [6]	82,30 ± 6,77	59,54 ± 15,80	45,40 ± 12,99	74,25 ± 12,24	78,27 ± 4,95	30
Hartmann et. al. [6]	85,51 ± 7,68	63,14 ± 12,46	42,31 ± 15,88	70,62 ± 17,95	81,89 ± 6,84	14

Hartmann et. al. [6] obtuvieron resultados con distintas bases de datos, por eso aparece dos veces en la tabla.

En las tablas 4.3 y 4.4 también se presentan los resultados de Machado et. al [11] y de Hartmann et. al. [6], respectivamente. Compararse con estos resultados tiene un alcance limitado, debido a que utilizan otra base de dato, la forma en que marcan los tipos de fase A es segundo a segundo, y además, utilizan validación cruzada al momento de evaluar sus sistemas.

4.1.3. Sistema de detección automático de CAP (módulo 4)

La tabla 3.11 muestra que aproximadamente el 10% de las fases A marcadas por el experto, en el conjunto de prueba, no corresponden a fases A contenidas en CAP. Como estas fases A no cumplen con los requisitos para pertenecer a CAP, no se consideraron en la evaluación del sistema de detección de CAP.

Para evaluar la sensibilidad y especificidad del sistema en distintos puntos de operación se crearon curvas ROC. La figura 4.5 contiene dos curvas ROC, las que fueron creadas a partir de los resultados de la detección de CAP para los registros de sueño completos, utilizando distintos valores del parámetro α_5 (Anexos B, tablas B.7 y B.8). De las curvas ROC se desprende que para valores altos del parámetro α_5 se obtienen resultados con alta sensibilidad, pero baja especificidad. Llegando a un máximo de sensibilidad para un valor de α_5 igual a 1,6 y para valores superiores la sensibilidad comienza a decrecer. Esto ocurre debido a que un valor alto de α_5 favorece la detección de fases A y disminuye la detección de fases B, provocando un aumento en los falsos positivos y una baja en los falsos negativos de fases A. Con mayor detección de fases A aumenta la detección de CAP, por lo que aumenta la sensibilidad para CAP. Y viceversa, valores pequeños de α_5 favorecen la detección de fases B, aumentando la especificidad de detección de CAP.

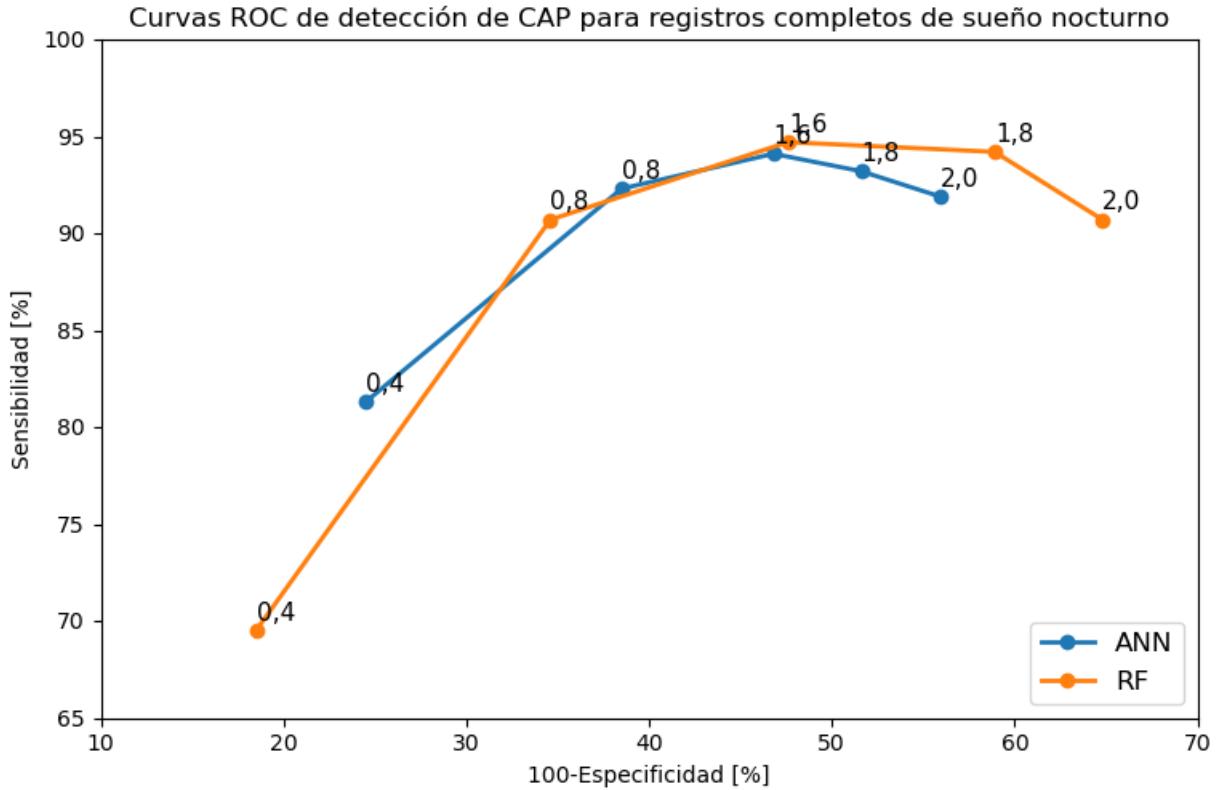


Figura 4.5: Curvas ROC del sistema de detección de CAP propuesto aplicado sobre registros completos de sueño nocturno. Las curvas se obtuvieron utilizando distintos valores del parámetro α_5 (valor asociado a cada punto) y aplicando clasificadores basados en ANN y RF (dos curvas).

La figura 4.6 presenta dos curvas ROC, las que fueron creadas a partir de los resultados de la detección de CAP sólo en los segmentos de registros en estado de sueño NREM, utilizando distintos valores del parámetro α_5 (Anexos B, tablas B.9 y B.10).

Al comparar la figura 4.6 con la figura 4.5, se ve que no hay grandes cambios en la sensibilidad, pero si en especificidad. La especificidad incrementa principalmente para valores altos del parámetro α_5 . Este aumento en la especificidad se traduce como una mejor detección de las zonas del EEG en que no hay CAP. En ambas figuras, también se observa una disminución en la sensibilidad para valores de α_5 superiores a 1,6, esta disminución hace que el sistema baje la detección de zonas donde hay presencia de CAP.

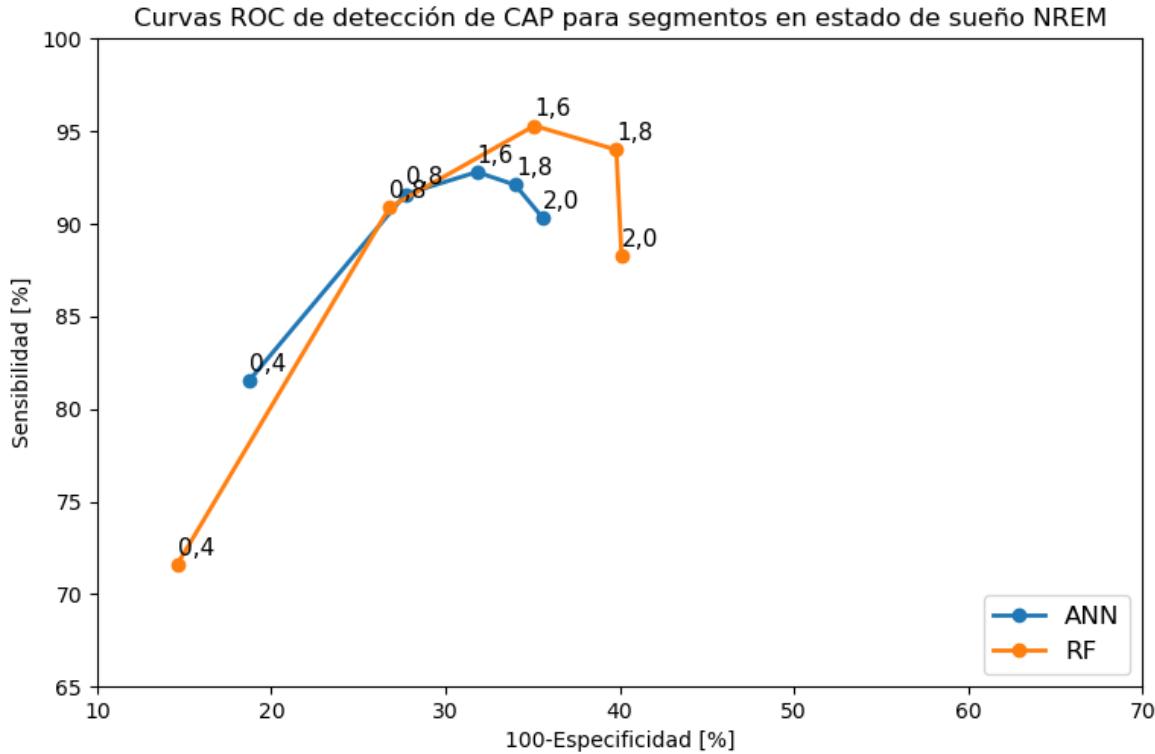


Figura 4.6: Curvas ROC del sistema de detección de CAP propuesto aplicado sobre segmentos del EEG en estado de sueño NREM. Las curvas se obtuvieron utilizando distintos valores del parámetro α_5 (valor asociado a cada punto) y aplicando clasificadores basados en ANN y RF (dos curvas).

De acuerdo a las curvas ROC de la figura 4.5, para los clasificadores basados en ANN se obtiene la máxima sensibilidad de 94,1 % con $\alpha_5=1,6$, y con una especificidad de 53,2 %. Eso quiere decir que, aproximadamente, mientras uno de cada 20 CAP no son detectados, poco menos de la mitad de los detectados son falsos (este análisis también aplica para clasificadores basados en RF, ya que los resultados son semejante a los de clasificadores basados en ANN). Eso es un desafío para mejorar. Algunas observaciones al respecto son:

1. A partir de la variación del parámetro α_5 , se ve que al obtener valores de especificidad y sensibilidad cercanos entre sí, en la detección automática de fases A, no se asegura que la especificidad y sensibilidad, de la detección automática de CAP, tengan valores similares. De hecho, cuando la especificidad y sensibilidad de la detección automática de fases A es similar entre sí, la detección automática de CAP tiene una baja especificidad y alta sensibilidad.
2. La diferencia de resultados en la detección de CAP en registros completos versus sólo segmentos de registros en estados NREM hace prever que mejorar el módulo 1 resultaría beneficioso, debido a que acotaría mejor las zonas de búsqueda de fases A.

No se encontraron trabajos que realicen detección automática de CAP en la revisión bibliográfica.

Capítulo 5

Conclusiones

El trabajo realizado en esta memoria consistió en desarrollar un sistema de detección automática de CAP. Para ello el sistema primero detecta los tramos de EEG compatibles con el estado de sueño NREM, luego busca eventos de fases A en esos tramos, y luego los asocia para definir la presencia de CAP. Además analiza las características de las fases A para identificar su tipo.

5.1. Detección de fases A

El sistema de detección de fases A tuvo un buen desempeño, lo que es atribuible a varios factores. En primer lugar, el uso conjunto de la FFT y el método de Welch permite tener una referencia de contexto dinámico de las variables de frecuencia. El uso de múltiples canales también contribuyó a una buena detección de fases A, ya que al combinar los canales se logró una detección más precisa.

Los resultados presentados en las curvas ROC, figuras 4.3 y 4.4, permiten observar el desempeño del sistema propuesto. Los resultados obtenidos parecen estar dentro de los mejores resultados de la literatura, tanto para los registros completos de sueño como para los segmentos de registros de sueño en estado NREM. Sin embargo, hay que considerar que las bases de datos no son las mismas, por lo que una comparación justa no es estrictamente posible.

5.2. Identificación del tipo de fase A

Para identificar una fase A es muy importante identificar las bandas de frecuencia predominantes en ella, ya que son la herramienta de diferenciación principal. La fase A2 presenta una de las mayores dificultades de identificación, al ser una mezcla de A1 y A3. Esto se sabía a partir del conocimiento experto y fue comprobado durante el entrenamiento del sistema de identificación del tipo de fase A. La baja sensibilidad en los tipos de fases A hace que este trabajo tenga poca aplicabilidad fuera del mundo de la investigación, por lo que sin dudas se deben realizar mejoras. Una de las mejoras que se puede hacer es incorporar información de otros canales del polisomnograma, por ejemplo, según conversaciones con expertos, existe información en los canales del electromiograma que puede ayudar a la identificación de las fases A2 y A3. Otra mejora puede ser incorporar información de las etapas del sueño, en base a la experiencia recopilada durante este trabajo, se identificó que las fases A1 tienen

una mayor presencia, respecto a fases A2 y A3, en etapa de sueño quieto profundo.

Los resultados de otros sistemas para identificar el tipo fase A publicados en la literatura también muestran una baja sensibilidad, como se muestra en las tablas 4.3 y 4.4.

Por otra parte, los otros trabajos, curiosamente, no identifican las fases A por tipo, sino que las segmentan por segundo, e identifican el tipo en forma aislada en cada segundo, lo que es útil como metodología de revisión y mejoramiento de un diseño, pero no es el resultado que esperan los expertos.

5.3. Sistema de detección automático de CAP

Los resultados de la detección automática de CAP, tanto para registros de sueño completo como segmentos de registros de sueño en estado NREM, pueden catalogarse como de baja especificidad y alta sensibilidad, útiles en el ámbito investigativo, pero poco aplicables a lo que los expertos buscan. Una forma de mejorar el detector automático de CAP es modificando el módulo 1, el cual no detecta correctamente los segmentos NREM, esto ayudaría a mejorar la especificidad de CAP. Una vez modificado el módulo 1, se puede pasar a revisar el módulo 2, el cual también provoca una baja especificidad en la detección de CAP.

5.4. Trabajo futuro

Se proponen los siguientes temas para explorar y mejorar el sistema:

1. Gran parte de los FP en la detección automática de fases A se da en etapa de sueño quieto profundo, por lo que se podría diseñar un tipo de detección especial para dicha etapa. Para ello se incorporaría un detector de etapa de sueño profundo y un diseño específico para el detector de fases A para esa etapa de sueño.
2. La brecha en los resultados del sistema aplicado sobre registros enteros versus segmentos sólo de sueño NREM de los registros indica que se pueden hacer mejoras en el módulo 1. Ello con el fin de reducir el ingreso de zonas con estado de sueño REM y zonas con vigilia al módulo 2, y con ello evitar las falsas detecciones que ello conlleva. Considerando que no queden segmentos NREM afuera.
3. Las características utilizadas en la detección de fases A son sólo frecuenciales. Se podría estudiar si existen características temporales que ayuden en la detección de fases A.
4. Con el fin de aumentar el tamaño del conjunto de entrenamiento, se podría aplicar un sobre muestreo de las clases más pequeñas, de tal forma de aumentar la base de datos en forma equilibrada y no disminuirla, como sucede con el submuestreo actual. Esto tendría la ventaja de aumentar la diversidad de muestras de las clases más grandes.
5. Una forma de mejorar el detector de fases A y el identificador del tipo de fase A es utilizar una nueva función de error en los clasificadores, dando mayor importancia a las clases más pequeñas.
6. Podría cambiarse la regla de decisión 2.5, la cual refiere sobre como decidir si una ventana es catalogada como A o B. Para ello se puede incorporar mayor cantidad de canales y/o incorporar pesos y/o grados de pertenencia difusos asociados a los canales.

7. En las zonas de sueño quieto profundo las fases A son principalmente del tipo A1. Esta información podría ser incorporada en el algoritmo de identificación del tipo de fase A, dando un mayor peso a dicha opción
8. Sería interesante aplicar el sistema propuesto a registros de sueños distintos a los ya utilizados. Esto permitiría ampliar la evaluación de la robustez y la capacidad de generalización del sistema propuesto. También sería de interés poder compararse con otros trabajos utilizando la misma base de datos.

Bibliografía

- [1] C. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [2] L. Breiman. *Random Forests*. Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
- [3] L. Causa. and C. Held. *Detección automática y caracterización de patrones de husos sigma en registros polisomnográficos de niños*. Tesis para optar a los grado de magíster en ciencias de la ingeniería mención ingeniería biomédica y al título de ingeniero civil electricista, Departamento de Ingeniería Eléctrica, Universidad de Chile, 2012.
- [4] Y. Freund and R. Schapire. *A decision-theoretic generalization of on-line learning and an application to boosting*. Journal of Computer and System Sciences., vol. 55, pp. 119-139, 1997.
- [5] P. Halász, M. G. Terzano, L Parrino, and R. Bódizs. *The nature of arousal in sleep*. J. Sleep Res., vol. 13, pp. 1-23, 2004.
- [6] S. Hartmann and M. Baumert. *Automatic A-Phase Detection of Cyclic Alternating Patterns in Sleep Using Dynamic Temporal Information*. IEEE Transactions on Neural System and Rehabilitation Engineering, vol. 27, no. 9, pp. 1695-1703., 2019.
- [7] C. Held, J. Heiss, P. Estevez, C. Perez, M. Garrido, C. Algarin, and P. Peirano. *Extracting Fuzzy Rules From Polysomnographic Recordings for Infant Sleep Classification*. IEEE Transactions On Biomedical Engineering, vol. 53, no. 10, pp. 1954-1962., 2006.
- [8] C. Iber, S. Ancoli-Israel, A. Chesson, and S. Quan. *The AASM manual for the scoring of sleep and associated events American Academy of Sleep Medicine*. American Academy of Sleep Medicine., pp. 48-9, Westchester, IL, USA, 2007.
- [9] H.H. Jasper. *The ten-twenty electrode system of the international federation*. Electroencephalography and Clinical Neurophysiology, vol. 10, pp. 371-375., 1958.
- [10] F. Machado, F. Sales, C. Bento, A. Dourado, and C. Teixeira. *Automatic identification of Cyclic Alternating Pattern (CAP) sequences based on the Teager Energy Operator*. 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), 2015.
- [11] F. Machado, F. Sales, C. Santos, A. Dourado, and C. A. Teixeira. *A knowledge discovery methodology from EEG data for cyclic alternating pattern detection*. BioMed. Eng. Online, vol. 17, no. 1, art. no. 185, 2018.
- [12] S. Mariani, A. Bianchi, E. Manfredini, V. Rosso, M. Mendez, L. Parrino, M. Matteucci, A. Grassi, S. Cerutti, and M.G. Terzano. *Automatic detection of A phases of the Cyclic Alternating Pattern during sleep*. 32nd Annual International Conference of the IEEE EMBS, 2010.

- [13] S. Mariani, A. Grassi, M. Mendez, L. Parrino, M.G. Terzano, and A. Bianchi. *Automatic detection of CAP on central and fronto-central EEG leads via Support Vector Machines*. 33rd Annual International Conference of the IEEE EMBS, 2011.
- [14] S. Mariani, E. Manfredini, V. Rosso, A. Grassi, M. Mendez, A. Alba, M. Matteucci, L. Parrino, M.G. Terzano, S. Cerutti, and A. Bianchi. *Efficient automatic classifiers for the detection of A phases of the cyclic alternating pattern in sleep*. Med. Biol. Eng. Comput., vol. 50, no. 4, pp. 359–372, 2012.
- [15] S. Mariani, A. Grassi, M. Mendez, G. Milioli, L. Parrino, M.G. Terzano, and A. Bianchi. *EEG segmentation for improving automatic CAP detection*. Clin. Neurophysiol., vol. 124, no. 9, pp. 1815–1823, 2013.
- [16] M. O. Mendez, A. Alba, I. Chouvarda, G. Milioli, A. Grassi, M. G. Terzano, and L. Parrino. *On Separability of A-Phases during the Cyclic Alternating Pattern*. 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society, Chicago, IL, USA, 2014.
- [17] F. Mendoza, A. Fred, S. Mostafa, F. Morgado-Dias, and A. Ravelo-García. *Automatic Detection of a Phases for CAP Classification*. 7th International Conference on Pattern Recognition Application and Methods, pp. 394-400., 2018.
- [18] H. Niknazar, S. Seifour, M. Mikaili, A. M. Nasrabadi, and A. Khorrami. *A Novel Method to Detect the A Phases of Cyclic Alternating Pattern (CAP) Using Similarity Index*. 23rd Iranian Conference on Electrical Engineering (ICEE), Tehran, Irán, 2015.
- [19] A. Orellana. *Árboles de decisión y Random Forest*. Universidad de Cuenca, 2018.
- [20] A. Rechtschaffeb and A. Kales. *A manual of standardized terminology, techniques and scoring system for sleep stages of human subjects*. UCLA, Brain Research Institute/Brain Information Service, Los Angeles, CA, USA, 1968.
- [21] A. Rosa, G. R. Alves, M. Brito, M. C. Lopes, and S. Tufik. *Visual and automatic cyclic alternating pattern (CAP) scoring: Inter-rater reliability study*. Arq. Neuropsiquiatr., vol. 64, 2006.
- [22] F. Rosenblatt. *The perceptron: A probabilistic model for information storage and organization in the brain*. Psychological review, vol. 16, no. 6, pp. 386-408, 1958.
- [23] J. Sammon. *A nonlinear mapping for data structure analysis*. IEEE Transactions on Computers, vol. 18, pp. 401-409., 1969.
- [24] S. Shanawaz, F. Mendoza, A. Ravelo-García, and F. Morgado-Dias. *Combination of Deep and Shallow Networks for Cyclic Alternating Patterns Detection*. 13th APICA International Conference on Automatic Control and Soft Computing (CONTROLO), 2018.
- [25] SWS Soft. *HypnoLab for Visual and Automatic Analysis of Polygraphic Sleep Recordings*. 2006.
- [26] M. G. Terzano, L. Parrino, A. Smerieri, R. Chervin, S. Chokroverty, C. Guilleminault, M. Hirshkowitz, M. Mahowald, H. Moldofsky, A. Rosa, R. Thomas, and A. Walters. *Consensus report. Atlas, rules, and recording techniques for the scoring of cyclic alternating pattern (CAP) in human sleep*. Sleep Med., vol. 3, pp. 187-199, 2001.

- [27] G. Tononi and C. Cirelli. *Sleep function and synaptic homeostasis*. Sleep Med. Rev., vol. 10, no. 1, pp. 49-62, 2006.
- [28] M. P. Walker and R. Stickgold. *Sleep, memory, and plasticity*. Annual Review of Psychology, vol. 57, no. 1, pp. 139-166, 2006.
- [29] P. Welch. *The use of Fast Fourier Transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms*. IEEE Transactions on Audio and Electroacoustics, vol. 15, pp. 70-73., 1967.

Anexo A

Base de datos

Tabla A.1: Definición de los conjuntos de entrenamiento, validación y prueba. Cada registro tiene un número asociado.

Entrenamiento		Validación		Prueba	
Registro	Etiqueta	Registro	Etiqueta	Registro	Etiqueta
1	ADTO10A1885	10	CASO10A10054	4	BATO10A7534
2	ALCO10A6853	20	DAMO10A7584	5	BECU10A3140
3	BALE10A10478	25	ERBE10A7610	9	CASA10A10000
6	BRRU10A7566	28	FRAC10A7246	11	CAVI10A7181
7	CACA10A10065	36	JOSA10A3050	12	CEVA10A6884
8	CAMO10A7589	45	SEYA10A10500	13	COBA10A2761
16	CRCA10A10337			14	CORI10A1178
18	CRES10A10460			15	COUR10A2151
21	DASE10A10515			17	CRCA10A7535
22	DEMA10A948			19	DAHE10A7447
24	ELGU10A7422			23	EDCA10A2051
26	ESAC10A3630			27	ESGA10A2952
20	GIMO10A2597			32	JOCI10A6129
30	HEVI10A6879			33	JOLA10A7631
31	JETA10A7034			34	JOOR10A10254
35	JOPE10A3720			40	MABA10A2333
37	JUVE10A3608			41	MABU10A6839
38	LILU10A7539			43	MIVA10A3463
39	LUVA10A9355			47	TAOR10A7626
42	MARA10A1969			48	VICA10AS7604
44	PASE10A6448				
46	TABR10A10156				

Tabla A.2: Cantidad y tipo de fases A en los registros del conjunto de entrenamiento marcadas por experto.

Nº Registro	Cantidad de fases		
	A1	A2	A3
1	253	88	151
2	250	40	72
3	256	78	55
6	74	15	22
7	201	55	79
8	182	51	80
16	315	57	70
18	375	85	80
21	518	36	31
22	213	125	84
24	279	25	34
26	177	41	47
29	150	23	81
30	248	28	51
31	492	43	46
35	524	88	71
37	331	71	68
38	107	47	18
39	210	72	82
42	289	37	47
44	100	51	101
46	358	73	89
Total	5902	1229	1459

Tabla A.3: Cantidad y tipo de fases A en los registros del conjunto de validación marcadas por experto.

Nº Registro	Cantidad de fases		
	A1	A2	A3
10	187	42	122
20	160	109	162
25	209	93	147
28	368	90	61
36	256	48	2
45	239	15	40
Total	1419	397	534

Tabla A.4: Cantidad de fases A en los registros del conjunto de entrenamiento marcadas por un experto y cantidad de estas fases que no están contenidas en CAP.

Nº Registro	Total de fases A	Fases A no contenidas en CAP
1	492	29
2	362	45
3	389	33
6	111	22
7	335	32
8	313	80
16	442	43
18	540	48
21	585	25
22	422	27
24	338	25
26	265	54
29	254	61
30	327	63
31	581	29
35	683	39
37	470	43
38	172	31
39	364	26
42	373	55
44	252	49
46	520	49
Total	8590	908

Tabla A.5: Cantidad de fases A en los registros del conjunto de validación marcadas por un experto y cantidad de estas fases que no están contenidas en CAP.

Nº Registro	Total de fases A	Fases A no contenidas en CAP
10	351	66
20	431	49
25	449	62
28	519	40
36	306	55
45	294	70
Total	2350	342

Anexo B

Resultados

Las tablas B.1 y B.2 presentan los resultados de la detección automática de fases A aplicados sobre registros completos de sueño, para clasificadores basados en ANN y RF, respectivamente. Ambas tablas, presentan resultados para distintos valores del parámetro α_5 .

Tabla B.1: Resultados del conjunto de prueba para la detección de fases A, considerando la totalidad del registro de sueño y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	94,5 87,0 80,6 76,8 72,0	50,9 68,6 77,2 79,0 82,4	91,2 85,6 80,3 77,0 72,8
5	95,1 89,4 83,4 80,3 75,7	53,2 68,0 75,8 79,4 83,8	91,4 87,4 82,7 80,2 76,5
9	92,9 87,5 79,9 76,9 75,7	47,8 64,0 71,4 73,2 74,3	89,2 85,6 79,2 76,6 75,6
11	94,3 89,2 84,3 81,7 77,5	62,0 74,5 81,6 84,5 86,4	92,2 88,2 84,1 81,9 78,1
12	94,1 87,8 81,1 78,2 72,7	55,8 71,2 79,0 81,5 81,9	91,1 86,5 81,0 78,5 73,4
13	93,1 87,2 82,4 79,3 74,5	55,2 69,5 76,5 79,9 82,5	90,0 85,7 81,9 79,4 75,2
14	95,2 89,8 84,5 81,6 75,7	47,5 62,1 70,9 73,5 78,6	92,6 88,3 83,8 81,1 75,9
15	95,6 91,3 86,8 83,9 78,0	51,6 64,4 72,7 75,8 79,3	93,4 90,0 86,1 83,5 78,1
17	94,0 87,8 81,6 78,8 74,8	62,6 75,2 81,9 83,6 86,7	91,2 86,6 81,6 79,3 75,8
19	93,4 88,2 82,9 79,7 74,3	55,9 69,6 78,9 81,6 85,5	90,4 86,7 82,6 79,9 75,3
23	90,9 82,3 77,0 75,0 74,2	61,1 76,0 84,2 86,7 89,2	88,1 81,7 77,7 76,1 75,6
27	92,7 84,1 77,1 75,4 73,5	61,4 74,9 80,8 81,9 83,8	90,6 83,5 77,3 75,8 74,2
32	94,4 87,7 81,2 78,4 73,7	41,0 53,8 62,1 64,9 68,3	87,3 83,2 78,7 76,6 73,0
33	95,7 90,2 84,0 81,1 77,1	53,3 68,3 76,8 80,3 82,7	92,1 88,3 83,4 81,0 77,6
34	93,5 87,2 80,8 77,7 73,8	61,6 73,5 81,1 83,4 86,6	90,6 85,9 80,8 78,2 75,0
40	94,0 88,2 81,6 78,6 73,9	57,4 72,1 81,2 84,2 86,3	91,0 86,8 81,5 79,1 74,9
41	94,4 87,4 80,2 77,2 73,2	57,0 71,8 79,5 82,2 84,1	91,5 86,2 80,1 77,6 74,1
43	92,9 86,8 80,3 77,4 73,1	52,2 63,2 69,6 72,0 75,9	89,7 85,0 79,5 77,0 73,4
47	93,9 87,2 79,8 76,4 72,1	49,9 68,6 78,6 81,9 86,9	90,9 85,9 79,8 76,8 73,1
48	95,7 89,7 83,5 80,3 74,9	51,1 67,8 76,6 79,3 82,3	93,0 88,4 83,1 80,2 75,3
Total	94,0 87,8 81,6 78,7 74,7	54,4 68,9 76,8 79,4 82,4	90,9 86,3 81,3 78,8 75,1

Tabla B.2: Resultados del conjunto de prueba para la detección de fases A, considerando la totalidad del registro de sueño y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetro α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	96,4 89,7 83,2 77,2 72,0	44,1 63,0 73,3 77,7 81,9	92,4 87,7 82,4 77,3 72,8
5	97,0 92,3 87,0 81,6 76,2	44,1 61,6 71,3 77,7 82,4	92,2 89,6 85,6 81,3 76,8
9	96,4 91,7 86,9 82,4 77,4	39,7 57,4 65,9 71,5 76,5	91,8 88,9 85,2 81,5 77,3
11	95,5 90,0 84,7 79,8 74,9	54,7 69,4 77,4 81,4 85,6	92,9 88,6 84,3 79,9 75,6
12	96,0 90,0 82,9 76,7 69,7	43,3 63,5 74,4 79,5 83,9	91,9 88,0 82,3 76,9 70,8
13	95,5 89,7 83,7 78,1 72,9	45,7 64,2 73,6 78,7 82,9	91,3 87,5 82,9 78,1 73,7
14	96,5 91,2 85,4 79,1 73,1	40,5 59,3 69,5 77,0 80,7	93,5 89,4 84,6 79,0 73,5
15	96,4 90,3 83,8 77,2 70,5	44,1 62,0 72,3 76,4 80,2	93,8 89,0 83,2 77,2 70,9
17	96,5 92,0 87,3 81,9 77,7	52,3 68,1 75,8 80,6 84,0	92,5 89,8 86,2 81,8 78,3
19	95,3 89,1 82,7 76,9 70,5	49,2 67,0 76,8 83,2 87,2	91,6 87,3 82,3 77,4 71,8
23	96,4 90,7 84,0 77,1 71,2	48,2 66,3 75,6 81,9 85,5	91,9 88,4 83,2 77,6 72,5
27	96,7 92,4 87,7 82,8 78,3	48,7 66,4 73,0 77,4 80,3	93,3 90,6 86,7 82,4 78,4
32	96,4 90,7 85,2 79,1 74,1	33,6 48,0 57,5 63,7 69,0	88,1 85,1 81,5 77,1 73,4
33	96,9 92,1 86,6 80,3 74,8	47,2 64,3 74,8 80,0 83,5	92,6 89,7 85,6 80,3 75,6
34	95,4 89,6 84,2 78,7 74,1	55,1 70,0 76,6 82,5 85,6	91,7 87,8 83,5 79,1 75,2
40	95,7 89,4 83,1 77,2 71,8	48,7 67,7 76,1 82,8 86,7	91,9 87,6 82,5 77,7 73,0
41	96,2 89,3 81,9 75,0 68,2	45,4 66,8 77,0 82,3 86,2	92,2 87,5 81,5 75,5 69,6
43	95,3 88,9 82,6 76,3 71,0	45,5 61,7 69,0 73,7 77,3	91,4 86,7 81,6 76,1 71,5
47	96,6 90,8 84,3 78,0 72,3	39,0 59,4 72,5 80,3 84,4	92,7 88,6 83,5 78,1 73,2
48	97,2 92,3 86,2 80,2 74,5	41,0 60,3 70,9 78,0 81,2	93,8 90,3 85,3 80,1 75,0
Total	96,2 90,6 84,7 78,8 73,3	45,5 63,3 72,7 78,3 82,2	92,2 88,4 83,7 78,7 73,9

Las tablas B.3 y B.4 presentan los resultados de la detección automática de fases A aplicados sobre segmentos del EEG en estado de sueño NREM, para clasificadores basados en ANN y RF, respectivamente. Ambas tablas, presentan resultados para distintos valores del parámetro α_5 .

Tabla B.3: Resultados del conjunto de prueba para la detección de fases A, considerando segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	96,9 92,6 88,4 86,3 83,3	50,5 70,5 77,5 79,9 83,7	93,4 90,9 87,6 85,8 83,3
5	97,6 93,7 89,6 87,3 84,1	54,3 69,2 77,6 80,3 83,8	93,7 91,5 88,5 86,7 84,0
9	96,8 92,3 87,4 85,0 83,0	48,7 64,5 72,7 74,7 76,4	92,8 90,1 86,2 84,1 82,4
11	95,2 91,2 87,0 84,8 81,7	61,0 74,5 81,6 84,0 86,1	93,0 90,1 86,6 84,8 82,0
12	96,0 91,2 86,3 84,3 80,6	55,0 70,7 78,5 80,8 81,1	92,8 89,6 85,7 84,0 80,7
13	95,3 91,8 88,2 86,4 83,3	57,1 69,9 76,9 80,3 83,2	92,1 90,0 87,3 85,9 83,3
14	96,1 92,3 88,2 86,1 82,4	49,5 63,7 73,6 77,6 82,6	93,6 90,8 87,4 85,6 82,4
15	96,6 93,5 90,0 88,4 84,1	54,5 69,6 76,6 79,9 84,3	94,5 92,4 89,3 88,0 84,1
17	97,0 93,5 90,1 88,7 86,4	62,2 75,9 82,5 84,4 86,9	93,8 91,9 89,4 88,3 86,5
19	95,4 91,5 87,8 85,7 81,8	55,6 70,3 78,1 80,6 86,3	92,1 89,8 87,0 85,2 82,2
23	92,7 86,1 82,9 82,3 82,0	62,0 76,3 85,4 87,3 89,9	89,8 85,2 83,1 82,8 82,7
27	94,5 87,6 82,3 80,4 79,9	61,7 75,7 80,2 83,1 84,3	92,2 86,7 82,2 80,6 80,2
32	96,8 93,9 91,2 89,8 87,6	39,6 51,8 61,1 64,5 68,4	89,2 88,3 87,2 86,5 85,1
33	96,0 90,8 85,4 83,1 79,6	53,9 67,9 76,1 80,2 83,8	92,4 88,9 84,6 82,8 79,9
34	96,1 91,8 87,7 85,6 82,6	61,5 73,0 82,0 84,1 86,5	93,0 90,1 87,2 85,5 82,9
40	96,4 92,5 88,2 86,4 83,4	56,5 72,3 81,7 84,0 85,7	93,1 90,9 87,7 86,2 83,6
41	96,5 91,4 86,7 84,7 81,5	58,3 72,8 79,4 82,4 84,6	93,6 89,9 86,1 84,6 81,8
43	95,0 91,1 87,0 85,3 81,8	51,7 63,2 70,2 72,5 77,0	91,6 88,9 85,7 84,3 81,4
47	96,3 91,5 86,1 83,5 80,2	51,2 70,1 80,5 83,2 87,6	93,2 90,0 85,7 83,5 80,7
48	97,5 94,2 90,3 88,6 85,9	49,7 66,9 75,7 78,1 81,3	94,6 92,5 89,4 87,9 85,6
Total	96,0 91,7 87,5 85,6 82,8	54,7 69,4 77,4 80,1 83,2	92,7 89,9 86,7 85,2 82,7

Tabla B.4: Resultados del conjunto de prueba para la detección de fases A, considerando segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	97,5 93,8 89,7 85,8 82,0	45,0 65,1 74,6 79,8 82,9	93,5 91,6 88,6 85,4 82,1
5	98,6 95,6 92,0 88,0 84,1	44,4 62,0 70,3 78,0 83,3	93,7 92,5 90,1 87,1 84,1
9	98,0 94,9 91,5 88,1 84,5	41,0 57,9 66,5 73,9 77,9	93,4 91,9 89,5 87,0 84,0
11	96,4 91,8 87,7 83,5 79,3	55,2 70,0 77,4 82,0 86,5	93,7 90,4 87,0 83,4 79,8
12	97,4 93,4 88,4 84,0 79,0	42,4 62,6 73,9 79,0 82,9	93,1 91,0 87,3 83,6 79,3
13	97,1 93,0 88,9 85,5 81,3	44,9 66,6 74,6 80,0 83,7	92,7 90,8 87,7 85,0 81,5
14	97,2 93,1 88,8 84,4 79,8	41,2 61,7 72,1 78,9 83,3	94,1 91,4 87,9 84,1 80,0
15	97,1 92,8 88,1 83,3 78,6	47,7 65,8 75,2 82,4 85,4	94,7 91,5 87,4 83,2 78,9
17	98,2 95,5 92,8 89,9 87,7	52,6 68,5 75,9 81,2 84,1	94,0 93,0 91,2 89,1 87,3
19	96,7 92,1 87,7 83,0 78,5	49,1 65,9 76,5 83,3 87,7	92,8 90,0 86,8 83,0 79,3
23	97,6 93,5 89,1 84,4 80,6	48,7 67,1 76,0 82,5 85,7	93,0 91,0 87,9 84,2 81,1
27	97,9 94,5 90,8 86,6 83,2	48,7 65,7 73,0 77,9 80,5	94,5 92,5 89,6 86,0 83,0
32	97,9 94,8 92,3 89,4 86,8	32,9 47,1 56,4 63,1 68,0	89,3 88,5 87,5 85,9 84,3
33	97,1 92,8 88,2 83,3 78,7	47,8 64,8 75,5 81,2 84,9	92,9 90,4 87,1 83,1 79,2
34	97,1 93,3 89,6 86,2 82,9	55,6 70,1 78,1 82,5 85,6	93,3 91,2 88,5 85,8 83,2
40	97,7 93,7 89,6 85,8 82,4	49,4 67,7 77,2 82,8 86,4	93,7 91,6 88,6 85,6 82,7
41	97,5 92,9 88,2 83,6 78,5	45,8 67,7 77,6 82,9 86,0	93,5 90,9 87,4 83,6 79,1
43	96,4 91,9 88,3 84,3 80,4	46,1 61,3 69,5 75,0 78,1	92,5 89,5 86,8 83,6 80,2
47	98,1 93,7 88,9 84,4 80,2	38,7 62,5 74,9 81,6 85,1	94,0 91,6 87,9 84,3 80,6
48	98,5 95,5 92,1 88,5 85,1	41,4 61,1 70,6 76,8 80,5	95,0 93,4 90,8 87,8 84,8
Total	97,5 93,6 89,6 85,6 81,7	45,9 64,1 73,3 79,2 82,9	93,4 91,2 88,3 85,0 81,7

Las tablas B.5 y B.6 presentan los resultados de la identificación del tipo de fase A aplicados sobre registros completos y sobre segmentos del EEG en estado de sueño NREM, respectivamente. Ambas tablas, presentan resultados para distintos valores del parámetro α_5 .

Tabla B.5: Resultados totales del conjunto de prueba para la identificación del tipo de fase A, considerando registros de sueño completos.

Parámetro α_5	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud global (%)
0,4	93,4	43,1	29,1	24,8	88,5
0,8	86,8	52,3	33,8	37,7	83,4
1,2	80,3	57,8	39,2	45,5	77,6
1,6	77,3	56,5	43,6	45,1	75,1
2,0	72,7	59,3	46,8	51,9	71,5

Tabla B.6: Resultados totales del conjunto de prueba para la identificación del tipo de fase A, considerando segmentos de registros de sueño en estado NREM.

Parámetro α_5	Sensibilidad B (%)	Sensibilidad A1 (%)	Sensibilidad A2 (%)	Sensibilidad A3 (%)	Exactitud global (%)
0,4	95,9	43,2	27,5	26,4	90,7
0,8	91,1	50,9	37,8	38,5	87,3
1,2	86,7	55,5	42,9	47,1	83,3
1,6	84,6	56,8	44,4	46,4	82,0
2,0	81,2	57,6	50,5	51,3	79,2

Las tablas B.7 y B.8 presentan los resultados de la detección automática de CAP aplicados sobre registros completos de sueño, para clasificadores basados en ANN y RF, respectivamente. Ambas tablas, presentan resultados para distintos valores del parámetro α_5 .

Tabla B.7: Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	80,6 59,9 52,8 45,7 43,0	77,3 92,1 93,9 95,1 93,2	79,5 70,6 66,4 62,0 59,6
5	75,1 65,1 63,7 59,1 54,2	89,8 94,1 88,9 88,0 84,1	80,1 74,9 72,2 68,8 64,3
9	69,9 62,6 55,3 52,6 56,9	76,3 93,8 96,4 94,4 90,0	71,7 71,2 66,7 64,1 66,1
11	69,7 55,9 45,1 42,5 36,9	87,5 94,6 95,9 97,1 97,8	73,1 63,4 54,9 53,1 48,7
12	76,5 58,4 52,6 50,2 44,6	81,1 94,1 98,0 95,2 90,2	77,5 66,5 62,9 60,4 55,0
13	79,2 64,1 49,1 40,5 33,0	71,7 90,0 94,4 96,1 97,0	76,9 72,1 63,0 57,6 52,7
14	88,0 82,2 71,1 65,4 59,2	64,9 83,3 90,2 92,9 94,7	82,8 82,4 75,4 71,6 67,2
15	94,1 83,5 72,7 63,6 53,0	73,4 85,5 94,2 95,7 95,7	91,3 83,8 75,7 68,0 59,0
17	75,2 61,8 56,9 49,3 44,9	94,6 98,9 98,1 95,2 93,5	81,7 74,2 70,7 64,7 61,1
19	73,3 56,2 47,2 41,6 36,4	77,5 93,3 96,1 97,7 98,5	74,3 65,4 59,3 55,5 51,7
23	79,0 70,2 60,0 54,8 49,8	91,3 94,7 93,2 91,4 90,1	82,8 77,8 70,4 66,3 62,4
27	67,7 59,4 53,5 51,2 50,4	81,6 84,1 80,6 76,9 73,8	71,1 65,4 60,2 57,5 56,1
32	67,0 50,1 37,7 33,1 28,5	91,2 99,4 99,4 99,4 99,1	74,6 65,5 57,1 53,9 50,6
33	77,7 61,3 53,3 48,6 44,2	86,2 95,4 93,8 86,8 84,9	80,7 73,3 67,6 62,0 58,5
34	66,7 48,2 45,8 40,9 41,7	85,1 95,1 98,2 98,2 97,9	73,9 66,5 66,2 63,3 63,6
40	70,8 56,5 45,9 47,7 42,1	80,0 93,2 95,4 87,7 87,3	74,3 70,3 64,5 62,8 59,2
41	78,8 59,9 54,7 48,3 41,1	80,3 92,1 93,6 93,4 91,3	79,3 70,7 67,7 63,4 58,0
43	67,8 51,5 39,9 33,2 25,2	74,6 90,5 94,2 96,9 100,0	69,4 61,0 53,1 48,6 43,4
47	72,3 54,5 47,5 41,4 43,3	82,0 94,0 94,3 92,4 86,7	75,3 66,6 61,9 57,1 56,6
48	81,1 69,1 59,0 57,5 54,1	78,9 88,4 93,5 94,2 92,2	80,6 73,2 66,3 65,3 62,2
Total	75,5 61,5 53,2 48,4 44,1	81,3 92,3 94,1 93,2 91,9	77,5 70,7 65,1 61,3 57,8

Tabla B.8: Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño completos y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	91,5 68,1 50,8 46,7 37,6	57,2 86,4 95,0 94,8 93,3	80,2 74,2 65,4 62,6 56,0
5	79,2 66,2 58,2 54,4 47,1	85,8 96,8 96,1 86,6 81,4	81,4 76,5 70,9 65,3 58,6
9	79,4 64,4 54,6 46,2 51,0	52,2 86,7 92,8 96,4 83,2	71,9 70,5 65,2 60,1 59,9
11	76,7 54,7 43,4 33,2 30,5	78,4 91,9 96,5 97,2 96,8	77,0 61,9 53,7 45,5 43,3
12	80,3 63,9 43,5 32,5 24,2	70,9 93,0 96,9 95,0 90,9	78,2 70,5 55,6 46,7 39,3
13	91,7 74,4 54,4 35,9 23,8	46,0 83,2 91,2 96,3 96,7	77,6 77,1 65,7 54,5 46,2
14	94,3 86,6 70,6 51,2 38,0	44,1 76,6 89,4 94,5 95,1	83,0 84,3 74,8 60,9 50,8
15	94,9 88,3 68,5 47,6 33,0	66,2 86,1 95,1 95,9 96,0	90,9 88,0 72,2 54,3 41,7
17	76,8 65,3 61,0 52,4 45,2	92,9 98,2 97,3 94,7 88,7	82,2 76,3 73,1 66,5 59,7
19	85,6 61,1 45,1 30,3 19,0	49,1 87,3 95,1 98,5 98,5	76,6 67,6 57,4 47,1 38,6
23	71,7 56,7 63,1 54,4 47,1	86,1 95,2 95,3 88,9 83,5	76,2 68,7 73,2 65,2 58,5
27	66,6 52,0 53,4 48,0 47,4	87,6 98,6 86,6 83,8 78,5	71,7 63,4 61,6 56,8 55,0
32	73,5 54,8 39,0 30,0 27,7	80,4 97,0 100,0 99,0 98,0	75,6 68,0 58,1 51,6 49,8
33	83,4 66,6 53,8 42,8 37,5	86,4 94,9 94,0 87,0 81,6	84,5 76,6 67,9 58,3 53,0
34	75,2 56,2 41,9 39,5 39,1	77,3 95,2 97,3 98,7 97,4	76,0 71,4 63,5 62,6 61,8
40	78,0 62,8 47,9 31,7 35,2	65,2 89,8 89,8 89,1 80,5	73,2 72,9 63,7 53,3 52,3
41	84,8 61,8 43,6 33,1 23,3	71,2 91,9 98,0 97,4 95,2	80,2 71,9 61,8 54,7 47,4
43	77,7 61,7 42,8 24,2 19,4	55,7 89,3 97,3 99,0 98,5	72,4 68,4 56,0 42,3 38,6
47	83,6 67,5 49,6 38,5 35,7	66,6 89,0 95,2 96,1 93,7	78,4 74,1 63,6 56,2 53,5
48	84,8 74,2 62,9 49,9 42,8	70,6 86,3 95,6 94,3 87,1	81,7 76,8 69,8 59,3 52,3
Total	81,5 65,4 52,4 41,1 35,2	69,5 90,7 94,7 94,2 90,7	78,4 73,0 64,7 56,2 50,8

Las tablas B.9 y B.10 presentan los resultados de la detección automática de CAP aplicados sobre segmentos del EEG en estado de sueño NREM, para clasificadores basados en ANN y RF, respectivamente. Ambas tablas, presentan resultados para distintos valores del parámetro α_5 .

Tabla B.9: Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño en segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en ANN. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	83,6 72,6 68,8 66,3 65,9	78,7 93,0 94,8 96,0 94,4	82,0 79,3 77,4 76,1 75,3
5	84,7 79,4 80,0 78,8 77,8	88,1 95,4 89,7 88,1 86,7	85,8 84,8 83,2 82,0 80,8
9	81,1 73,6 71,0 70,2 67,9	76,8 93,7 97,4 94,5 90,8	79,9 79,2 78,3 76,9 74,2
11	71,8 59,7 55,2 52,4 50,2	90,5 92,7 97,5 98,8 98,2	75,4 66,0 63,3 61,4 59,4
12	78,6 67,2 63,6 63,8 65,2	80,3 91,7 96,4 95,2 82,3	79,0 72,8 71,0 70,9 69,1
13	84,8 72,4 63,8 58,9 54,5	69,4 90,7 94,9 96,7 98,9	80,1 78,0 73,4 70,5 68,1
14	89,2 81,8 76,6 70,9 67,1	65,3 86,1 94,9 97,8 98,3	83,8 82,8 80,7 76,9 74,1
15	93,1 83,4 73,8 66,1 59,9	78,6 89,2 99,1 99,1 99,1	91,0 84,2 77,3 70,6 65,4
17	82,6 80,8 84,0 81,0 80,6	94,8 86,7 78,5 77,3 74,9	86,7 82,8 82,2 79,8 78,7
19	78,7 61,8 53,9 49,0 44,0	79,0 92,7 96,8 97,6 99,1	78,8 69,4 64,5 61,0 57,6
23	82,0 76,5 72,9 69,6 68,8	90,8 95,6 94,9 94,2 91,7	84,8 82,4 79,8 77,3 76,0
27	78,6 72,6 70,1 73,3 74,0	84,1 84,0 77,4 67,5 66,1	79,9 75,4 71,9 71,9 72,0
32	80,2 73,9 71,1 70,8 72,3	88,6 98,0 99,2 99,9 99,1	82,8 81,4 79,9 79,9 80,7
33	78,1 63,9 59,0 55,5 53,2	89,0 96,0 93,7 89,4 86,0	81,9 75,2 71,1 67,4 64,7
34	75,6 67,9 63,7 62,3 62,5	85,7 95,3 98,2 98,4 97,8	79,6 78,6 77,1 76,3 76,3
40	79,5 73,2 68,6 68,5 67,2	78,9 86,4 90,2 86,7 86,3	79,3 78,2 76,7 75,3 74,4
41	86,4 76,4 70,9 68,6 62,3	82,0 92,4 93,4 93,9 92,2	84,9 81,8 78,5 77,1 72,4
43	72,6 59,4 52,8 49,6 46,6	71,1 90,6 97,1 98,2 99,2	72,3 67,0 63,5 61,4 59,4
47	80,9 71,0 69,7 69,0 72,8	78,9 93,7 79,2 77,4 72,1	80,3 78,0 72,6 71,6 72,6
48	84,7 78,6 74,5 75,0 75,9	79,3 88,1 93,1 94,6 93,3	83,5 80,7 78,4 79,1 79,6
Total	81,3 72,3 68,2 66,0 64,4	81,5 91,6 92,8 92,1 90,3	81,6 77,9 75,0 73,2 71,5

Tabla B.10: Resultados del conjunto de prueba para la detección automática de CAP, considerando registros de sueño en segmentos del EEG en estado de sueño NREM y utilizando clasificadores basados en RF. Los resultados presentados consideran distintos valores del parámetros α_5 : (0,4 | 0,8 | 1,2 | 1,6 | 2)

Nº Registro	Especificidad (%)	Sensibilidad (%)	Exactitud (%)
4	91,9 76,4 68,3 64,1 62,9	58,1 87,2 95,8 97,0 98,0	80,7 80,0 77,4 74,9 74,5
5	86,2 78,2 73,1 74,2 72,5	85,7 96,0 98,4 87,1 80,4	86,0 84,2 81,6 78,5 75,2
9	87,8 77,9 70,1 63,3 57,9	56,7 86,0 94,1 98,6 99,8	79,2 80,1 76,7 73,0 69,4
11	78,6 59,5 52,7 45,2 42,8	80,8 93,2 97,9 100,0 100,0	79,1 66,0 61,4 55,8 53,8
12	83,8 69,0 53,6 55,2 57,4	68,1 91,7 96,6 88,2 82,3	80,3 74,2 63,4 62,7 63,0
13	92,7 80,4 64,4 55,4 48,1	53,4 82,2 97,4 98,6 98,6	80,6 80,9 74,6 68,7 63,6
14	91,4 85,4 70,7 58,1 52,9	44,8 80,0 93,6 98,4 98,7	80,9 84,2 75,8 67,1 63,2
15	94,4 83,9 66,0 52,2 45,3	71,2 90,9 98,9 99,1 99,1	91,2 84,8 70,5 58,7 52,8
17	84,6 77,4 80,6 78,8 79,5	92,8 98,9 79,2 76,5 73,5	87,3 84,6 80,1 78,0 77,5
19	87,8 67,7 51,1 40,2 43,4	52,7 85,3 95,4 100,0 93,4	79,1 72,0 62,0 54,9 55,7
23	73,9 62,5 70,5 69,5 68,0	86,7 96,9 96,4 93,5 88,0	77,9 73,3 78,6 77,0 74,2
27	74,5 64,8 71,2 71,3 71,2	88,5 93,9 86,2 77,2 70,7	77,9 71,9 74,9 72,7 71,0
32	85,2 77,0 70,6 68,7 75,5	79,4 95,8 99,2 99,0 73,1	83,4 82,9 79,6 78,2 74,8
33	84,3 67,9 53,4 51,7 51,7	88,4 95,7 97,1 91,1 83,6	85,8 77,7 68,7 65,5 62,9
34	81,1 71,0 65,5 62,9 65,2	80,7 93,6 97,4 98,3 85,0	80,9 79,8 78,0 76,7 72,9
40	84,0 74,1 67,0 64,2 65,1	71,6 84,2 90,8 88,9 82,7	79,3 77,9 75,9 73,5 71,7
41	89,2 75,0 61,8 55,6 55,4	73,6 93,6 97,6 96,5 93,6	84,0 81,2 73,8 69,3 68,2
43	80,6 64,2 49,5 43,6 42,1	60,3 91,0 97,4 98,7 99,8	75,7 70,7 61,1 56,9 56,1
47	88,4 73,5 63,7 58,8 70,1	68,4 91,0 96,4 96,4 76,4	82,2 78,9 73,8 70,3 72,0
48	86,9 79,2 74,4 70,4 70,3	70,1 90,8 99,6 96,8 89,0	83,4 81,6 79,8 76,0 74,3
Total	85,4 73,2 64,9 60,2 59,9	71,6 90,9 95,3 94,0 88,3	81,7 78,3 73,4 69,4 67,3