

Reporte de proyecto

Clasificación de patologías del sueño

Luis Juventino Velasquez Hidalgo

January 10, 2025

Abstract

En este trabajo se aborda el análisis de las etapas del sueño, con un enfoque en la fase NREM enfocado a analizar las fases A presentes en dicha etapa. El CAP es una métrica significativa que refleja la inestabilidad del sueño, siendo útil para evaluar tanto la calidad del sueño como los trastornos asociados a este. Dado que el análisis del CAP tradicionalmente requiere de un experto, se presenta un enfoque automatizado basado en el uso de algoritmos de aprendizaje no supervisado para la clasificación de estas fases. Con un accuracy del 0.68, este estudio propone una metodología para detectar y clasificar el CAP, demostrando que este patrón puede ser un indicador confiable de las patologías del sueño. Los resultados obtenidos no muestran una alta precisión en la clasificación de los registros, pero esto es ha sabiendas de que el algoritmo de detección de CAP tiene un F1-score de 0.63, lo que respalda la idea de que el CAP contiene información valiosa para el diagnóstico de estas patologías. Finalmente, se subraya la importancia de continuar con la investigación de métodos más eficientes para la clasificación automática del CAP.

Planteamiento

Las etapas del sueño comúnmente se dividen en 2 etapas, REM y NREM. Siendo la etapa NREM la más conocida por ser asociada al sueño profundo. Pero artículos exponen que la etapa NREM contiene información que describe la calidad del descanso a la hora de dormir. La etapa NREM se divide en fases A y B. Siendo la fase B la representante del ruido del fondo. En cambio, A se subdivide en A1, A2 y A3. Estas tres sub-etapas suelen estar asociados con microdespertares. Esto incentiva la teoría que hoy se conoce como Cyclic alternating pattern (CAP).

Dicho patrón solo se encuentra en la etapa NREM, siendo esta etapa la más dominante a la hora de dormir. Por lo que el estudio de dicha etapa proporciona información que puede ser interpretada como un promedio del sueño global.

El inconveniente con el CAP es que es tardado de analizar, ya que se necesita de un experto para poder interpretar los resultados. Por lo que es de gran interés el estudio de modelos que puedan clasificar y analizar dichas etapas de manera automática.

Justificación

En el artículo *Cyclic alternating pattern (CAP): The marker of sleep instability* [1] Terzano junto a otros expertos estudian y caracterizan al CAP como una métrica importante del sueño analizando su comportamiento en diferentes personas con trastornos del sueño. Concluyendo con la afirmación del título del artículo.

Los parametros que se buscan al estudiar el CAP

The main measures of CAP.

CAP time: the total duration of all CAP sequences

CAP rate: the percentage ratio of CAP time to total NREM sleep time

Phase A1 index: the number of phase A1 subtypes per hour of sleep

Phase A2 index: the number of phase A2 subtypes per hour of sleep

Phase A3 index: the number of phase A3 subtypes per hour of sleep

Figure 1: Principales características del CAP

son los que se pueden ver en la **figura 1**.

En el artículo [1] se demuestra que dichos estadísticos obtenidos a través del CAP son indicadores muy significativos y contienen información no solo de la calidad del sueño, sino también de los cambios biológicos del individuo. Las diferencias del CAP en niños y adultos es muy marcada pues cambia tanto la frecuencia de los eventos como la duración de los mismos.

Se ha observado que la importancia de la fase A radica en que representa un aumento en la actividad cerebral, lo que simula pequeños despertares, siendo en niños y adolescentes necesario el tener altas tasas de CAP para que las propiedades restauradoras del sueño sean efectivas. La **figura 2** muestra las diferencias entre las diferentes etapas del crecimiento.

Otro resultado interesante del artículo de Terzano[1] es que apunta a que hay suficiente evidencia para justificar que el aumento de la frecuencia del CAP en adultos se debe a factores externos provocados por estímulos sensoriales físicos o sueño conciliado bajo condiciones disruptivas del sueño. Estos últimos usualmente provocados por algún desorden del sueño como el síndrome de piernas inquietas, depresión, desorden de alimentación, entre otros. Por

Age-related changes of the main CAP parameters during development.

| Age | CAP rate% | A1% | A2% | A3% | A1 index | A2 Index | A3 Index |
|----------------|-----------|------|------|------|----------|----------|----------|
| 1–4 months | 12.9 | 85.2 | 10.3 | 4.4 | 19.8 | 2.8 | 0.5 |
| Pre-school-age | 25.9 | 63.2 | 21.5 | 15.3 | 24.8 | 6.5 | 4 |
| School-age | 33.4 | 84.4 | 6.4 | 9.1 | 39.5 | 2.7 | 3.3 |
| Peripubertal | 62.1 | 85.5 | 9.1 | 3.2 | — | — | — |
| Adolescence | 43.4 | 71.3 | 19.7 | 9.0 | 45 | 12.4 | 5.7 |
| Young adults | 31.9 | 61.4 | 27.9 | 10.7 | 25.5 | 11.6 | 4.4 |
| Middle age | 37.5 | 62.0 | 26.2 | 11.8 | 33.3 | 14.1 | 6.4 |
| Elderly | 55.3 | 46.6 | 35.3 | 18.1 | 30.0 | 22.7 | 11.6 |

Figure 2: Diferencia del CAP en las diferentes etapas del crecimiento.

Table 5

Changes of the main CAP parameters (vs. age-matched normal controls) in the different pathologies studied in adults.

| | CAP rate% | A1% | A2% | A3% |
|-----------------------------------|-----------|-----|-----|-----|
| Noise | ↑ | ↑ | ↑ | ↑ |
| Narcolepsy | ↓ | ↓ | ↑ | = |
| OSAS | ↑ | ↓ | = | ↑ |
| UARS | ↑ | — | — | — |
| Insomnia | ↑ | ↑ | ↑ | ↑ |
| Hypnotics (vs. placebo) | ↓ | ↓ | ↓ | =/↓ |
| First night effect ¹⁶² | ↑ | ↓ | ↑ | ↑ |
| PLM | ↑ | ↓ | ↑ | ↑ |
| Bruxism | = | ↓ | ↑ | ↑ |
| NFLE | ↑ | ↑ | ↑ | ↑ |
| PGE | ↑ | ↑ | ↑ | ↓ |
| Depression | ↑ | ↑ | ↑ | ↑ |
| Eating disorders | ↑ | — | — | — |
| MSA | ↓ | — | — | — |

OSAS: obstructive sleep apnea syndrome. UARS: upper airway resistance syndrome. PLM: periodic limb movements. RLS: restless legs syndrome. NFLE: nocturnal frontal lobe epilepsy. PGE: primary generalized epilepsy. MSA: multiple system atrophy.

Figure 3: Diferencia del CAP en diferentes desordenes presentes durante la etapa del sueño.

el contrario, situaciones o condiciones que estimulan el sueño bajan la frecuencia del CAP. Dicha estimulación puede ser causada por narcolepsia, apnea del sueño, déficit de atención, sueño después de periodos de privación del sueño entre otros. La **figura 3** muestra las diferencias en la frecuencia del CAP en diferentes desordenes que se pueden presentar al momento de dormir.

Ya que la fase A es el complemento del ruido basta con encontrar los momentos donde la amplitud de la varianza presente picos altos. Entonces la clasificación del CAP se resume en encontrar un algoritmo que haga lo dicho. En otro artículo llamado *A new quantitative automatic method for the measurement of non-rapid eye movement sleep electroencephalographic amplitude variability*[2] se describe un método para obtener métricas que tienen una correlación con los principales parámetros de CAP mostrados en la **Figura 1**.

Otros enfoques para clasificar el CAP automáticamente incluyen el uso de métodos de aprendizaje supervisado, como lo es el uso de redes neuronales o máquinas de soporte vectorial.

Objetivo general

Poder analizar las etapas del sueño dando especial importancia en las características conocidas como Patrones Alternantes Cíclicos (CAP) de la fase de sueño NREM para usar dicha información en un clasificador que determine si una patología del sueño esta presente en la persona

Objetivos específicos

- Segmentar las fases CAP del ciclo de sueño
- Extraer características de las fases del sueño
- Crear un clasificador para determinar si el paciente presenta alguna patología o no

Hipótesis

El CAP tiene la suficiente información para distinguir la calidad del sueño y se manifiesta incluso en cantidades tan pequeñas como la de un canal. Poder extraer la mayor información de dicha etapa puede nutrir nuestro entendimiento del sueño y con ello identificar patologías del sueño.

Trabajos similares

- DETECCIÓN DE PATRONES ALTERNANTES CÍCLICOS EN REGISTROS POLISOMNOGRÁFICOS DE NIÑOS [3]

El trabajo propuesto es el de analizar y detectar el CAP en infantes con algún desorden en el sueño. Para ello se propone el uso de un clasificador supervisado que pueda identificar las fases del sueño. La base de datos usada tiene las siguientes características:

- 48 registros
- CAP precalificado por un experto
- Canales conforme al sistema internacional 10-20
- Canales para la detección motora.

El diagrama de flujo del trabajo es el siguiente

- Se segmenta en ventanas de 30 segundos con un traslape del 50%. Se aplica una ventana de Hamming y se calcula la transformada de Fourier.
- Se calcula la varianza de la señal y se obtiene el promedio contextual de cada segmento. Este proceso se repite por cada canal seleccionado.
- Dichas características se pasan a un clasificador supervisado que determina si la ventana de 30 segundos contiene un CAP o no.

- *L-Tetrolet Pattern-Based Sleep Stage Classification Model Using Balanced EEG Datasets* [4]

Se encarga de encontrar exclusivamente un clasificador que logre discriminar si un EEG contiene alguna patología del sueño. No se usaron las métricas del CAP. La base de datos usada tiene las siguientes características:

- (CAP) Sleep dataset, de Physionet
- Clasificación en 3 clases: Insomnio, sin patología y otros
- CAP precalificado por un experto

El diagrama de flujo del trabajo es el siguiente

- Se agrupa toda la señal en una matriz de 3×3 y se calcula iterativamente métricas para alimentar un clasificador supervisado.
- Se aplica el algoritmo de **Relief**
- Se aplica el algoritmo de **Inca**
- Se entrena una CSVM para discriminar las clases

• *Automatic Cyclic Alternating Pattern (CAP) analysis: Local and multi-trace approaches* [5]

Este artículo se encarga de implementar el algoritmo para clasificar CAP del artículo [2]. Pero usa las características generadas para entrenar un algoritmo de clasificación supervisada que reconozca las etapas CAP en otros archivos. La base de datos se describe como:

- (CAP) Sleep dataset, de Physionet
- CAP precalificado por un experto
- Clasificación binaria, presencia de CAP o no.

El diagrama de flujo del trabajo es el siguiente

- Se separan las bandas de frecuencia en 2
- Aplica el algoritmo incluido en [2] para obtener métricas con alta correlación al CAP
- Cada segmento de 1 segundo se ignora como posible candidato. Cada dos etapas que están separadas solamente por 1 segundo se unen en una sola etapa.
- Entrena un SVM para marcar el CAP de futuras señales

En este documento también se hizo el experimento usando 5 canales y uno solo. Dando como resultado que no hay una mejoría notable usando 5 canales. Por otra parte el tercer paso que agrega sí aumenta la calidad del clasificador de CAP's

Resultados

Las métricas de cada trabajo están en la Tabla 1. El objetivo de cada artículo era distinto. Así que la comparación solo sirve para motivar la implementación de los algoritmos mencionados

El artículo 2 muestra que si es posible clasificar con algoritmo de aprendizaje supervisado, pero el

método utilizado para crear las características no está bien sustentado. Sin embargo el Artículo 1 y 3 dan la esperanza que el método propuesto en [2] es lo suficientemente bueno para extraer una suficiente información del CAP. k

También se buscaron trabajos que usaran un método de clustering para clasificar señales electroencefalográficas [6,7,8]. Usualmente, cada problema tiene su estándar de preprocesamiento. Luego se calculan métricas estadísticas para alimentar al clasificador.

Base de datos

La base de datos a usar es la (CAP) *Sleep database* alojada en Physionet.com. Cuenta con 108 registros los cuales se distribuyen de la siguiente forma:

- 2 Bruxismo
- 9 Insomnio
- 5 Narcolepsia
- 40 Epilepsia del lóbulo frontal nocturna
- 10 Movimientos periódicos de las piernas
- 22 Trastorno de conducta REM
- 4 respiración alterada durante el sueño

Los registros del dataset no son todos iguales. En algunos registros la frecuencia es diferente y en no están todas las columnas faltantes. Se garantiza que cada registro contiene al menos uno de los siguientes datos. EEG conforme al sistema 10-20, 2 Canales EOG, 2 Canales EMG y un posible EKG.

La metodología con la que fue tomado el dataset se desconoce. El dataset fue donado a Physionet por el profesor Mario Giovanni Terzano, profesor Liborio Parrino, y el equipo de expertos que trabaja en el Sleep Disorders Center of the Ospedale Maggiore de Parma, Italy,

Metodología seguida

Se utilizó una extracción de características igual a la que se usó en el tercer artículo, con el adición de que dichas características fueron utilizadas para entrenar un clasificador no supervisado que discrimina los registros de personas con alguna patología con los que no. El diagrama del algoritmo quedaría como sigue:

- Se separan las bandas de frecuencia en 2
- Aplica el algoritmo incluido en [2] para obtener los segmentos clasificados como CAP
- Cada segmento de 1 segundo se ignora como posible candidato. Cada dos etapas que están separadas solamente por 1 segundo se unen en una sola etapa.

Table 1: Resultados obtenidos por artículo

| | r tículo 1 | Artículo 2 | Artículo 3 |
|---------------|--------------|--------------------|--------------------|
| Base de datos | Ajena | CAP Sleep Database | CAP Sleep Database |
| Metrica | Sensibilidad | F-1 Score | F-1 Score |
| Resultado | 81 | 95 | 63 |

- Se calculan las características que se mencionan en [1].
- Dichas características son usadas para entrenar un algoritmo K-Means para clasificación binaria

Resultados finales

Los resultados del algoritmo son los vistos en la **Figura 4**. El algoritmo logro una precisión del 0.95, recall del 0.68 y f1-score de 0.79 para los registros de personas con patologia. Por otro lado, para los registros de personas de control, (o sin patologia) las metricas fueron de: 0.18 de precision, 0.67 de recall y un f1-score de 0.29. Presentando un accuracy del 0.68.

Conclusiones

El CAP demostró ser una métrica que contiene mucha información. En esté trabajo se implemento el algoritmo para detectar el CAP sin pensar en el rendimiento mostrado en los artículos relacionados . Esto puede servir como prueba de que el CAP en efecto es un marcador confiable para identificar patologías del sueño. Esto impulsa la investigación de nuevos métodos para clasificar el CAP pues los metodos que se tienen actualmente son muy pobres y es la mayor limitante para analizar la etapa del sueño NREM, lo cual es de especial interés porque en la actualidad es un proceso manual que requiere de conocimiento experto.

1. Parrino, L., Ferri, R., Bruni, O., Terzano, M. G. (2012). Cyclic alternating pattern (CAP): The marker of sleep instability. En *Sleep Medicine Reviews* (Vol. 16, Issue 1, pp. 27–45). Elsevier BV. <https://doi.org/10.1016/j.smrv.2011.02.003>
2. Marín Abarca, M. (2021). Detección de patrones alternantes cíclicos en registros polisomnográficos de niños. Disponible en <https://repositorio.uchile.cl/handle/2250/184069>
3. Tramonti Fantozzi, M. P., Faraguna, U., Ugon, A., Ciuti, G., Pinna, A. (2021). Automatic Cyclic Alternating Pattern (CAP) analysis: Local and multi-trace approaches. En F. Provini (Ed.), *PLOS ONE* (Vol. 16, Issue 12, p. e0260984). Public Library of Science (PLoS). <https://doi.org/10.1371/journal.pone.0260984>
4. Tramonti Fantozzi, M. P., Faraguna, U., Ugon, A., Ciuti, G., Pinna, A. (2021). Automatic Cyclic Alternating Pattern (CAP) analysis: Local and multi-trace approaches. En F. Provini (Ed.), *PLOS ONE* (Vol. 16, Issue 12, p. e0260984). Public Library of Science (PLoS). <https://doi.org/10.1371/journal.pone.0260984>
5. Manjusha, M., Harikumar, R. (2016). Performance analysis of KNN classifier and K-means clustering for robust classification of epilepsy from EEG signals. En *2016 International Conference on Wireless Communications, Signal Processing and Networking (WiSP-NET)* (pp. 2412–2416). 2016 International Conference on Wireless Communications, Signal Processing and Networking (WiSPNET). IEEE. <https://doi.org/10.1109/wispnet.2016.7566575>
6. Murugappan, M. (2011). Human emotion classification using wavelet transform and KNN. En *2011 International Conference on Pattern Analysis and Intelligence Robotics* (pp. 148–153). 2011 International Conference on Pattern Analysis and Intelligent Robotics (ICPAIR). IEEE. <https://doi.org/10.1109/icpair.2011.5976886>
7. Yazdani, A., Ebrahimi, T., Hoffmann, U. (2009). Classification of EEG signals using Dempster Shafer theory and a k-nearest neighbor classifier. En *2009 4th International IEEE/EMBS Conference on Neural Engineering* (pp. 327–330). 2009 4th International IEEE/EMBS Conference on Neural Engineering (NER). IEEE. <https://doi.org/10.1109/ner.2009.5109299>
8. FERRI, R., RUNDO, F., NOVELLI, L., TERZANO, M. G., PARRINO, L., BRUNI, O. (2011). A new quantitative automatic method for the measurement of non-rapid eye movement sleep electroencephalographic amplitude variability. En *Journal of Sleep Research* (Vol. 21, Issue 2, pp. 212–220). Wiley. <https://doi.org/10.1111/j.1365-2869.2011.00981.x>




Figure 4: Matriz de confucion resultante